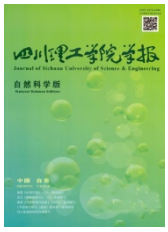

四川轻化工大学学报(自然科学版)
Journal of Sichuan University of Science & Engineering(Natural Science Edition)
ISSN 2096-7543,CN 51-1792/N

《四川轻化工大学学报(自然科学版)》网络首发论文

题目：　基于 CLD-YOLO 的高粱病虫害识别方法
作者：　任方俊，华才健，陈玉章
收稿日期：　2024-10-14
网络首发日期：　2026-03-06
引用格式：　任方俊，华才健，陈玉章. 基于 CLD-YOLO 的高粱病虫害识别方法[J/OL]. 四川轻化工大学学报(自然科学版).
https://link.cnki.net/urlid/51.1792.N.20260306.1532.002

网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

网络首发时间：2026-03-06 17:28:50　网络首发地址：https://link.cnki.net/urlid/51.1792.N.20260306.1532.002

基于 CLD-YOLO 的高粱病虫害识别方法

任方俊[1a]，华才健[1a]，陈玉章[1b,2]

（1. 四川轻化工大学 a 计算机科学与工程学院，b 生物工程学院，四川 宜宾 644000；
2. 四川省酿酒专用粮工程技术研究中心，四川 宜宾 644000）

摘　要：针对自然环境下的高粱病虫害检测难度大的问题，提出了一种基于改进 YOLOv8n 的高粱病虫害检测模型 CLD-YOLO。首先，在主干网络中引入 ODConv 结构替代传统卷积，以减少背景噪声干扰，增强模型对高粱叶片特征的聚焦，从而提升识别精度。其次，在主干网络的 SPPF 模块之后引入 LSKA 注意力机制，充分融合卷积与自注意力的优势，有效突出病虫害的细节特征，进一步提高检测精度。最后，在颈部网络采用 DySample 动态上采样技术，使其能够更精准地定位和识别高粱的病虫害部分，显著提高了高粱病虫害的检测能力。实验结果表明，CLD-YOLO 在高粱病虫害图像识别任务中的 mAP50%达到了 90.9%，精确度为 90.5%，计算量为 7.3 GFLOPs。相比于 YOLOv8n，mAP50%提升了 3.8%，精确度提升了 5.1%，计算量下降了 9.9%。改进后的模型具有更高的识别精度，目标定位更加准确，适用于自然环境中高粱病虫害的精准识别，为高粱病虫害智能化识别提供了理论参考。

关键词：高粱病虫害；目标检测；注意力机制；动态上采样；YOLOv8n

中图分类号：TP391.4　　**文献标志码：**A

引　言

高粱作为世界五大农作物之一，在我国已有了上千年的种植、食用及酿造历史，是我国最为主要的粮食作物之一，同时也是中国白酒产业最为常用的酿酒原料之一[1]。然而，高粱的生长过程中常常遭受各种病虫害，严重影响了高粱的产量与品质。传统的病虫害识别方法通常依赖于人工观察，存在主观性强、耗时费力、准确度低等问题，难以满足大规模高粱种植的需求。

近年来，深度学习技术在计算机视觉领域取得了显著成就，其在农业领域的应用日益广泛。特别是在农作物病虫害检测方面[2]，深度学习模型发挥重要作用，极大地推动了病虫害识别技术的实际应用。目前，应用于病虫害检测的目标检测算法主要分为两大类。第一类是两阶段目标检测算法，代表性算法包括 Mask R-CNN[3]和 Faster-RCNN[4]等。BARI 等[5]使用 Faster-RCNN 对 3 种水稻病害进行检测，尽管检测精度有所提升，但由于检测速度较慢，难以满足水稻病害检测的实时性需求。第二类是一阶段目标检测算法，该类算法通过卷积神经网络（Convolutional Neural Network, CNN），直接预测出目标的分类结果和位置，代表算法主要有 SSD[6]、YOLO[7-8]系列等。Sun 等[9]构建了一个轻量级卷积神经网络 MEAN-SSD，成功地在移动设备上检测了 5 种苹果叶片病害，同时降低了模型大小。Wang 等[10]提出了一种适用于复杂自然背景的 YOLOv4-GCF 荔枝病虫害检测模型，该模型能够有效减弱复杂背景的影响，快速且精准地识别图像中的荔枝病虫害目标。Li 等[11]在 YOLOv5n 模型上进行黄瓜病害检测研究，引入了协调注意力机制和 Transformer 结构，显著提高了模型的检测精度和鲁棒性。Soeb 等[12]提出针对自然环境下的 YOLO-T 茶叶病害自动检测模型，检测精度优于现存的 CNN、深度神经网络（Deep Neural Network, DNN）等模型。

针对自然环境下高粱病虫害检测存在的不足，如识别准确度低、模型内存占用较大、区分相似病虫害困难、实时性和计算效率有待提高，难以完全满足实际生产需求等问题，提出一种在 YOLOv8 模型上增加注意力机制的高粱病虫害检测模型 CLD－YOLO（Composite Learning Detection-YOLO），以期为高粱病虫害的自动化防控提供理论基础。

1 改进的 CDL-YOLO 算法

1.1 目标检测网络 CLD-YOLO

YOLOv8n 模型是 YOLOv8[13] 系列中的轻量化版本，它具备较小的深度和宽度，能够在资源受限

收稿日期：2024-10-14
基金项目：国家自然科学基金面上项目(42471437)
通信作者：华才健(1977-),男,副教授,博士,研究方向为大数据分析、计算机视觉,(E-mail)hwacj@suse.edu.cn

的环境中实现高效的目标检测。由于 YOLOv8n 设计紧凑，具有卓越的精度、速度和架构灵活性，同时具备良好的扩展性和轻量化特性，这些性能使其特别适合在资源受限设备上部署，因此选择在其基础上进行改进，从而得到用于高粱病虫害检测算法（CLD-YOLO）。首先，将 YOLOv8 骨干网络中的传统卷积模块（Conv）替换为 ODConv 卷积模块，抑制杂乱背景信息的干扰，使模型更专注于提取高粱叶片的特征，从而提升其识别精度。然后，在骨干网络中引入大型可分离核注意力（LSKA）模块，该模块融合了卷积与自注意力机制，能够更高效地捕获高粱病虫害图像中的局部上下文特征，动态调整通道维度。在不增加计算负担的前提下，LSKA 模块放大了图像细节，进一步提高了检测的准确性。最后，通过引入DySample动态上采样技术，增强模型对细节的感知能力，使其能够更精确地定位和识别高粱病虫害区域。此外，该模块几乎未增加模型的参数量，确保了网络的轻量化与精度的同步提升。CLD-YOLO 的网络结构图如图 1 所示。

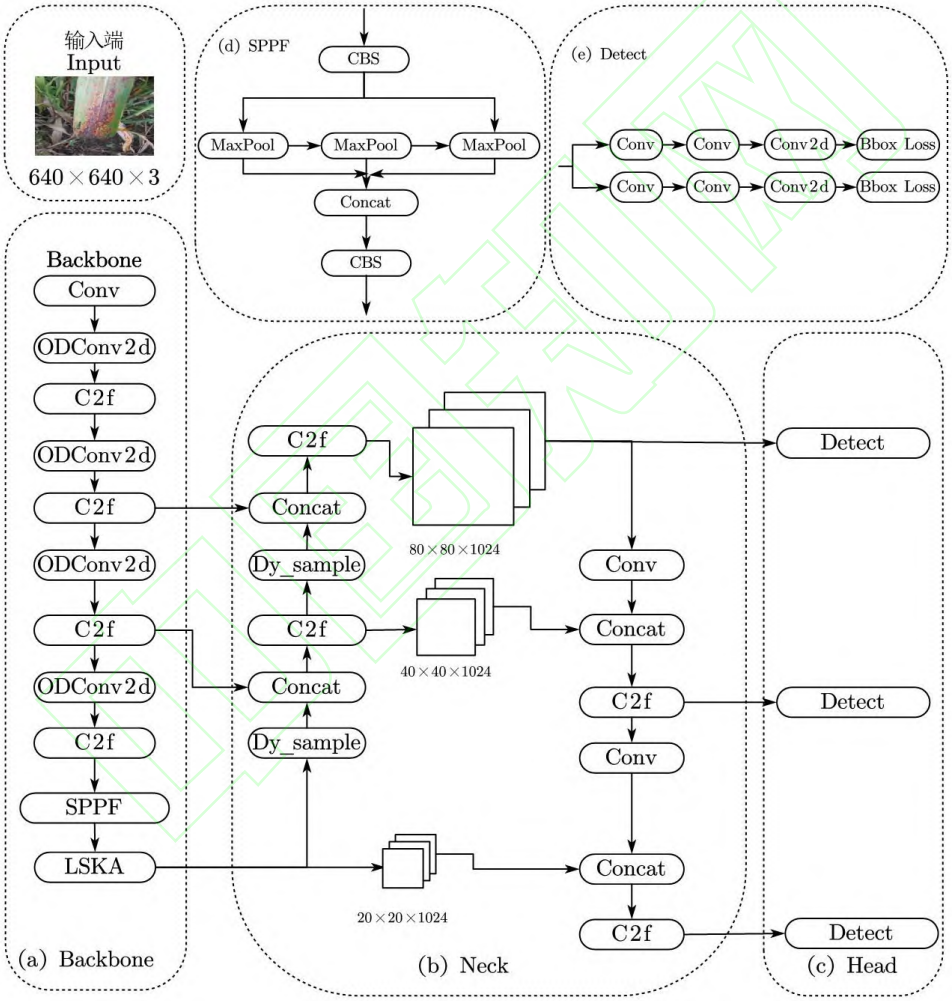

图 1 CLD-YOLO 网络结构图

1.2 ODConv 模块

对于在自然环境下进行高粱病虫害识别，提高模型精度的关键在于抑制杂乱背景信息的干扰，使模型更专注于提取高粱叶片的特征。全维动态卷积 ODConv[14]采用并行策略结合多维注意力机制，在卷积核张量的 4 个维度上实施自适应加权，从而实现卷积核的动态调制与优化。该方法不仅关注输入通道、输出通道和空间维度，还考虑了卷积核的形状与大小，全面优化了卷积过程。这种方法可以增强模型对高粱病虫害特征的关注度，从而提高识别准确率，其结构图如图 2 所示。

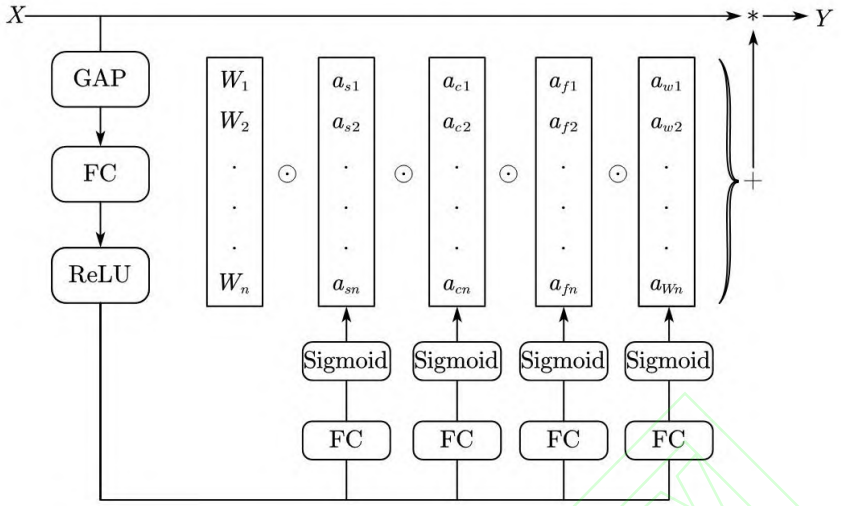

图 2 ODConv 结构图

ODConv 对动态卷积可以描述成如式(1)所示。

$$y=(a_{w1}\square a_{f1}\square a_{c1}\square a_{s1}\square W_1+\ldots +a_{wn}\square a_{fn}\square a_{cn}\square a_{sn}\square W_n)*x \tag{1}$$

其中，x、y 分别表示输入和输出特征；W_i 表示卷积核；a_{s1}、a_{c1}、a_{f1} 和 a_{w1} 分别为空间维度、输入通道维度、输出通道维度和卷积核维度的的注意力权重；*表示卷积核的运算；⊙表示在核空间不同维度上的乘法运算。这 4 种注意力机制相互补充，能够在位置、通道、滤波器和卷积核维度上对卷积核 W_i 进行不同的加权处理并进行累加，使得卷积操作在输入的各个维度上展现出差异化表现。通过这种方式，模型能够更加精准地捕捉高粱病虫害病斑的关键特征及其上下文信息，从而提升整体性能和泛化能力。本文采用全维动态卷积 ODConv 来替代主干网络中的普通卷积，以增强网络的特征提取能力和上下文信息的捕捉能力，确保模型能够充分挖掘高粱叶片病虫害的特征，从而提升检测的精度。

1.3 LSKA 注意力机制

由于高粱病虫害病斑形状复杂，病变的部分表现出的颜色多样，一些病变部分的颜色相似而难以对其难以进行辨识。为了提高模型在复杂背景中提取病变特征的能力，本文引入了 LSKA 注意力机制[15]。LSKA（Large Separable Kernel Attention）是对 LKA（Large Kernel Attention）注意力机制[16]的改进，其注意力机制对比如图 3 所示。与标准 LKA 设计不同，LSKA 将 LKA 模块中的二维深度卷积和深度扩展卷积核分解为水平方向和垂直方向的两个一维卷积核，并将分解后的卷积核串联使用。通过这种设计，LSKA 能够在不引入额外模块的情况下直接应用大核的深度卷积层，不仅能够持续关注病变区域并放大其细节，且在不增加计算负担的前提下显著提升检测的准确性。

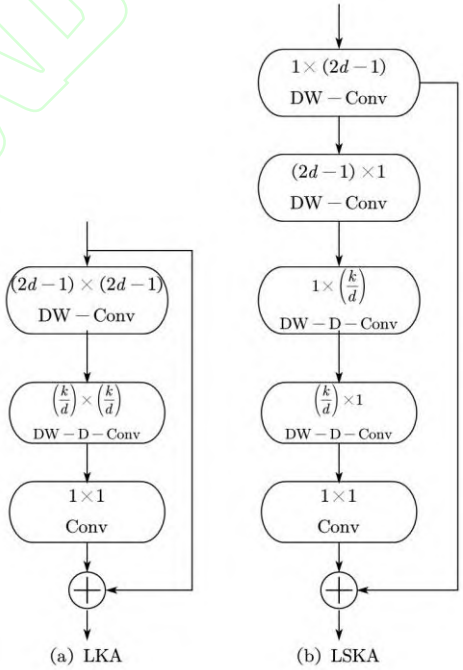

图 3 LKA 和 LSKA 注意力机制对比

1.4 颈部网络中的上采样算子改进

颈部网络中的上采样算子通常用于恢复特征图像的分辨率，以便更好地解析图像中的细节信息。原模型采用的是最近邻插值法，这种方法虽然简单直观，但没有考虑其他邻近像素值的权重，导致上采样后的高粱病虫害图像出现锯齿状边缘和模糊的纹理，从而使得病虫害部分与健康部分难以分辨。为了解决此问题，引入动态上采样（DySample）[17]，

在提高特征图分辨率的同时，Dysample 也能够更好地还原病虫害部分特征，从而提高模型对病斑细节的感知能力。DySamples 上采样流程如图 4 所示。

首先是网格采样（Gird Sample）过程，给定大小为 $C\times H\times W$ 的特征图 X 和一个大小为 $2g\times sH\times sW$ 的采样集 S，其中采样集 S 由采样点生成器生成，Grid_sample 函数使用采样集 S 中的位置对 X 重新采样得到大小为 $C\times sH\times sW$ 的特征图 X'，此过程数学表达式如式(2)所示。

$$X'=\text{Grid_sample}(X,S) \tag{2}$$

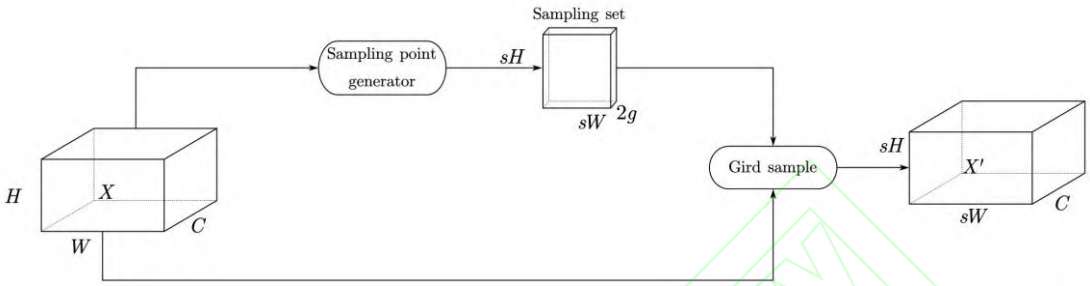

图 4 DySample 上采样流程

采样集 S 的实现方式如图 5 所示。输入特征图 X 通过 2 个并行的线性变换层输出 2 个尺寸为 $H\times W\times 2gs^2$ 的偏移量 O_1 和 O_2，$2gs^2$ 表示模型为特征图 X 中得每个空间位置预测的偏移通道数。通过将 O_1 的采样因子设置为动态因子 0.5σ，O_2 的采样因子取默认值进行输出；将偏移量 O_1 与 O_2 结合后通过像素重组，生成大小为 $2g\times sH\times sW$ 的偏移量 O；最终通过将偏移量 O 与原始的采样网格 G 之和得到采样集 S，其数学表达式如式(3)、式(4)所示：

$$O=linear(X) \tag{3}$$

$$S=G+O \tag{4}$$

该方法通过学习偏移量来动态调整上采样的每个点，从而更精确地恢复高粱病虫害的病斑细节特征。这不仅增强了模型对细节的感知能力，还能够更准确地定位和识别高粱的病虫害部分。

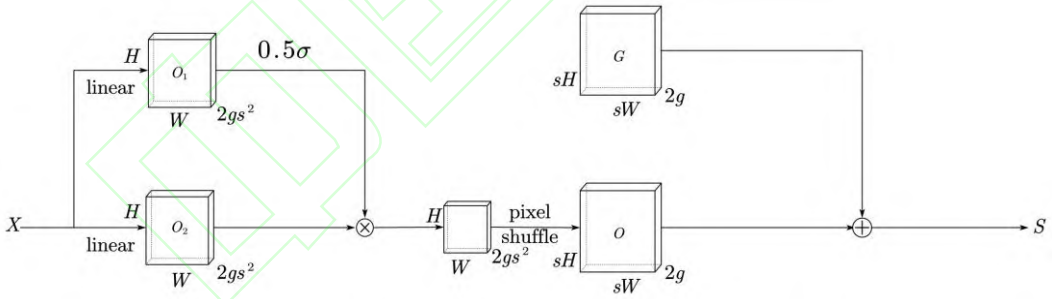

图 5 动态采样中的采样点生成器

2 数据集与实验配置

2.1 高粱病虫害数据集介绍

为了满足酿酒专用高粱病虫害[18]识别的需求，本文构建了一个专用于高粱病虫害的数据集。此外，为了覆盖到常见的高粱病虫害类型，纳入了 Thite 等[19]公开发布的数据集。其中酿酒专用高粱病虫害图像数据来自四川轻化工大学酿酒专用粮工程技术研究中心实验室以及五粮液酿酒专用粮种植基地，使用手机作为图像采集设备，在不同时刻和拍摄角度的条件下，对高粱病虫害部位进行多方位、多角度、多种距离拍摄。数据集含 4670 张高粱病虫害图像，独立分布，主要分为七种常见的高粱病虫害类别：炭疽和红腐病、黑穗病、谷物霉菌、锈病、蝼蛄、东方黏虫、芒蝇。高粱病虫害种类如图 6 所示。

图 6 高粱病虫害图像

将数据集按 8∶1∶1 的比例划分为训练集、验证集和测试集，并对其进行了手动标注。具体来说，使用 LabelImg 软件对高粱的病虫害区域进行标注，添加了相应的识别框。该软件生成了对应的标签文件，生成的 txt 文件包含目标的标签信息，便于后续模型的训练和数据处理。由于样本数量不均衡，为增强网络的泛化能力，防止图像数量不足导致过拟合，使用翻转、比例缩放、局部裁剪、改变对比度等数据增强方法，平衡各类病虫害的数量，同时去除不符合条件的增强图像。高粱病虫害数据集的详细信息见表 1。

表 1 高粱病虫害图像数据集

分类	图像数/张							总计/张
	炭疽和红腐病	黑穗病	谷物霉菌	锈病	蝼蛄	东方黏虫	芒蝇	
训练集	498	240	474	718	607	476	731	3744
验证集	63	42	71	68	88	72	60	464
测试集	60	43	67	72	80	72	68	462
共计/张	621	325	612	858	775	620	859	4670

2.2 实验配置和评价指标

实验使用 Pytorch 框架，它是一种灵活且易用的开源深度学习工具库，能够高效地构建和训练深度神经网络模型。实验环境及相关参数见表 2。

表 2 实验配置

名称	配置
操作系统	Ubuntu 20.04.6
CPU	Intel(R) Xeon(R) Silver 4210R CPU @ 2.40GHz
显卡	NVIDIA GeForce RTX 3080 10GB
Epochs	200
Batch	16

为了验证模型对自然环境下高粱病虫害的检测性能，使用深度学习领域中常见的评价指标来验证检测模型的性能，包括：准确率（Precision，P）、召回率（Recall，R）、平均精确度均值（mean Average Precision，mAP）、计算量（GFLOPs）以及参数量（Parameters）。计算公式如式(5)-式(8)所示：

$$P=\frac{T_{\mathrm{P}}}{T_{\mathrm{P}}+F_{\mathrm{P}}} \tag{5}$$

$$R=\frac{T_{\mathrm{P}}}{T_{\mathrm{P}}+F_{\mathrm{N}}} \tag{6}$$

$$f_{AP}=\int_0^1 P(R)\mathrm{d}R \tag{7}$$

$$f_{\mathrm{mAP}}=\frac{1}{n}\sum_{i=1}^{n} AP_i \tag{8}$$

准确率是所有检测为受到病虫害结果中真正受病虫害数量所占比例。召回率是所检测到受害数量在实际受害总量中所占的比例。平均精度 AP 是基于精确度和召回率进行计算的，P-R 曲线下的面积即为 AP 的值，mAP 则是所有类别 AP 的平均值。mAP 作为目标检测的主要评估指标，它能够全面反映模型的整体性能，值越高表明模型的性能越好。$mAP_{0.5}$ 表示当 IoU 阈值设为 0.5 时的平均精度。$GFLOPs$ 用于测量模型运行时间，它的值越低，则代表模型较小，模型执行计算量和所需时间也就越少。

3 实验与分析

3.1 实验结果

图 7 展示了改进算法与原始 YOLOv8 算法在相

同训练策略下的对比实验结果，横轴表示训练轮次，纵轴显示了评估指标。从对比曲线可以看出，改进模型在各项性能指标上均优于 YOLOv8 算法。具体而言，与 YOLOv8 算法相比，改进模型的精度、召回率和平均精度均值（在交并比 IoU 阈值为 0.5 时的 mAP）分别提高了 5.1 个百分点、0.8 个百分点和 3.8 个百分点。

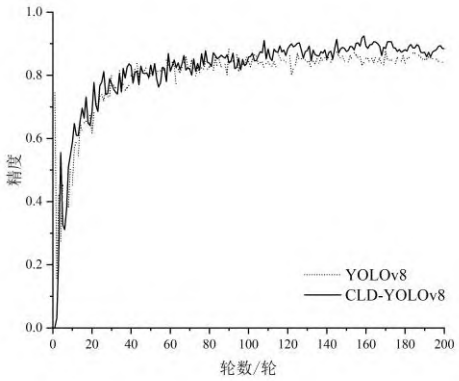

(a) 精度对比

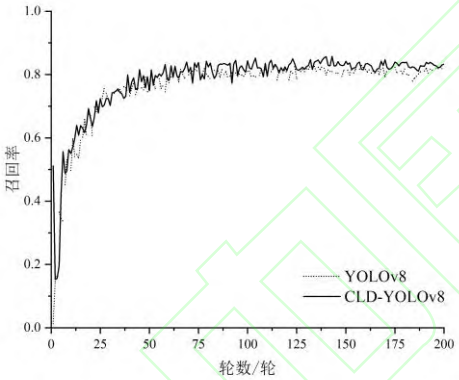

(b) 召回率对比

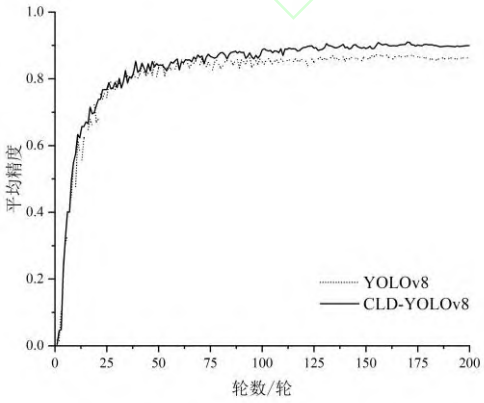

(c) 平均精度对比

图 7 本文模型与 YOLOv8 的试验结果可视化对比

3.2 主流模型性能对比

CLD-YOLO 算法是基于 YOLOv8n 模型基础上改进，为验证其优越的检测性能，在相同的实验环境下，将 CLD-YOLO 与当前主流的目标检测算法（如 Faster-RCNN、SSD 以及 YOLO 系列）进行了检测性能的对比，实验结果见表 3。所有模型均在统一的数据集与参数配置下进行了 200 轮的迭代训练与测试。

表 3 多种模型对比实验结果

模型	*P*/%	*R*/%	$mAP_{0.5}$/%	*Params*/M	*FLOPs*/G
Faster-RCNN	44.9	83.1	73.8	137.099	370.21
SSD	85.4	72.4	82.1	26.285	62.75
YOLOv3	86.1	81.8	86.4	61.556	155.40
YOLOv3-tiny	84.5	78.7	84.8	12.131	18.90
YOLOv6	86.1	80.8	86.5	4.234	11.80
YOLOv7-tiny	81.0	80.7	83.1	6.030	13.20
YOLOv8n	85.4	81.6	87.1	3.007	8.10
YOLOv9s	88.7	81.8	88.8	9.748	39.60
CLD-YOLO	90.5	82.4	90.9	4.282	7.30

从表中可以看出，Faster-RCNN、SSD、YOLOv3、YOLOv3-tiny 等模型的检测计算量和参数量较大，模型过于冗余，不适合在计算资源有限的设备上部署，也难以胜任复杂多变环境下的高粱病虫害检测任务。相较之下，CLD-YOLO 模型在精确度、$mAP_{0.5}$ 等多个性能指标上表现优越。具体而言，CLD-YOLO 模型的检测准确度相比 SSD、YOLOv3、YOLOv3-tiny、YOLOv6、YOLOv7-tiny、YOLOv8n 和 YOLOv9s 模型分别提升了 5.1、4.4、1.2、4.4、9.5、5.1 和 1.8 个百分点；召回率分别提高了 10.0、0.6、3.7、1.6、1.7、0.8 和 0.6 个百分点；$mAP_{0.5}$ 则分别提升了 8.8、4.5、6.1、4.4、7.8、3.8 和 2.1 个百分点。在计算量方面，CLD-YOLO 模型仅次于 YOLOv5。总体而言，本文提出的 CLD-YOLO 模型相对所比较的主流模型在保持小模型和低计算量的同时，显著提升了检测精度，其 $mAP_{0.5}$ 达到 90.5%，模型参数量仅为 4.28 M，计算量仅为 7.3 G。这一特性很好地平衡了检测精度与轻量化需求，能够更加高效地应对复杂多变的环境，实现高粱病虫害检测。此外，CLD-YOLO 在计算资源有限的设备上部署更加便捷。

从图 8 中各主流目标检测模型对自然环境下病虫害的检测结果可以看出，本文提出的 CLD-YOLO 模型具有更高的识别精度。相比之下，其他模型存在目标定位不完整或精度不足的问题。尽管 Faster-RCNN 在某些类别上表现出较高的置信度，但由于其模型参数较大，不适合部署在资源受限的设备上。综上所述，CLD-YOLO 保证有较高的检测精度的同时，满足轻量化要求，能够在资源受限的设备上进行检测。

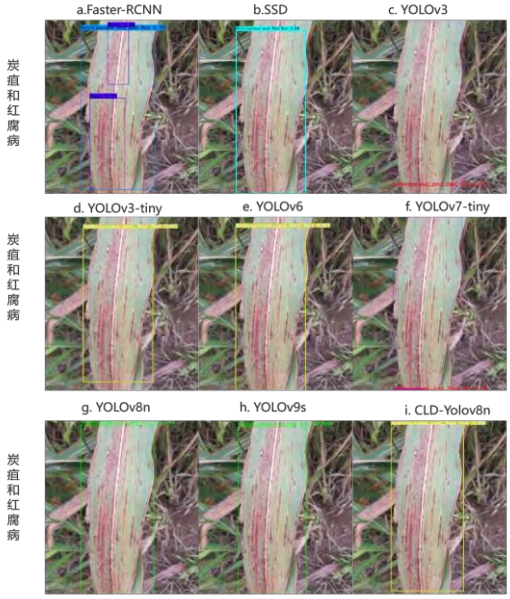

(a) 炭疽和红腐病

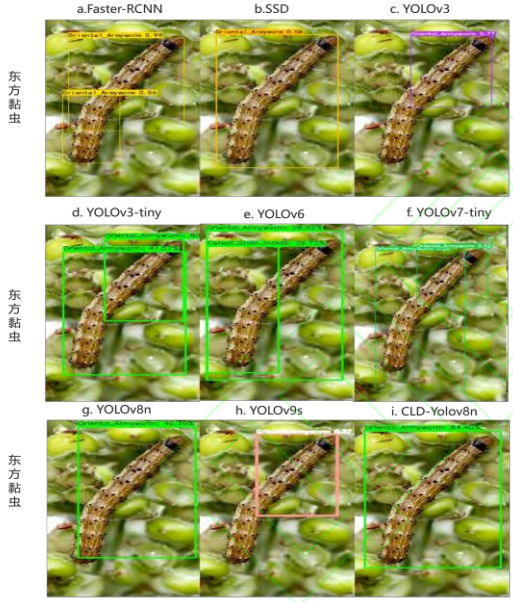

(b) 东方黏虫

图 8 自然环境下虫害检测结果图

3.3 消融实验性能对比

为了验证各个改进模块的有效性，在共同应用 YOLOv8n 模型框架的前提下，进行消融实验，结果见表 4。基于原始 YOLOv8n 模型，检测模型的 $mAP_{0.5}$ 达到了 87.1%。在此基础上，分别引入 ODConv 卷积、可分离核注意力（LSKA）模块和 DySample 动态上采样后，模型的 $mAP_{0.5}$ 分别提升了 1.5、2.0 和 1.3 个百分点，验证了各个模块的添加对模型性能的有效提升。

表 4 消融实验结果

改进方法	*P*/%	*R*/%	$mAP_{0.5}$/%	*Params*/M	*FLOPs*/G
YOLOv8n	85.4	81.6	87.1	3.007	8.1
YOLOv8n+ODConv	88.2	81.9	88.6	4.199	7.2
YOLOv8n+LSKA	87.5	82.6	89.1	3.080	8.1
YOLOv8n+DySample	85.6	81.1	88.4	3.019	8.1
YOLOv8n+ODConv+LSKA	85.3	82.2	89.4	4.270	7.2
YOLOv8n+ODConv+LSKA+DySample	90.5	82.4	90.9	4.282	7.3

通过更全面的评价指标可知，在将主干部分的 Conv 卷积替换为 ODConv 卷积后精确度提升了 2.8 百分点，$mAP_{0.5}$ 提升了 1.5 个百分点，GFLOPs 减少了 11.1 百分点，说明引入的 ODConv 卷积不仅降低了计算量，而且也提升了精确度。在已引入 ODConv 的模型基础上，于主干 SPPF 后进一步引入 LSKA 模块，$mAP_{0.5}$ 由 88.6%提升至 89.4%，再次提升 0.8 个百分点，且计算量保持不变，说明引入的 LSKA 模块能够更好地捕捉高粱病虫害图像病斑的局部上下文信息。最后，在同时引入 ODConv 与 LSKA 的基础上，将颈部上采样替换为 DySample 后，精确率提升至 90.5%，$mAP_{0.5}$ 提升至 90.9%，分别提升 5.2 和 1.5 个百分点。通过依次添加各个模块，证明了融合后网络的合理性。

3.4 高粱病虫害识别移动端应用设计

将改进后的 CLD-YOLO 模型通过 Pytorch 的加速推理框架进行格式转换和加载后，部署于 Flask 服务器并开发高粱病虫害识别小程序。用户可以通过该小程序，上传或拍摄高粱病虫害图片，小程序将图片上传至 Flask 服务器进行预测，并将结果返回至小程序前端，用户可以直接查看高粱病虫害信息，了解病害成因及相应的治疗方法。除了病害识别功能外，小程序还提供了常见的高粱病虫害类别模块，帮助用户学习相关知识，相关功能如图 9 所示。通过该小程序，用户能够及时识别高粱病虫害类型及其分布情况，针对性地使用药物进行治疗，进而增加高粱产量。

(a) 图片识别界面　　(b) 识别结果界面

(c) 病虫信息界面　　(d) 病虫类别界面

图 9 小程序功能图

4 结束语

鉴于高粱叶片病虫害形态复杂、颜色特征区分度低等难题，针对酿酒专用高粱病虫害识别的需求，提出了一种改进的高粱叶片病虫害检测模型 CLD-YOLO。主要研究结论如下。

1）在主干网络中引入 ODConv 结构，替代传统卷积，减少了杂乱背景信息的干扰，使模型更专注于提取高粱叶片的特征，从而提升识别的准确性。此外，在原有主干网络的 SPPF 模块之后，加入了 LSKA 注意力机制，同样起到了抑制背景噪声、强化特征提取的作用，进一步提高了模型的识别精度。

2）通过使用 DySample 动态上采样，增强了模型对细节的捕捉能力，使其能够更加精准地定位和识别高粱病虫害区域。改进融合了 YOLOv8 的核心模块，提出了 CLD-YOLO 高粱叶片病虫害检测模型，实现了高精度的高粱叶片病虫害检测。

3）改进后的 CLD-YOLO 模型在本文数据集上，$mAP_{0.5}$ 达到 90.9%，较 YOLOv8n 提升了 3.8 个百分点。精确度为 90.5%，较 YOLOv8n 提升了 5.1 个百分点。

在未来的工作中，计划建立图像分割模型，对病虫害目标进行精细分割，并优化模型参数，在保持精度的同时实现轻量化边缘设备部署，以达到实现对高粱病虫害部位精准施药，减少农药使用，降低较传统均匀施用化学农药方式对环境造成的负面影响。

参考文献：

[1] 张福耀,平俊爱.高粱的起源、驯化与传播[J].陕西农业科学,2022,68(4):82-87.

[2] 王彦翔,张艳,杨成娅,等.基于深度学习的农作物病害图像识别技术进展[J].浙江农业学报,2019,31(4):669-676.

[3] XU Y Y,LI D W,XIE Q,et al.Automatic defect detection and segmentation of tunnel surface using modified Mask R-CNN[J].Measurement,2021,178:109316.

[4] REN S Q, HE K M, GIRSHICK R, et al. Faster R-CNN:towards real-time object detection with region proposal networks[J].IEEE Transactions on Pattern Analysis and Machine Intelligence,2017,39(6):1137-1149.

[5] BARI B S,ISLAM M N,RASHID M,et al.A real-time approach of diagnosing rice leaf disease using deep learning-based faster R-CNN framework[J].PeerJ Computer Science,2021(7):e432.

[6] LIU W,ANGUELOV D,ERHAN D,et al.SSD:single shot multibox detector[C]//Computer Vision–ECCV 2016:14th European Conference,Amsterdam,The Netherlands,October 11-14,2016:21-37.

[7] DIWAN T,ANIRUDH G,TEMBHURNE J V.Object detection using YOLO:challenges,architectural successors,datasets and applications[J].Multimedia Tools and Applications,2023,82(6):9243-9275.

[8] WANG C Y,BOCHKOVSKIY A,LIAO H M.YOLOv7:trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]//2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR),Vancouver,Canada,June 17-24, 2023:7464-7475.

[9] SUN H N,XU H W,LIU B,et al.MEAN-SSD:a novel real-time detector for apple leaf diseases using improved light-weight convolutional neural networks[J].Computers and Electronics in Agriculture,2021,189:106379.

[10] WANG W X,LIU Z Q,GAO P,et al.Detection of Litchi diseases and insect pests based on improved YOLOv4 model[J].Transactions of the Chinese Society for Agricultural Machinery,2023,54(5):227-235.

[11] LI S F,LI K Y,QIAO Y,et al.A multi-scale cucumber disease detection method in natural scenes based on YOLOv5[J].Computers and Electronics in Agriculture,2022,202:107363.
[12] SOEB M J A,JUBAYER M F,TARIN T A,et al.Tea leaf disease detection and identification based on YOLOv7 (YOLO-T)[J]. Scientific Reports,2023,13(1):6078.
[13] TERVEN J,CÓRDOVA-ESPARZA D M,ROMERO-GONZÁLEZ J A.A comprehensive review of YOLO architectures in computer vision:from YOLOv1 to YOLOv8 and YOLO-NAS[J].Machine Learning and Knowledge Extraction,2023,5(4):1680-1716.
[14] QIAN J J,LIN J,BAI D,et al.Omni-dimensional dynamic convolution meets bottleneck transformer:a novel improved high accuracy forest fire smoke detection model[J].Forests,2023,14(4):838.
[15] LAU K W,PO L M,REHMAN Y A U.Large separable kernel attention:Rethinking the large kernel attention design in CNN[J].Expert Systems with Applications,2024, 236:121352.
[16] GUO M H,LU C Z,LIU Z N,et al.Visual attention network[J].Computational Visual Media,2023,9(4):733-752.
[17] LIU W Z,LU H,FU H T,et al.Learning to Upsample by Learning to Sample[C]//2023 IEEE/CVF International Conference on Computer Vision (ICCV),Paris,France,October 01-06,2023:6027-6037.
[18] 宜宾市农业农村局.酿酒专用粮 宜宾糯红高粱绿色生产技术规程:DB5115/T 29—2020[S].宜宾:宜宾市市场监督管理局,2020.
[19] THITE S,PATIL K.Sorghum disease image dataset[DB/OL].(2024-6-15)[2024-10-10].https://data.mendeley.com/datasets/fgb3cmfrg2/1.

引用格式：

中 文: 任方俊,华才健,陈玉章.基于 CLD-YOLO 的高粱病虫害识别方法[J].四川轻化工大学学报(自然科学版),2026,39(2)

英 文:REN F J,HUA C J,CHEN Y Z.Sorghum pest and disease identification method based on CLD-YOLO[J].Journal of Sichuan University of Science & Engineering (Natural Science Edition),2026,39(2)

Sorghum Pest and Disease Identification Method Based on CLD-YOLO

REN Fangjun[1a], HUA Caijian[1a], CHEN Yuzhang[1b,2]

(1a. School of Computer Science and Engineering, 1b. School of Biological Engineering, Sichuan University of Science & Engineering, Yibin 644000, China; 2. Sichuan Province Engineering Technology Research Center of Liquor-Making Grains, Yibin 644000, China)

Abstract: To address the challenges of sorghum pest and disease detection in natural environments, we propose a sorghum pest and disease detection model, CLD-YOLO, based on an improved YOLOv8n. First, the ODConv structure is introduced into the backbone network to replace traditional convolutions. This modification reduces background noise interference and enhances the model's focus on sorghum leaf features, thereby improving detection accuracy. Additionally, the LSKA attention mechanism is incorporated after the SPPF module in the backbone network, effectively combining the strengths of convolution and self-attention to highlight the detailed features of diseases and pests, further enhancing detection precision. Finally, the DySample dynamic upsampling technique is applied in the neck network to enable more precise localization and identification of sorghum pest and disease-affected areas, significantly boosting detection performance. Experimental results show that CLD-YOLO achieves a mAP0.5 of 90.9% and an accuracy of 90.5% in sorghum pest and disease image recognition tasks, with a computational load of only 7.3 GFLOPs. Compared to YOLOv8n, mAP0.5 improved by 3.8 percentage points, accuracy by 5.1 percentage points, and computational load decreased by 9.9%. The improved model offers higher recognition accuracy and more precise target localization, making it suitable for accurate detection of sorghum pests and diseases in natural environments. It provides a theoretical basis for the intelligent recognition of sorghum pests and diseases.

Key words: sorghum pests and diseases; target detection; attention mechanism; dynamic upsampling; YOLOv8n