doi:10.6041/j.issn.1000-1298.2026.04.031

基于改进 YOLO v8 的水稻害虫检测方法

刘善梅　程　焜　翟瑞芳　陈　阳　彭　辉
（华中农业大学信息学院，武汉 430070）

摘要： 为实现对复杂背景下多尺度水稻害虫的实时精准检测，构建了一个涵盖多种水稻害虫图像的数据集，提出了一种水稻害虫实时检测模型 YOLO v8－FDI。该模型基于 YOLO v8n 架构，采用 FasterNet 作为主干网络，在保持对害虫特征敏感度的同时，优化了网络结构；通过引入 Dynamic Head 技术，模型能够动态调整输出层检测头，以更好地适应不同类型和尺寸的害虫特征，进而提升模型精度和泛化能力；通过采用 Inner－IoU 损失函数，模型在损失计算过程中能够自动调节比例因子，不仅加快了模型训练收敛速度，还进一步提高了模型性能。实验结果表明，YOLO v8－FDI 模型处理单幅害虫图像平均时间为 12.43 ms，具备每秒处理超过 80 帧图像能力，满足了实际应用中的实时性要求。在测试集上，YOLO v8－FDI 模型的精确率、平均精度均值（mAP@0.5:0.95）和 F1 分数分别为 97.7%、94.0% 和 97.2%，相较于 YOLO v3－tiny、YOLO v5n、YOLO v7－tiny、YOLO v8n、YOLO v9t 和 YOLO v10n 模型，精确率分别提升 5.2、2.7、6.7、3.4、2.2、3.2 个百分点；mAP@0.5:0.95 分别提升 10.8、5.4、18.1、2.3、1.0、6.4 个百分点；F1 分数分别提升 2.6、2.0、4.9、1.2、1.3、2.9 个百分点。所构建的 YOLO v8－FDI 模型实现了复杂背景下多尺度水稻害虫实时精准检测，可为农业害虫实时监测提供技术支撑。

关键词： 水稻；害虫检测；YOLO v8n；FasterNet；Dynamic Head

中图分类号： TP391.4；S431.3　　**文献标识码：** A　　**文章编号：** 1000-1298(2026)04-0317-10　　**OSID：**

Rice Pest Detection Method Based on Improved YOLO v8

LIU Shanmei　CHENG Kun　ZHAI Ruifang　CHEN Yang　PENG Hui
(*College of Informatics*, *Huazhong Agricultural University*, *Wuhan* 430070, *China*)

Abstract: Aiming to achieve real-time and accurate detection of multi-scale rice pests in complex backgrounds, a dataset containing images of various rice pests was constructed and a pest detection model called YOLO v8－FDI was proposed. The model was based on the YOLO v8n architecture, utilizing the more efficient FasterNet as its backbone network. This design optimized the network structure while maintaining sensitivity to pest features. Dynamic Head technology was incorporated, allowing the model to dynamically adjust the detection heads in the output layer. This improved the model's accuracy and generalization for pests of different types and sizes. Furthermore, the Inner－IoU loss function was adopted to automatically adjust scaling factors during loss calculation process. This accelerated training convergence and further improved model performance. Experimental results showed that the YOLO v8－FDI model processed a single pest image in an average time of 12.43 m, achieving a processing speed of 80 frames per second (FPS), meeting real-time requirements for practical applications. On the test set, the model's detection precision, mean average precision mAP@0.5:0.95 and F1 score were 97.7%, 94.0%, and 97.2%, respectively. Compared with YOLO v3－tiny, YOLO v5n, YOLO v7－tiny, YOLO v8n, YOLO v9t, and YOLO v10n, precision was improved by 5.2, 2.7, 6.7, 3.4, 2.2, and 3.2 percentage points, mAP@0.5:0.95 was increased by 10.8, 5.4, 18.1, 2.3, 1.0, and 6.4 percentage points, and F1 score was raised by 2.6, 2.0, 4.9, 1.2, 1.3, and 2.9 percentage points. The novelty lied in the improvements made to the YOLO v8n architecture by integrating FasterNet, Dynamic Head, and the Inner－IoU loss function. These enhancements significantly improved the model's accuracy and generalization, offering strong technical support for real-time and accurate pest monitoring in complex backgrounds.

Key words: rice; pest detection; YOLO v8n; FasterNet; Dynamic Head

收稿日期：2024－11－11　修回日期：2024－12－16

基金项目： 国家重点研发计划项目（2023YFF1000101）和湖北省科技厅重点研发计划项目（2024BBB055）

作者简介： 刘善梅（1979—），女，副教授，博士，主要从事智能检测与控制研究，E-mail：lsmei@mail.hzau.edu.cn

通信作者： 彭辉（1979—），女，副教授，博士，主要从事计算机视觉研究，E-mail：moonbird@mail.hzau.edu.cn

0 引言

水稻作为我国粮食安全的基石,其生长过程不可避免地面临害虫侵袭。这些害虫不仅对水稻植株造成直接伤害,导致产量下降,还可能成为疾病传播的媒介,对水稻的整体健康构成威胁。因此,有效的害虫检测和控制对于保障水稻的稳定生产和提高作物质量具有重要意义[1-3]。目前,我国田间水稻害虫的控制方法通常依赖于大规模喷洒农药,这种做法不仅可能对水稻的生长造成负面影响,还可能对土壤生态环境和水质造成长期污染[4-5]。鉴于此,开发一种能够准确识别水稻害虫的智能化检测技术,实现害虫的精准防控,对于提高水稻产量和保障食品安全具有重要意义。

深度学习算法能够高效处理和分析庞大的农业数据集,为农业生产带来了革命性的变革[6]。近年来,深度学习技术在作物病虫害的智能识别和早期预警方面显示出巨大应用潜力[7-11]。李就好等[12]提出了一种基于改进 Faster R-CNN 的田间苦瓜叶部病害检测方法,在 4 种不同苦瓜叶部病害以及健康叶片的识别任务中,准确率达到 86.39%。LI 等[13]提出了一种改进的 Faster R-CNN 算法(TPest-RCNN)用于识别温室粘性陷阱图像中的微小害虫,对白粉虱和蓟马等微小害虫的识别准确率高达 95.2%。TANG 等[14]提出了一种结合深度图像挖掘和多特征融合的害虫检测方法 Pest-YOLO,在包含 28 000 幅图像和 24 个类别的大型害虫数据集上平均精度达到 71.6%。樊湘鹏等[15]提出了一种基于改进卷积神经网络的玉米病害识别方法,对复杂背景下的 9 种玉米病害平均识别精度为 97.10%,比未优化网络模型提高 9.02 个百分点。梁勇等[16]针对水稻稻纵卷叶螟和二化螟成虫的图像识别问题,引入 YOLO v5 算法对监测设备和诱捕器上的这 2 种害虫进行识别与计数,对这 2 种害虫识别准确率分别达到 91.67% 和 93.39%,召回率分别达到 98.30% 和 98.48%,F1 分数分别达到 94.87% 和 95.87%。王铭慧等[17]针对番茄病虫害目标小而密的特点提出了基于 Swin Transformer 的 YOLOX 目标检测网络,在番茄病虫害测试集上的检测精确率达到 86.3%。王卫星等[18]提出了一种荔枝病虫害检测模型 YOLO v4-GCF,其在含有 5 种病虫害目标的荔枝病虫害数据集的训练集、验证集和测试集上的平均精度分别达到 95.31%、90.42% 和 89.76%,从而证明了该模型在荔枝病虫害检测任务中的高效性和准确性。ZHANG 等[19]结合 DenseNet 密集连接卷积网络和自注意力机制提出了一种脐橙病虫害识别模型 DCPSNET,识别准确率为 96.90%。HU 等[20]提出了一种多尺度双分支结构的水稻害虫识别模型(GAN-MSDB-ResNet),在 4 种常见水稻病害识别任务中准确率高达 99.34%。

已有研究表明,深度学习技术在农作物病虫害检测中表现出显著效果。然而,在水稻害虫检测中,该技术仍面临复杂背景干扰、害虫尺度差异大、数据集样本种类代表性不足及样本量有限等挑战。为解决上述问题,本文构建一个包含 14 类水稻害虫图像的数据集 IP14-RICE,并基于 YOLO v8n[21]提出一种水稻害虫检测模型 YOLO v8-FDI。采用更高效的 FasterNet[22]作为主干网络,并引入 Dynamic Head[23]动态检测头和 Inner-IoU[24]损失函数,以期实现复杂背景下多尺度水稻害虫实时精准检测,为水稻害虫自动监测提供技术支撑。

1 材料与方法

1.1 水稻害虫数据集构建

为解决水稻害虫检测中深度学习技术面临的挑战,实现复杂背景下多尺度水稻害虫的实时精准检测目标,构建一个包含自然环境下非结构化复杂背景、害虫形态尺度多样、样本种类丰富、样本量充足、且高质量标注的数据集显得尤为重要。在公开的大型害虫数据集 IP102[25]的基础上,通过数据筛选、数据增强以及精细的数据标注操作,构建了满足上述要求的水稻害虫数据集 IP14-RICE。

1.1.1 水稻害虫数据筛选

从 IP102 数据集含有的约 19 000 幅用于目标检测任务的图像中筛选出所有与水稻虫害相关的 14 类害虫图像,共 1 248 个样本。所涵盖害虫类别和数量具体包括:亚洲稻螟 166 例、褐飞虱 111 例、稻潜叶蝇 25 例、稻瘿蚊 93 例、稻叶毛虫 114 例、稻叶禅 117 例、稻纵卷叶螟 174 例、稻苞虫 36 例、稻秆蝇 28 例、稻水象甲 153 例、白背飞虱 78 例、水稻三化螟 81 例、稻管蓟马 20 例以及灰飞虱 52 例。这些图像均采集于自然条件下,背景展现出非结构化的复杂特性。样本不仅涵盖 14 种不同类别水稻害虫,且即便是同一类别害虫,在其不同生长阶段亦呈显著的形态多样性。此外,这些害虫在尺寸上也存在明显差异,体现了样本多尺度特性。各类水稻害虫图像如图 1 所示。

然而,尽管这些样本具有非结构化复杂背景,害虫形态多样、尺度不一,以及样本种类丰富等特性,但它们的数量相对有限,难以满足水稻害虫深度学习检测模型对数据集规模的需求。另外,根据数据筛选结果,发现各类害虫数量存在显著差异,呈样本

图 1　水稻害虫图像

Fig. 1　Images of rice pests

不均衡问题。但进一步深入分析后，观察到数量较多的害虫类别通常包含了该害虫在不同生长阶段的多种形态，且不同形态间的特征差异较大。相比之下，数量较少的害虫类别则形态相对单一，样本间的特征差异较小。显然，由于水稻害虫数据集的以上特性，各类害虫数量的不均衡并不一定会导致模型对数量少的类别害虫的检测表现欠佳。因此，在数据集构建阶段，并未采用相关技术均衡各类害虫数量，而是采用数据增强技术解决数据集规模有限的问题。

1.1.2　数据增强与标注

为了在增加样本量的同时，进一步提升数据集样本多样性，实施了一系列数据增强策略，以对水稻害虫基础数据进行有效扩充。具体采取的数据增强策略主要包括：①实施水平和垂直翻转操作以及镜像对称操作，以模拟害虫在不同方向和视角下的观测情况。②采用仿射变换操作，包括旋转、缩放、倾斜等，以模拟害虫的多种朝向和视角变形。③通过向图像中添加随机噪声来模拟光照不足、传感器误差或复杂环境中的各种干扰因素。④调整图像的对比度，以模拟不同光照下的图像变化情况。⑤通过尺度变换和图像平移操作来模拟不同拍摄距离和捕获位置下的图像变化。通过上述数据增强操作，共生成 9 984 幅未标注的水稻害虫增强图像。随后，采用 LabelImg 标注软件对 9 984 幅增强图像进行了人工标注。同时对原有 1 248 幅已标注的基础图像数据的标注质量进行了细致检查，并对其中标注不精确图像重新做了更加精细的标注。最终，将经优化标注的 1 248 幅基础图像与通过数据增强及标注后获得的 9 984 幅图像合并，构建了一个包含 11 232 幅水稻害虫图像的数据集，作为后续研究基础，并将其命名为 IP14 - RICE。数据增强前后水稻害虫种类与数量如表 1 所示。

表 1　数据增强前后水稻害虫种类与数量

Tab. 1　Types and quantities of rice pests before and after data augmentation

害虫类别	增强前数量	增强后数量
亚洲稻螟	166	1 494
褐飞虱	111	999
稻潜叶蝇	25	225
稻瘿蚊	93	837
稻叶毛虫	114	1 026
稻叶禅	117	1 053
稻纵卷叶螟	174	1 566
稻苞虫	36	324
稻杆蝇	28	252
稻水象甲	153	1 377
白背飞虱	78	702
水稻三化螟	81	729
稻管蓟马	20	180
灰飞虱	52	468
总计	1 248	11 232

1.2　YOLO v8n

YOLO v8n 算法凭借其速度与精度的显著优势，已成为研究者的首选。其主干网络 Backbone 采用 CSPDarknet[21] 以实现特征提取，并通过采用梯度流更为丰富的 C2f 结构来提升模型的性能。在特征融合方面，YOLO v8n 继承了特征融合网络（Feature pyramid networks，FPN）和（Path aggregation network，PANet）的核心思想，通过自顶向下与自底向上的路径对特征进行增强。经过特征增强的 3 个特征图随后被送入检测头。在处理检测结果时，YOLO v8n 采用非极大值抑制策略来过滤重叠的检测框，并通过设置置信度阈值和 IoU 阈值来筛选出最终的检测结果。

YOLO v8n 在实际应用中表现出色,成为目标检测任务的理想选择。但在一些特定场景下的应用仍存在不足:①YOLO v8n 在处理复杂背景或小目标时的表现还有改进空间,尤其是在细粒度的目标检测任务中,易出现漏检或误检情况。②YOLO v8n 虽引入了无锚框检测方式,但在处理目标形状和尺度变化较大的场景时,仍存在一定局限。

1.3 水稻害虫检测模型 YOLO v8 - FDI 构建

针对复杂背景下多尺度水稻害虫实时检测任务需求,以 YOLO v8n 模型为基础,对其主干网络、网络检测头以及损失函数 3 个部分进行改进,构建水稻害虫检测模型 YOLO v8 - FDI。具体改进策略如下:①为满足水稻害虫检测实时性的需求,采用更高效的 FasterNet 作为主干网络,以在保持对害虫特征的敏感度的同时,优化网络结构,提高计算效率,进而提高网络的运行速度。②通过引入 Dynamic Head(Dyhead)技术,使得模型能够动态调整输出层的检测头,以更好地适应不同类型、不同尺寸害虫特征,进而提升模型的精度和泛化性能。③通过采用 Inner - IoU 损失函数,使得模型能够在损失计算过程中自动调节比例因子,从而在提升目标定位精度和加快模型训练收敛速度的同时,进一步提高模型的检测准确性。经以上改进措施得到的水稻害虫检测模型 YOLO v8 - FDI 结构如图 2 所示。

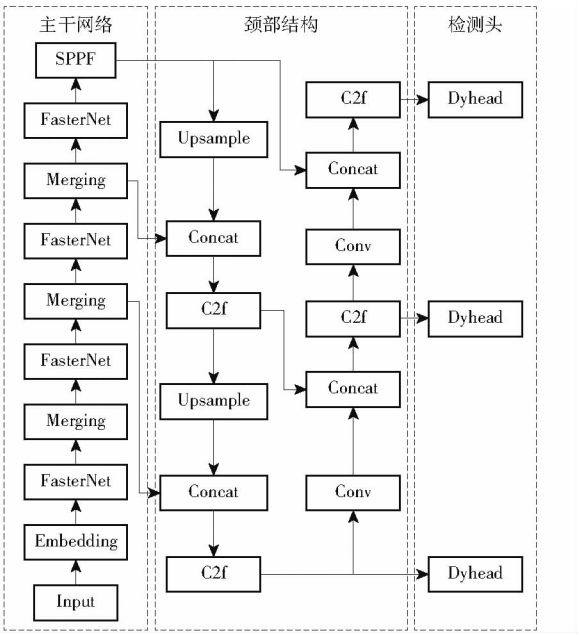

图 2 YOLOv8 - FDI 模型结构

Fig. 2 Structure of YOLOv8 - FDI detection model

1.3.1 YOLO v8 - FDI 模型主干网络

YOLO v8n 模型主干网络 CSPDarknet 虽在特征提取方面表现出色,但其卷积层数量较多、结构较为复杂,在一定程度上增加了模型的计算负担和运行时间。为弥补此不足,有研究借鉴了轻量化网络的设计方法,如 GhostNet[26]、MobileNet[27] 和 ShuffleNet[28]等,这些网络通过深度可分离卷积(Depthwise separable convolution, DSC)、幻影卷积(GhostConv)、群混洗卷积(Group shuffle convolution, GSConv)等技术,在一定程度上降低了模型复杂度。然而,这些卷积方法在实现特征提取的同时,也引入连接、混洗和池化等额外的数据处理操作,增加了模型运行时间。并且深度卷积操作的频繁内存访问也对检测模型的实时性产生了不利影响。

FasterNet[22]是一种在保持高准确性的同时追求更快运行速度的神经网络架构,其通过引入创新的部分卷积(Partial convolution, PConv)来优化计算过程,且其架构设计简单,没有复杂的附加结构,可弥补 YOLO v8n 模型主干网络的不足。因此,采用 FasterNet 作为 YOLO v8 - FDI 模型的主干网络,其整体架构如图 2 的主干网络部分所示,包含 4 个层次化阶段,每个阶段都有 1 个 FasterNet 块的堆叠,并且在每个阶段之前都有 1 个嵌入(Embedding)或合并(Merging)层。嵌入层通过 4 × 4 卷积操作实现高效的空间下采样;融合层通过 2 × 2 卷积操作扩展通道数,为后续深度特征的捕捉提供坚实基础;FasterNet 块引入了部分卷积 PConv,这种卷积操作只对输入的部分通道进行卷积处理,从而减少计算量和内存使用,同时保持模型的高效性。显然,FasterNet 块是主干网络的关键组件,其由 1 个部分卷积(PConv)和 2 个逐点卷积(Point-wise convolution, PWConv)组成,如图 3 所示。

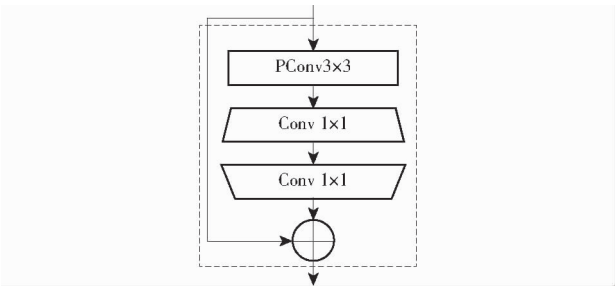

图 3 FasterNet 模块

Fig. 3 FasterNet block

由图 3 可知,部分卷积 PConv 仅对一部分通道进行常规卷积处理,而对其他通道则不进行卷积操作。通常情况下,PConv 会选取特征图中前段或后段连续的 P 个通道进行卷积操作,如图 4 所示。

部分卷积 PConv 通过减少不必要的卷积操作,显著降低了模型的计算量和内存访问频率,同时压缩了模型参数量,提升了模型的实时性。

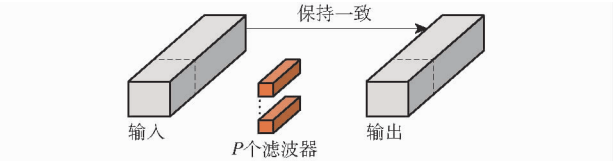

图 4　部分卷积

Fig. 4　Partial convolution(PConv)

1.3.2　YOLO v8－FDI 模型网络检测头

Dynamic Head 是一种新颖的动态检测头方法，其核心思想是通过引入多种注意力机制来统一并增强目标检测头部的功能，进而提升模型目标检测的精度和泛化能力。将 Dynamic Head 引入 YOLO v8－FDI 模型，以优化模型检测头的性能，从而提高模型对复杂背景下多尺度水稻害虫目标的检测能力。具体而言，如图 5 所示，Dynamic Head 通过在特征金字塔的不同层级、空间位置和输出通道上分别部署尺度感知注意力、空间感知注意力和任务感知注意力 3 种类型的注意力模块，以实现尺度感知、空间感知和任务感知。其中，尺度感知注意力模块部署在特征级别维度上，学习不同语义级别的相对重要性，以增强个体目标的特征，这些目标的特征基于其尺度在适当的级别上进行增强；空间感知注意力模块部署在空间（即高度×宽度）维度上，学习在空间位置上的一致性区分性表示，帮助模型更好地识别目标在不同形状、旋转和位置下的特征；任务感知注意力模块部署在通道维度上，指导不同的特征通道分别支持不同的任务。

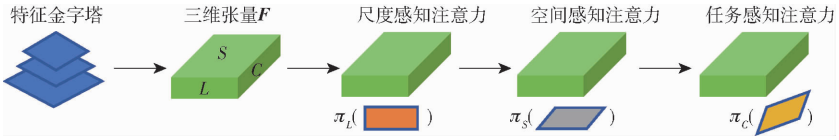

图 5　Dynamic Head 方法

Fig. 5　Dynamic head method

在图 5 中，特征金字塔为图 2 所示的 YOLO v8－FDI 检测模型颈部结构输出的不同层级的特征，其在被输入 Dynamic Head 前需通过上采样或下采样统一尺度，调整后得到一个三维张量 $\boldsymbol{F} \in \boldsymbol{R}^{L\times S\times C}$。其中，$L$、$S$、$C$ 分别表示尺度感知、空间感知和任务感知 3 个维度。具体而言，L 表示不同尺度的特征层数；S 表示特征图高度和宽度相乘得到的一个维度，用于在张量中表示特征图的空间位置信息；C 表示通道数，即每个空间位置的特征向量所包含的通道数量。

Dynamic Head 主要通过尺度感知注意力、空间感知注意力和任务感知注意力来实现其核心功能。如图 5 所示，π_L、π_S、π_C分别为应用于张量 $\boldsymbol{F}$ 的 L、S 和 C 3 个不同维度上的注意力函数。Dynamic Head 的优势在于将尺度、空间、任务感知 3 种注意力机制统一在一个框架中，形成了一个综合的注意力学习问题。尽管这些注意力机制分别作用于不同的特征维度，但其性能可相互补充，共同提升目标检测头部的表示能力，且无需增加额外的计算开销。

给定特征张量 $\boldsymbol{F} \in \boldsymbol{R}^{L\times S\times C}$，应用自注意力一般公式为

$$W(\boldsymbol{F}) = \pi(\boldsymbol{F})\boldsymbol{F} \tag{1}$$

式中　π——注意力函数

Dynamic Head 应用注意力公式为

$$W(\boldsymbol{F}) = \pi_C(\pi_S(\pi_L(\boldsymbol{F})\boldsymbol{F})\boldsymbol{F})\boldsymbol{F} \tag{2}$$

其中

$$\pi_L(\boldsymbol{F})\boldsymbol{F} = \sigma\left(f\left(\frac{1}{SC}\sum_{S,C}\boldsymbol{F}\right)\right)\boldsymbol{F} \tag{3}$$

$$\pi_S(\boldsymbol{F})\boldsymbol{F} = \frac{1}{L}\sum_{l=1}^{L}\sum_{k=1}^{K} W_{l,k}\boldsymbol{F}(l;p_k+\Delta p_k;c)\Delta m_k \tag{4}$$

$$\pi_C(\boldsymbol{F})\boldsymbol{F} = \max(\alpha^{(1)}(\boldsymbol{F})\boldsymbol{F}_C + \beta^{(1)}(\boldsymbol{F}),\ \alpha^{(2)}(\boldsymbol{F})\boldsymbol{F}_C + \beta^{(2)}(\boldsymbol{F})) \tag{5}$$

$$\sigma(x) = \max\left(0, \min\left(1, \frac{x+1}{2}\right)\right) \tag{6}$$

式中　$f(\cdot)$——由 1×1 卷积层近似的线性函数

K——稀疏采样位置个数

$p_k+\Delta p_k$——自学习空间偏移量

Δm_k——自学习位置 p_k 处重要标量

$\boldsymbol{F}_C$——第 c 通道特征

$\alpha^{(1)}$、$\alpha^{(2)}$、$\beta^{(1)}$、$\beta^{(2)}$——超参数

1.3.3　YOLO v8－FDI 模型损失函数

YOLO v8n 边界框回归使用完整的交叉联合 CIoU（Complete intersection over union）作为损失函数。CIoU 是对传统 IoU（Intersection over union）的改进，其不仅考虑了边界框的重叠区域，还考虑了边界框中心点之间距离和它们的宽高比相似度，从而提供了更全面的相似度度量。然而，CIoU 仍使用固定的尺度来计算损失，且没有区分不同 IoU 值的样本，这导致其在不同检测任务中缺乏足够的泛化能力。为弥补 CIoU 的不足，在 YOLO v8－FDI 模型中引入 Inner－IoU 损失函数[24]。Inner－IoU 通过引入辅助边界框和比例因子来动态调整损失计算，不仅能够适应不同的检测任务和数据集，提高模型的泛化能力，且能够更有效地处理高 IoU 和低 IoU 样本，

加速模型的收敛。Inner－IoU 损失函数具有更高的灵活性和适应性，其在目标检测任务中，尤其是在复杂场景下多尺度目标检测，能够实现更准确的检测结果。

1.4 模型训练和测试环境

模型训练和测试均在同一环境下运行，所使用硬件设备包括 Intel i9－12900k 处理器，NVIDIA GeForce RTX3090 显卡，软件环境为 Ubuntu 20.04 操作系统、Python 3.8、CUDA 11.8，深度学习框架为 Pytorch 1.13.1。

1.5 评价指标

采用精确率（Precision）、召回率（Recall）、平均精度均值（Mean average precision，mAP）、F1 分数、单幅图像平均推理时间对模型性能进行全面评价。其中，mAP 采用 mAP@0.5 和 mAP@0.5:0.95。mAP@0.5 表示当 IoU 阈值为 0.5 时的平均精度均值，mAP@0.5:0.95 表示从 0.5 到 0.95 之间以步长为 0.05 取多个 IoU 阈值分别计算对应的平均精度后得到的均值。

2 实验与结果

2.1 对比实验

2.1.1 IP14－RICE 数据集

为验证所提 YOLO v8－FDI 模型的性能，在 IP14－RICE 水稻害虫数据集上，将其与其他主流目标检测模型（YOLO v3－tiny、YOLO v5n、YOLO v7－tiny、YOLO v8n、YOLO v9t 和 YOLO v10n）进行对比，结果如表 2 和图 6 所示。

表 2 不同模型在 IP14－RICE 数据集上的结果

Tab.2 Results of different models on IP14－RICE dataset

%

模型	精确率	召回率	mAP@0.5	mAP@0.5:0.95	F1 分数
YOLO v3－tiny	92.5	96.7	97.3	83.2	94.6
YOLO v5n	95.0	95.5	98.5	88.6	95.2
YOLO v7－tiny	91.0	93.8	96.1	75.9	92.3
YOLO v8n	94.3	97.7	98.7	91.7	96.0
YOLO v9t	95.5	96.4	98.7	93.0	95.9
YOLO v10n	94.5	94.1	97.8	87.6	94.3
YOLO v8－FDI	97.7	96.7	99.0	94.0	97.2

由表 2 可知，在 IP14－RICE 数据集上，改进 YOLO v8－FDI 模型精确率、召回率、mAP@0.5、mAP@0.5:0.95 和 F1 分数分别为 97.7%、96.7%、99.0%、94.0% 和 97.2%。除召回率稍逊于 YOLO v8n（97.7%）、持平于 YOLO v3－tiny（96.7%）外，其他指标均优于其他模型。具体而言，其精确率、mAP@0.5、mAP@0.5:0.95 和 F1 分数比 YOLO v8n 的 94.3%、98.7%、91.7%、96.0% 分别提升 3.4、3、2.3、1.2 个百分点；比 YOLO v3－tiny 的 92.5%、97.3%、83.2%、94.6% 分别提升 5.2、1.7、10.8、2.6 个百分点。其精确率、召回率、mAP@0.5、mAP@0.5:0.95 和 F1 分数比 YOLO v7－tiny 的 91.0%、93.8%、96.1%、75.9%、92.3% 分别提升 6.7、2.9、2.9、18.1、4.9 个百分点；比 YOLO v5n 的 95.0%、95.5%、98.5%、88.6%、95.2% 分别提升 2.7、1.2、5、5.4、2.0 个百分点；比 YOLO v9t 的 95.5%、96.4%、98.7%、93.0%、95.9% 分别提升 2.2、3、3、1.0、1.3 个百分点；比 YOLO v10n 的 94.5%、94.1%、97.8%、87.6%、94.3% 分别提升 3.2、2.6、1.2、6.4、2.9 个百分点。以上结果表明，YOLO v8－FDI 模型精确率、mAP@0.5、mAP@0.5:0.95 和 F1 分数表现更优，模型整体性能优于其他对比模型。

由图 6 可以看出，在检测复杂背景下不同类别水稻害虫时，YOLO v8－FDI 模型对各种害虫的检测置信度均高于其他对比模型，展现出了极高的准确度和稳定性。在对图 6 第 11 行和第 12 行所示的稻秆蝇和稻水象甲害虫检测时，其置信度分别为 0.93 和 0.92，远高于其他模型。YOLO v8－FDI 模型在对多尺度水稻害虫检测时，优势更加明显。比如，在对图 6 第 3 行所示的 3 种不同尺度褐飞虱检测时，YOLO v9t 以 0.46 置信度将其中最大尺度的褐飞虱误检为稻叶禅，而其他对比模型对其中 2 个较小尺度的褐飞虱均存在不同程度漏检问题。相比之下，YOLO v8－FDI 模型不仅完全避免了漏检或误检现象，而且对这 3 种不同尺度的褐飞虱检测置信度分别达到 0.94、0.86 和 0.83，远高于其他模型结果，充分展示了该模型的优异性能。

2.1.2 IP102 数据集

为验证模型的泛化性，在 IP102 大型作物害虫数据集上，进行对比实验。IP102 数据集包含 18 975 幅标注了目标边界框的图像，涵盖了水稻、玉米、小麦、甜菜等 8 类农作物的主要害虫，每类农作物的主要害虫细分为多个二级类别，共包含 102 类害虫。结果如表 3 所示。

由于 IP102 数据集中的类别众多且分布极不均匀（其中最多的一类有 2 347 幅图像，最少的仅有 2 幅图像），因此所有模型在这一数据集上的性能均有所下降。从表 3 可以看出，YOLO v8－FDI 模型精确率和 F1 分数最优，分别达到 58.1% 和 55.8%，这表明该模型在预测正样本时的准确性最高，且其在精确率和召回率之间达到了良好的平衡；召回率方

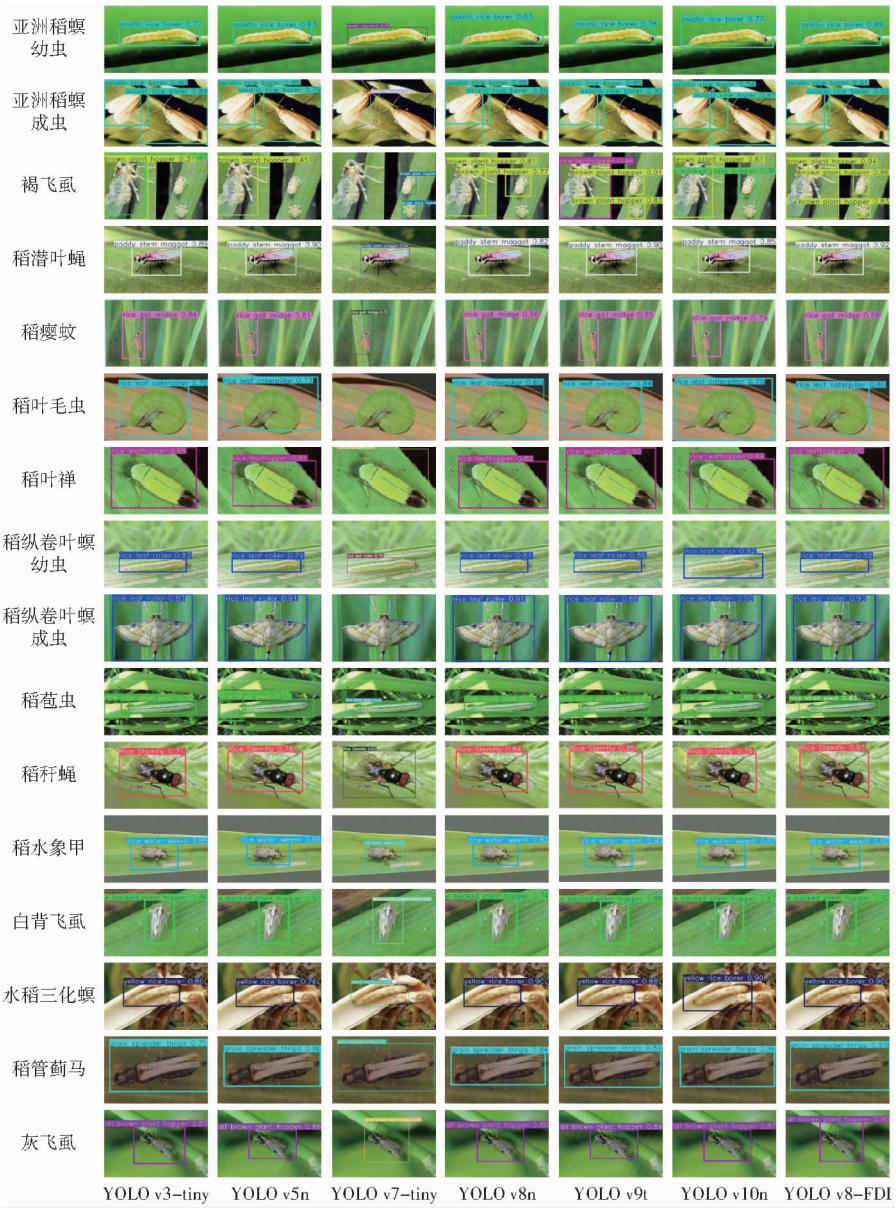

图 6　不同模型在 IP14－RICE 数据集上的检测结果

Fig. 6　Detection results of different models on IP14－RICE dataset

表 3　不同模型在 IP102 数据集上的结果

Tab. 3　Results of different models on IP102 dataset

%

模型	精确率	召回率	mAP@0.5	mAP@0.5:0.95	F1 分数
YOLO v3－tiny	53.5	54.3	54.2	31.7	53.8
YOLO v5n	56.3	54.3	57.1	36.6	55.3
YOLO v7－tiny	55.5	53.0	54.3	32.1	54.2
YOLO v8n	57.3	53.7	56.6	32.2	55.4
YOLO v9t	53.5	51.7	52.0	33.2	52.6
YOLO v10n	53.4	56.2	56.3	36.4	54.7
YOLO v8－FDI	58.1	53.6	55.8	35.3	55.8

面，YOLO v10n 表现最佳，为 56.2%，显示了其在减少漏检目标方面的优势；在 mAP@0.5 和 mAP@0.5:0.95 上，YOLO v5n 取得最佳值（57.1% 和 36.6%），显示出其在检测准确性和稳定性上的优越性。综合来看各模型在 IP102 数据集上的表现，虽 YOLO v8－FDI 并未非所有指标均表现最优，但其在综合表现上依然具有竞争力，尤其是在精确率和 F1 分数上的突出表现证明了该模型在水稻害虫检测任务中的能力。此外，与 YOLO v8n 相比，YOLO v8－FDI mAP@0.5:0.95 的提升也表明了其在执行不同尺度和复杂背景下目标检测任务中的能力有所提高。总体而言，在 IP102 数据集上，尽管 YOLO v8－FDI 在某些方面仍有优化空间，但其模型精确率和 F1 分数均优于其他模型，依然展现出了良好的泛化能力和应用潜力。

2.2　消融实验

在相同实验平台和相同参数设置下，在水稻害虫数据集 IP14－RICE 上进行了消融实验，以验证所提 YOLO v8－FDI 模型中各改进模块（FasterNet 主

干网络、Dynamic Head 动态检测头、Inner－IoU 损失函数)的有效性和先进性。消融实验结果如表 4 所示。

表 4 IP14－RICE 数据集消融实验结果

Tab. 4 Results of ablation experiments on IP14－RICE dataset %

模型	精确率	召回率	mAP@0.5	mAP@0.5:0.95	F1 分数
YOLO v8n	94.3	97.7	98.7	91.7	95.9
YOLO v8n + FasterNet	97.5	95.5	98.7	91.3	96.0
YOLO v8n + Dynamic Head	95.1	97.0	98.3	92.7	96.0
YOLO v8n + FasterNet + Dynamic Head	97.5	95.8	98.8	93.2	96.2
YOLO v8－FDI	97.7	96.7	99.0	94.0	97.2

从表 4 可以看出,在 IP14－RICE 数据集上,YOLO v8n 的检测精确率、召回率、mAP@0.5、mAP@0.5:0.95 和F1 分数分别为 94.3%、97.7%、98.7%、91.7%和 95.9%。将 YOLO v8n 的主干网络 CSPDarknet 替换为 FasterNet 后的模型(YOLO v8n + FasterNet)精确率、召回率、mAP@0.5、mAP@0.5:0.95 和F1 分数分别为 97.5%、95.5%、98.7%、91.3%和 96.0%,精确率较 YOLO v8n 提升 3.2 个百分点,证明了 FasterNet 主干网络的积极作用。将 YOLO v8n 的检测头替换为 Dynamic Head 后的模型(YOLO v8n + Dynamic Head)精确率、召回率、mAP@0.5、mAP@0.5:0.95 和 F1 分数分别为 95.1%、97.0%、98.3%、92.7%和 96.0%,精确率和 mAP@0.5:0.95 分别比 YOLO v8n 模型提高 0.8、1.0 个百分点,证明了 Dynamic Head 动态检测头的积极作用。同时改进主干网络和检测头后的模型(YOLO v8n + FasterNet + Dynamic Head)精确率、召回率、mAP@0.5、mAP@0.5:0.95 和 F1 分数分别为 97.5%、95.8%、98.8%、93.2%和 96.2%,相比 YOLO v8n + FasterNet 和 YOLO v8n + Dynamic Head 模型,mAP@0.5、mAP@0.5:0.95 和 F1 分数均有所提升,证明了这 2 个模块协同作用的有效性。在此基础上,进一步引入 Inner－IoU 损失函数后,YOLO v8－FDI 模型的精确率、召回率、mAP@0.5、mAP@0.5:0.95 和 F1 分数分别为 97.7%、96.7%、99.0%、94.0% 和 97.2%,相比 YOLO v8n + FasterNet + Dynamic Head 模型,所有指标均进一步提升,证明了 Inner－IoU 损失函数的有效性,也证明了这 3 个模块协同作用的有效性。

通过以上结果可以看出,主干网络 FasterNet、Dynamic Head 动态检测头和 Inner－IoU 损失函数 3 个模块均在提升模型性能方面发挥了积极作用,特别是在组合使用时,能够显著增强模型综合性能,使得 YOLO v8－FDI 模型的精确率、mAP@0.5、mAP@0.5:0.95 和F1 分数均高于其他模型,从而证明了这些改进措施对于提升水稻害虫目标检测任务的积极影响。

2.3 实时性评价

在实际应用中,实时性是目标检测模型的关键指标之一。在实验中测得,YOLO v8－FDI 模型对单幅水稻害虫图像的平均推理时间为 12.43 ms。换言之,YOLO v8－FDI 模型具备每秒处理超过 80 帧图像的能力。这一结果表明,该模型能够以足够快的速度处理输入图像数据,满足实际应用场景中的实时性要求。

3 结论

(1)提出了一种基于改进 YOLO v8n 算法的水稻害虫检测模型 YOLO v8－FDI。该模型通过采用更高效的 FasterNet 作为主干网络,在保持高效捕捉害虫特征的同时,优化了网络结构;通过引入 Dynamic Head 技术动态调整网络输出层的检测头,使得模型能够适应非结构化复杂背景下不同类别、不同形状、不同尺寸的水稻害虫特征,进而提升了其精度和泛化能力;通过引入 Inner－IoU 损失函数,使得模型在损失计算过程中能够自动调节比例因子,从而加快了训练收敛速度,且进一步提高了性能。

(2)构建了一个用于水稻害虫检测的数据集 IP14－RICE,该数据集共包含 14 类 11 232 幅自然环境下非结构化复杂背景、不同形态、不同尺寸的水稻害虫图像。所构建的 YOLO v8－FDI 模型在 IP14－RICE 测试集上的精确率、mAP@0.5:0.95 和 F1 分数分别为 97.7%、94.0%和 97.2%,相较于对比模型,精确率分别提升 5.2、2.7、6.7、3.4、2.2、3.2 个百分点;mAP@0.5:0.95 分别提升 10.8、5.4、18.1、2.3、1.0、6.4 个百分点;F1 分数分别提升 2.6、2.0、4.9、1.2、1.3、2.9 个百分点;检测单幅图像平均用时为 12.43 ms。由此可得,YOLO v8－FDI 模型能够实现复杂背景下的多尺度水稻害虫实时精准检测,可为农业害虫实时监测提供技术支撑。

参考文献

[1] 吕亮,常向前,张舒,等. 水稻害虫绿色防控技术应用研究现状及展望[J]. 环境昆虫学报,2021, 43(3): 623－632.

LÜ Liang, CHANG Xiangqian, ZHANG Shu, et al. Current situation and prospect of application of green control techniques for rice insect pests[J]. Journal of Environmental Entomology, 2021, 43(3): 623 – 632. (in Chinese)

[2] 李有志,方继朝. 水稻害虫:研究进展与展望[J]. 昆虫学报,2024, 67(4): 443 – 455.
LI Youzhi, FANG Jichao. Rice pests: research progresses and prospects[J]. Acta Entomologica Sinica, 2024, 67(4): 443 – 455. (in Chinese)

[3] 徐红星,郑许松,田俊策,等. 我国水稻害虫绿色防控技术的研究进展与应用现状[J]. 植物保护学报, 2017, 44(6): 925 – 939.
XU Hongxing, ZHENG Xusong, TIAN Junce, et al. Advances in the development and application of control technologies for insect pest management in paddy fields in China[J]. Journal of Plant Protection, 2017, 44(6): 925 – 939. (in Chinese)

[4] 梁玉刚,李静怡,周晶,等. 中国水稻栽培技术的演变与展望[J]. 作物研究,2022, 36(2): 180 – 188.
LIANG Yugang, LI Jingyi, ZHOU Jing, et al. Evolution and prospect of rice cultivation technology in China[J]. Crop Research, 2022, 36(2): 180 – 188. (in Chinese)

[5] 曾文伟,罗华,石小江,等. 我国常规稻发展现状与优势分析[J]. 作物研究,2023,37(2):167 – 169.
ZENG Wenwei, LUO Hua, SHI Xiaojiang, et al. Analysis of the development status and advantages of conventional rice in China[J]. Crop Research, 2023, 37(2):167 – 169. (in Chinese)

[6] 贾少鹏,高红菊,杭潇. 基于深度学习的农作物病虫害图像识别技术研究进展[J]. 农业机械学报,2019,50(增刊):313 – 317.
JIA Shaopeng, GAO Hongju, HANG Xiao. Research progress on image recognition technology of crop pests and diseases based on deep learning[J]. Transactions of the Chinese Society for Agricultural Machinery, 2019, 50(Supp.): 313 – 317. (in Chinese)

[7] YU X, ZHENG J. A review on the application of deep learning methods in detection and identification of rice diseases and pests[J]. Computers, Materials & Continua, 2024, 78(1):197 – 225.

[8] CHITHAMBARATHANU M, JEYAKUMAR M K. Survey on crop pest detection using deep learning and machine learning approaches[J]. Multimedia Tools and Applications, 2023, 82(27): 42277 – 42310.

[9] 翟肇裕,曹益飞,徐焕良,等. 农作物病虫害识别关键技术研究综述[J]. 农业机械学报,2021,52(7):1 – 18.
ZHAI Zhaoyu, CAO Yifei, XU Huanliang, et al. Review of key techniques for crop disease and pest detection[J]. Transactions of the Chinese Society for Agricultural Machinery, 2021,52(7):1 – 18. (in Chinese)

[10] DENG J, YANG C, HUANG K, et al. Deep-learning-based rice disease and insect pest detection on a mobile phone[J]. Agronomy, 2023, 13(8): 2139.

[11] 陈科圻,朱志亮,邓小明,等. 多尺度目标检测的深度学习研究综述[J]. 软件学报,2021,32(4):1201 – 1227.
CHEN Keqi, ZHU Zhiliang, DENG Xiaoming, et al. Deep learning for multi-scale object detection: a survey[J]. Journal of Software, 2021,32(4):1201 – 1227. (in Chinese)

[12] 李就好,林乐坚,田凯,等. 改进 Faster R – CNN 的田间苦瓜叶部病害检测[J]. 农业工程学报, 2020,36(12):179 – 185.
LI Jiuhao, LIN Lejian, TIAN Kai, et al. Detection of leaf diseases of balsam pear in the field based on improved Faster R – CNN[J]. Transactions of the CSAE, 2020, 36(12): 179 – 185. (in Chinese)

[13] LI W, WANG D, LI M, et al. Field detection of tiny pests from sticky trap images using deep learning in agricultural greenhouse[J]. Computers and Electronics in Agriculture, 2021, 183: 106048.

[14] TANG Z, CHEN Z, QI F, et al. Pest – YOLO: deep image mining and multi-feature fusion for real-time agriculture pest detection[C]//2021 IEEE International Conference on Data Mining (ICDM). IEEE, 2021: 1348 – 1353.

[15] 樊湘鹏,周建平,许燕,等. 基于改进卷积神经网络的复杂背景下玉米病害识别[J]. 农业机械学报,2021,52(3):210 – 217.
FAN Xiangpeng, ZHOU Jianping, XU Yan, et al. Corn disease recognition under complicated background based on improved convolutional neural network[J]. Transactions of the Chinese Society for Agricultural Machinery, 2021,52(3):210 – 217. (in Chinese)

[16] 梁勇,邱荣洲,李志鹏,等. 基于 YOLO v5 和多源数据集的水稻主要害虫识别方法[J]. 农业机械学报,2022,53(7): 250 – 258.
LIANG Yong, QIU Rongzhou, LI Zhipeng, et al. Recognition method of major rice pests based on YOLO v5 and multi-source datasets[J]. Transactions of the Chinese Society for Agricultural Machinery, 2022, 53(7):250 – 258. (in Chinese)

[17] 王铭慧,张怀清,樊江川,等. 基于深度学习网络实现番茄病虫害检测与识别[J]. 中国农业大学学报,2023,28(11): 165 – 181.
WANG Minghui, ZHANG Huaiqing, FAN Jiangchuan, et al. Detection and identification of tomato diseases and pests based on deep learning networks[J]. Journal of China Agricultural University, 2023, 28(11): 165 – 181. (in Chinese)

[18] 王卫星,刘泽乾,高鹏,等. 基于改进 YOLO v4 的荔枝病虫害检测模型[J]. 农业机械学报, 2023,54(5):227 – 235.
WANG Weixing, LIU Zeqian, GAO Peng, et al. Detection of litchi diseases and insect pests based on improved YOLO v4 model[J]. Transactions of the Chinese Society for Agricultural Machinery,2023,54(5):227 – 235. (in Chinese)

[19] ZHANG X, BU J, ZHOU X, et al. Automatic pest identification system in the greenhouse based on deep learning and machine vision[J]. Frontiers in Plant Science, 2023, 14: 1255719.

[20] HU K, LIU Y M, NIE J, et al. Rice pest identification based on multi-scale double-branch GAN – ResNet[J]. Frontiers in

Plant Science, 2023, 14: 1167121.

[21] VARGHESE R, SAMBATH M. YOLO v8: a novel object detection algorithm with enhanced performance and robustness[C]// 2024 International Conference on Advances in Data Engineering and Intelligent Computing Systems (ADICS). IEEE, 2024: 1 – 6.

[22] CHEN J, KAO S, HE H, et al. Run, don't walk: chasing higher FLOPS for faster neural networks[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023: 12021 – 12031.

[23] DAI X, CHEN Y, XIAO B, et al. Dynamic Head: unifying object detection heads with attentions[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021: 7373 – 7382.

[24] ZHANG H, XU C, ZHANG S. Inner-IOU: more effective intersection over union loss with auxiliary bounding box[J]. arXiv Preprint, arXiv:2311.02877, 2023.

[25] WU X, ZHAN C, LAI Y K, et al. Ip102: a large-scale benchmark dataset for insect pest recognition[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019: 8787 – 8796.

[26] HAN K, WANG Y, TIAN Q, et al. Ghostnet: more features from cheap operations[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020: 1580 – 1589.

[27] HOWARD A, SANDLER M, CHU G, et al. Searching for Mobilenetv3[C]// Proceedings of the IEEE/CVF International Conference on Computer Vision, 2019: 1314 – 1324.

[28] ZHANG X, ZHOU X, LIN M, et al. Shufflenet: an extremely efficient convolutional neural network for mobile devices[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 6848 – 6856.

(上接第 295 页)

[24] 张雨迪. 内蒙古河套灌区义长灌域不同土地利用类型土壤温室气体排放特征及驱动机制[D]. 呼和浩特:内蒙古科技大学,2025.
ZHANG Yudi. Characteristics and driving mechanisms of soil greenhouse gas emissions under different land use tyeps in the Yichang Irrigation Area of Hetao Irrigation District, Inner Monglia[D]. Hohhot: Inner Monglia University of Science & Technology, 2025. (in Chinese)

[25] 张梦飞. 基于机地协同的夏玉米农田土壤碳排放估算方法研究[D]. 杨凌:西北农林科技大学, 2021.
ZHANG Mengfei. Estimation of soil carbon emission from summer maize field based on ground measurement and UAV remote sensing[D]. Yangling: Northwest A&F University, 2021. (in Chinese)

[26] MYNENI R B, WILLIAMS D L. On the relationship between FAPAR and NDVI[J]. Remote Sensing of Environment, 1994, 49(3): 200 – 211.

[27] JIANG Nan, YANG Zaiqiang, ZHANG Hanqi, et al. Monitoring and risk prediction of low-temperature stress in strawberries through fusion of multisource phenotypic spatial variability features[J]. Plant Phenomics, 2025, 7(2): 100041.

[28] GAO Si, ZHONG Run, YAN Kai, et al. Evaluating the saturation effect of vegetation indices in forests using 3D radiative transfer simulations and satellite observations[J]. Remote Sensing of Environment, 2023, 295: 113665.

[29] VERRELST J, SCHAEPMAN M E, KOETZ B, et al. Angular sensitivity analysis of vegetation indices derived from CHRIS/PROBA data[J]. Remote Sensing of Environment, 2008, 112(5): 2341 – 2353.

[30] SCHUERGER A C, CAPELLE G A, DI BENEDETTO J A, et al. Comparison of two hyperspectral imaging and two laser-induced fluorescence instruments for the detection of zinc stress and chlorophyll concentration in bahia grass (*Paspalum notatum* Flugge.)[J]. Remote Sensing of Environment, 2003, 84(4): 572 – 588.

[31] PEÑUELAS J, GAMON J A, FREDEEN A L, et al. Reflectance indices associated with physiological changes in nitrogen- and water-limited sunflower leaves[J]. Remote Sensing of Environment, 1994, 48(2): 135 – 146.

[32] COMPTON J T. Red and photographic infrared linear combinations for monitoring vegetation[J]. Remote Sensing of Environment, 1979, 8(2): 127 – 150.

[33] SIMS D A, GAMON J A. Relationships between leaf pigment content and spectral reflectance across a wide range of species, leaf structures and developmental stages[J]. Remote Sensing of Environment, 2002, 81(2): 337 – 354.

[34] PENG Manman, HAN Wenting, LI Chaoqun, et al. Diurnal and seasonal CO_2 exchange and yield of maize cropland under different irrigation treatments in semiarid Inner Mongolia[J]. Agricultural Water Management, 2021, 255: 107041.

[35] KELLY J, KLJUN N, EKLUNDH L, et al. Modelling and upscaling ecosystem respiration using thermal cameras and UAVs: application to a peatland during and after a hot drought[J]. Agricultural and Forest Meteorology, 2021, 300: 108330.

[36] ZHANG L, NIU Y, ZHANG H, et al. Maize canopy temperature extracted from UAV thermal and RGB imagery and its application in water stress monitoring[J]. Front Plant Sci., 2019, 10: 1270.