中图分类号： TP391　　论文编号：

学科分类号： 520　　密　　级： 公　开

安徽理工大學

硕 士 学 位 论 文

基于改进 YOLO 的绝缘子缺陷检测算法研究

作者姓名： 刘云

专业名称： 计算机科学与技术

研究方向： 图形图像处理

导师姓名： 于瓅 教授

导师单位： 计算机科学与工程学院

答辩委员会主席： 汪军

论文答辩日期： 2025 年 12 月 5 日

安徽理工大学研究生院

年　月　日

中国知网 https://www.cnki.net

A Dissertation in Computer Science and Technology

Research on Insulator Defect Detection Algorithm Based on Improved YOLO

Candidate: Liu Yun

Supervisor: Yu Li

School of Computer Science and Engineering

Anhui University of Science and Technology

No. 168, Taifeng Street, Huainan, 232001, Anhui, P. R. China

中国知网 https://www.cnki.net

摘 要

近年来，无人机技术发展迅速，已广泛应用于输电线路绝缘子检测。然而航拍图像背景复杂，缺陷位置密集且容易隐藏，这些因素都给绝缘子缺陷检测带来了很大困难。还有检测模型参数量大，难以部署到内存受限的无人机等设备，这进一步增加了绝缘子缺陷检测的难题。针对这些问题，本文提出了基于 YOLOv8n 算法改进的绝缘子缺陷检测算法，旨在提高模型的检测性能及实现模型的轻量化。主要工作包括：

（1）针对模型检测精度低且漏检误检较多问题，本文提出了一种基于改进 YOLOv8 的绝缘子缺陷算法 CSSD_YOLOv8。改进算法首先使用 SAConv 代替 Conv，设计了全新的 SA_C2f 模块并代替部分 C2f，以提高模型对多尺度目标的特征提取能力；为丰富多尺度特征表达，设计了 SPPF_LSKA 模块；还设计了 DWR_Detect 检测头来替换原 Detect 结构，以降低小目标的漏检率；在此期间为增强小目标的检测效果，添加了小目标检测层来增强深层语义信息及浅层语义信息的结合。实验结果表明，改进后的算法相较于原算法平均检测精度提高 3.1%，还改善了原算法漏检、误检情况，证明了改进算法的有效性。

（2）针对模型参数量及计算量大，不利于部署问题，本文提出了一种基于轻量化结构与知识蒸馏相结合的绝缘子缺陷检测算法。改进算法以 YOLOv8n 为基础网络，并对其模型结构进行轻量化设计，首先将 WTConv 模块与 C2f 集成，构建了 C2f_WTConv 模块来捕获图像中的多尺度特征；继而设计了一种动态采样的特征融合颈部结构 DEHSFPN，它通过引入 ELA 注意力改进 HSFPN 网络结构，得到高效特征融合网络 EHSFPN，在此期间采用 Dysample 上采样算子进行动态采样来提高特征融合效率及模型性能；最后采用 MGD 知识蒸馏技术，在保持参数量不变的前提下提升模型检测精度。实验结果表明，改进后的算法 mAP 值在保持 91%的前提下，参数量减少了 24.1%，GFLOPs 降低了 30.9%，模型体积缩小了 22%，达到了轻量化模型的目的，更适合部署到内存受限的无人机设备。

图 [29] 表 [6] 参 [71]

关键词：绝缘子缺陷检测；Yolov8；特征融合；知识蒸馏

分类号：TP391

中国知网 https://www.cnki.net

Abstract

In recent years, UAV technology has been developing rapidly and has been widely used in transmission line insulator detection. However, aerial images often have complex backgrounds, dense defect locations, and easily concealed flaws, all of which pose significant challenges for insulator defect detection. Additionally, detection models typically have a large number of parameters, making them difficult to deploy on devices with limited memory, such as drones, which further complicates insulator defect detection. To address these issues, this article proposes an insulator defect detection algorithm based on an improved YOLOv8n model, aiming to enhance the model's detection performance and achieve model lightweighting. The main work includes:

(1) Aiming at the low detection accuracy of the model and the problem of more miss detection, this work proposes an insulator defect detection algorithm CSSD_YOLOv8 based on the improved YOLOv8. The improved algorithm firstly uses the SAConv instead of the Conv, and designs a new SA_C2f module and replaces part of the C2f, in order to increase the model's ability of feature extraction for multiscale targets; in order to enrich the multiscale feature expression, a new module is designed to replace part of C2f. enrich the multi-scale feature expression, the SPPF_LSKA module is designed; the DWR_Detect detection header is also designed to replace the original Detect structure to reduce the leakage rate of small targets; during this period, in order to enhance the detection effect of small targets, a small target detection layer is added to enhance the combination of deep semantic information and shallow semantic information. The experimental results show that the improved algorithm improves the average detection accuracy by 3.1% compared with the original algorithm, and also improves the original algorithm's leakage detection and misdetection, which proves the effectiveness of the improved algorithm.

(2) Aiming at the number of model parameters and large computational volume, which is not conducive to the deployment of the problem, this work proposes an insulator defect detection algorithm based on the combination of lightweight structure and knowledge distillation. The improved algorithm takes YOLOv8n as the base network, and lightweight design of its model structure, firstly, integrates the WTConv module with C2f, and constructs the C2f_WTConv module to capture multi-scale features in the image; following that, it designs a dynamically sampled feature fusion neck structure DEHSFPN, which improves the structure of the HSFPN network through the introduction of ELA attention, and The efficient feature

中国知网　https://www.cnki.net

fusion network EHSFPN is obtained, during which the Dysample up-sampling operator is used for dynamic sampling to improve the feature fusion efficiency and model performance; finally, the MGD knowledge distillation technique is used to improve the model detection accuracy while keeping the number of parameters constant. The experimental results show that the mAP value of the improved algorithm reduces the parameter quantity by 24.1%, the GFLOPs by 30.9%, and the model volume by 22% while keeping 91%, which achieves the purpose of lightweight model and is more suitable for deploying to the memory-constrained UAV devices.

Figure [29] Table[6] Reference[71]

Key Words： Insulator Defect Detection; Yolov8; Feature Fusion; Knowledge Distillation

Chinese Books Catalog:TP391

中国知网　https://www.cnki.net

目 录

1 绪论.....1
1.1 研究背景与意义.....1
1.2 国内外研究现状.....2
1.2.1 传统的绝缘子缺陷检测.....2
1.2.2 基于深度学习的绝缘子缺陷检测.....3
1.3 论文研究内容.....5
1.4 论文组织结构.....6
2 相关理论和技术.....8
2.1 卷积神经网络.....8
2.1.1 卷积层.....8
2.1.2 激活函数.....9
2.1.3 池化层.....10
2.1.4 全连接层.....11
2.2 目标检测算法.....11
2.2.1 两阶段目标检测算法.....11
2.2.2 单阶段目标检测算法.....12
2.3 知识蒸馏.....17
2.4 模型评价指标.....17
2.5 本章小结.....19
3 基于 CSSD__YOLOv8 网络的绝缘子缺陷检测方法.....20
3.1 YOLOv8 算法概述.....20
3.2 网络模型设计.....21
3.2.1 构造 SA__C2f 模块.....22
3.2.2 设计 SPPF__LSKA 结构.....24
3.2.3 设计 Detect__DWR 模块.....25
3.2.4 添加小目标层.....26
3.3 实验过程与结果分析.....27
3.3.1 数据集的构建.....27
3.3.2 实验环境配置.....28
3.3.3 实验结果分析.....28
3.4 本章小结.....32
4 基于改进 YOLOv8 与知识蒸馏的模型轻量化方法.....33
4.1 轻量化网络设计.....33
4.1.1 构造 C2f__WTConv 模块.....34

中国知网 https://www.cnki.net

4.1.2 设计 EHSFPN 结构.....35
4.2 基于知识蒸馏的检测精度改进.....37
4.3 实验结果及分析.....39
4.3.1 模型轻量化消融实验.....39
4.3.2 蒸馏算法实验结果与分析.....41
4.3.3 与其它轻量化模型对比实验.....42
4.4 本章小结.....44
5 总结与展望.....45
5.1 论文总结.....45
5.2 未来展望.....46
参考文献.....47

中国知网 https://www.cnki.net

插图或附表清单

插图：

图 1 绝缘子缺陷示例 1
图 2 技术路线图 6
图 3 卷积神经网络结构图 8
图 4 卷积运算 9
图 5 不同激活函数对比 10
图 6 池化层操作 10
图 7 SSD 算法结构 13
图 8 YOLOv3 网络结构图 14
图 9 YOLOv5 网络结构图 16
图 10 YOLOv8 网络结构图 21
图 11 CSSD_YOLOv8 网络结构图 22
图 12 可切换的空洞卷积结构 23
图 13 SA_C2f 结构 24
图 14 LSKA 和 SPPF-LSKA 模块结构 25
图 15 Detect_DWR 模块 25
图 16 扩张残差模块图 26
图 17 部分绝缘子及缺陷数据集 27
图 18 训练结果对比 30
图 19 原 YOLOv8n 检测图 31
图 20 改进后的 YOLOv8n 检测图 31
图 21 WDEH_YOLOv8 网络结构图 33
图 22 WTConv 结构图 34
图 23 C2f_WT 结构图 35
图 24 EHSFPN 结构图 36

中国知网 https://www.cnki.net

图 25 改进后的 SFF 模块 37
图 26 Dysample 模块 37
图 27 消融实验的 mAP0.5 曲线 40
图 28 蒸馏前后的 mAP 变化曲线 42
图 29 模型改进前后的检测图 44

附表：

表 1 训练参数配置 28
表 2 不同算法性能对比 29
表 3 消融实验结果 29
表 4 轻量化 YOLOv8 消融实验 39
表 5 知识蒸馏前后模型对比 41
表 6 不同轻量化模型对比 43

中国知网 https://www.cnki.net

1 绪论

1.1 研究背景与意义

我国经济全面复苏，全社会制造业活动加速恢复，各行各业对电力的需求持续增长。稳定的电力供应作为国家经济的具有战略意义的支柱，其安全可靠是实现经济可持续发展的关键，而输电线路作为电力供应的关键渠道，其重要性不言而喻[1]。到 2023 年底，我国 220 千伏及以上输电线路总长度将超过 92 万千米，足以绕地球 23 圈。同年，我国输电线路长度将达到 46 297 千米[2]，输电线路不断扩大，覆盖范围遍布全国。

绝缘子是输电系统主要的绝缘装置，具有良好的机械支撑及电气绝缘功能，用来固定导体，防止电流的流动，对保证输电安全起着不可或缺的作用[3]。绝缘体长期暴露在强电场环境中，会受到各种不利因素的影响。降雨、降雪及极端温度变化等恶劣天气条件会对绝缘子造成侵蚀；污垢堆积及鸟类活动也会损坏绝缘子。这些因素的综合作用会造成输电线路绝缘子逐渐老化甚至损坏的结果。倘若绝缘子长期暴露在外部环境，损坏的风险就会大大增加，造成图 1 所示绝缘子故障的结果。相关统计数据反映 80%以上的电力系统故障都是由绝缘子故障引起的[4]，这一比例表明绝缘子出现故障会对电网的安全稳定运行构成极大的风险。鉴于此，定期对输电线路绝缘子进行维护检查，对防止重大输电线路事故的发生具有深远的技术价值，也对确保电力系统的长期稳定运行具有战略意义[5]。

图 1 绝缘子缺陷示例

Fig1 Example of an insulator defect

在检测架空线路绝缘子缺陷的传统工作中，人工检测一直是主要手段。架空线路数量的不断增加，检测任务的范围越来越大，检测环境也越来越复杂[6]。这些变化让人工

中国知网 https://www.cnki.net

巡检效率低、成本高、安全风险大的弊端日益显现，尤其在交通不便、自然环境恶劣的情况下，巡检难度明显增加。在此期间北斗系统及 5G 技术不断发展，无人机技术日益成熟，无人机巡检逐渐成为输电线路智能巡检的主流方式之一。无人机巡检具有高效、成本低、巡检效果好特点，但一直筛选航拍图像容易造成工作人员视觉疲劳，进而增加误判风险。近年来，受人工智能技术不断发展的影响，目标检测算法逐渐取代了传统的人工检测方法。与成本高、耗时长的人工检测相比，目标检测算法既能高效安全地完成绝缘子缺陷检测任务，又在绝缘子缺陷检测中表现出良好的适用性，得到了广泛的应用[7]。但绝缘子缺陷检测领域仍然面临着许多挑战，如绝缘子图像特征复杂需进一步提高算法精度；模型部署过程中计算量大需对模型轻量化。鉴于此，本文改进了 YOLOv8n 目标检测算法，并将其应用于绝缘子缺陷检测，构建了缺陷检测模型。模型的建立旨在提升检测精度及减少模型参数量，为电力系统的绝缘子缺陷检测提供新思路方法。准确检测绝缘缺陷，能及时发现并修复潜在故障，有效预防大规模停电事件发生，增强电力系统的稳定可靠性，对保障社会安全及人民生活具有重要意义[8]。

1.2 国内外研究现状

绝缘子在保证电气绝缘性能方面起着关键作用，它的关键地位及易故障特性让绝缘子缺陷检测成为当前研究的热点领域。近年来，国内外许多研究人员对输电线路绝缘子缺陷检测进行了研究，并取得了许多成果。深入调查文献发现绝缘子检测的相关技术主要分为两大类，传统图像处理技术及深度学习算法。

1.2.1 传统的绝缘子缺陷检测

在研究的早期阶段，传统图像处理方法与机器学习技术相结合是绝缘子的检测的主要方法。具体来说，研究人员先利用阈值分割及边缘检测等图像处理技术将绝缘子区域从复杂的背景中分离出来；继而利用方向梯度直方图（HOG）、尺度不变特征变换（SIFT）等算法在该区域中提取人工塑造的目标特征，其中包括颜色、轮廓及纹理等信息；最后让机器学习技术训练特征分类器，对绝缘子特征进行分类，从而输出缺陷检测结果。

近年来，绝缘体缺陷检测技术在几个关键领域取得了重大进展。在图像定位领域，Zhao Z 等人提出了一种基于方向角检测及二进制形状先验知识的多目标定位方法，将几何特征与物理约束相结合，提高了定位精度[9]。在旋转不变性检测领域，Jabid T 及 Uddin M Z 等人提出了一种利用局部方向模式及支持向量机（SVM）检测绝缘子的方法，成功解决了传统算法对角度变化敏感的问题[10]。Zhai Y 等人从 airsat-2 图像中提取空间形

中国知网 https://www.cnki.net

态特征并结合深度学习模型，实现了绝缘子误差的自动检测及定位，大大提高了检测效率及准确率[11]。在智能图像分割领域，Guifeng Z 等人提出了一种基于群优化聚类算法的保护装置图像分割方法，能更精确地进行边界提取，提高了传统分割算法的全局搜索能力[12]。Liu Y 等研究人员结合边缘比例统计方法，开发了一种自适应鲁棒边缘检测算法，大大提高了图像处理的鲁棒性[13]。在无人机应用领域，陈文浩等人基于无人机技术，开发了高效的绝缘子缺陷检测定位系统。该系统通过多角度成像及数据融合实现了输电线路绝缘子缺陷的快速检测定位[14]。在数据增强方法领域，Li Z 等人提出了一种反转变换的数据增强策略，提高了绝缘子检测的准确性[15]。

传统的绝缘子缺陷检测方法取得了一些成果，但仍面临许多问题。如这些方法依赖于人工特征提取，难以适应绝缘子的各种特性，存在鲁棒性不足和泛化能力有限问题。传统算法对图像质量要求较高，考虑到其只能提取表面特征，在光照及角度变化的情况下很难准确检测到缺陷，在复杂场景中容易误检与漏检。另外传统方法在处理大量图像数据时计算效率低，检测速度不能满足实际应用的需要。

1.2.2 基于深度学习的绝缘子缺陷检测

近年来，硬件性能的大幅提升及深度学习技术的突飞猛进，让目标检测技术取得了重大突破，在电力系统领域得到了更广泛应用。深度学习方法利用卷积神经网络（CNN）自动提取深层特征信息，无需人工设计特征。与传统方法相比，它可以更高效地捕捉到目标的丰富信息，表现出更强的泛化能力及表现力。深度学习算法还具备噪声处理的能力，在目标检测领域反映出巨大的潜力，因此基于深度学习的检测方法正在逐步取代传统方法。

依据网络训练方式的差异，目标检测算法被划分为双阶段及单阶段两大类。双阶段算法将检测流程分为两个阶段，而单阶段算法直接定位目标缺陷的具体位置，跳过了候选区域生成阶段，简化了检测流程。基于此，众多国内外研究者围绕双阶段及单阶段网络展开了一系列改进工作。Kang G 等人[16]提出了一种用于高速铁路绝缘子表面缺陷检测的深度架构，结合去噪自编码器对绝缘子图像进行特征提取及去噪处理，然后利用多任务学习进行缺陷检测及分类，提高了检测的准确性。顾超越等人[17]提出了一种基于改进 Faster-RCNN 的无人机巡检架空线路销钉缺陷检测方法，对 Faster-RCNN 框架进行了改进，包括优化网络结构、调整参数等，能更准确地检测出架空线路销钉的缺陷，提升了检测的准确率及召回率。Feng Z 等人[18]提出了一种基于 YOLOv5 的电气绝缘子缺

中国知网 https://www.cnki.net

陷检测方法，调整 YOLOv5 模型参数对绝缘子图像进行实时检测，提高了模型对绝缘子缺陷的检测速度及精度。熊炜等人[19]提出了一种基于改进 YOLOv8 算法的绝缘子缺陷检测模型，对 YOLOv8 算法进行了网络结构改进，提高了对绝缘子缺陷的检测准确率，能够达到检测出各种类型绝缘子缺陷的效果。Ahmed F 及 Mohanta J C[20]提出了一种利用自主四旋翼无人机及 SSD 网络进行电力传输线绝缘子检测的方法，由自主四旋翼无人机采集绝缘子图像，利用 SSD 网络进行实时检测，该方法实现了对绝缘子的准确检测。Zhang L 等人[21]提出了一种改进的 YOLOv8 绝缘子缺陷检测算法，通过改进模型结构、增强特征提取能力等手段，使得在存在差异光照、姿态及遮挡条件下识别到绝缘子表面的各类缺陷。

检测精度在不断提高，网络模型中的参数量也相应增加，这对模型的部署提出了更大的挑战。为了降低系统计算复杂度，研究人员对模型轻量化进行了广泛研究。典型的如 Wang B 等人[22]提出了用于测量输电线路冰厚的轻量级边缘估计方法 Icing-EdgeNet。该方法利用剪枝技术优化模型结构，在保持高精度的前提下降低了计算复杂度，适用于资源有限的边缘设备。Liu J 等人[23]提出了一种基于 char 波导的改进方法，该方法通过优化模型网络结构来检测航空图像的绝缘子故障，提高了模型对不同环境下绝缘子故障的检测准确率，为电力检测提供了一种可靠的故障检测技术。Qiu Z 等人[24] 提出了一种基于 YOLOv4 模型的轻量级绝缘子检测改进方法，该方法通过改进模型的网络结构，提高了缺陷识别准确率，适用于实时监测输电线路绝缘子的运行状态。Li Y 等人[25]提出了一种基于 SSD 的绝缘子缺陷检测改进算法，该算法结合了双网络的优势，提高了绝缘子缺陷检测的准确性和速度。伍箴燎等人[26]提出了一种基于改进 YOLOv5 算法的绝缘子多缺陷检测方法，对 YOLOv5 算法进行了优化，使其能更高效地检测绝缘子的多种缺陷。赵洋等人[27]提出了一种融合注意力与多尺度的电缆绝缘子缺陷检测方法，算法引入注意机制及轻量化设计，使模型能更准确地检测出存在差异尺度的电缆绝缘子缺陷，提高了检测精度及效率。Liu Y 等人[28]提出了一种基于 YOLOv8 的轻量化绝缘子缺陷检测方法，该方法通过改进模型结构，在保持高精度的在同时，降低了模型的计算复杂度，为电气设备的智能检测提供了新技术选择。

现有的深度学习的缺陷检测方法已经实现了智能化处理，并已成为输电线路绝缘子缺陷检测的主流算法。但现有模型在检测小缺陷方面仍存在困难，如深度学习网络模型消耗大量内存的问题，在检测精度方面仍有提升空间。基于此，本文在模型精度及轻量

中国知网 https://www.cnki.net

化方面进行研究，让模型部署能够适应更多的实际应用场景。实现高精度及小参数量之间的平衡是绝缘子缺陷检测实际应用领域的主要研究方向。

1.3 论文研究内容

本文针对绝缘子缺陷检测领域的研究需求，基于 YOLOv8n 网络并结合模型轻量化策略对绝缘子缺陷检测方法进行了深入研究，提出了绝缘子缺陷检测改进方案。主要研究内容包括：

（1）针对绝缘子缺陷检测中存在精度偏低、漏检率与误检率较高的问题，本文提出了一种基于改进的 YOLOv8 算法 CSSD_YOLOv8。该算法引入 SAConv 作为新的基础卷积模块，设计了创新性的 SA_C2f 模块，并用其替换了部分 C2f 结构，增强了模型在多尺度目标特征提取方面的性能；在此基础上，改进算法设计了 SPPF_LSKA 结构，在 SPPF 中引入 LSKA 注意力机制，以达到丰富多尺度特征表达能力的效果。还有针对传统检测头在小目标检测的局限性，改进算法在深层语义信息提取层面进行创新设计，提出了 DWR_Detect 新型检测头；最后添加小目标检测层来提升小目标检测效果。通过一系列实验验证，改进算法较原 YOLOv8 算法在平均精度指标上实现了提升 3.1 个百分点的效果，CSSD_YOLOv8 算法在改善原有算法性能的同时，提升了绝缘子缺陷检测的准确率，达到了降低误检率的预期效果。

（2）针对模型存在参数量大、计算开销大等问题，本文提出了一种基于轻量化与知识蒸馏相结合的检测算法。该算法以 YOLOv8n 模型为基础，通过一系列轻量化设计策略提升模型性能。在具体实现中，为达到提取图像中多尺度特征的效果，该算法将 WTConv 模块与 C2f 结构进行融合，形成 C2f_WTConv 模块，扩大了网络的感受野范围，提升了模型对复杂场景下特征信息的捕捉能力。在特征融合环节，该算法设计了一种动态采样特征融合颈部结构（DEHSFPN），利用 ELA 注意力机制改进 HSFPN 网络架构，得到 EHSFPN 结构，还采用 Dysample 上采样算子进行动态采样操作，进一步提升了特征提取的效率与效果。为实现检测精度与模型复杂度的平衡，本算法在轻量化模型中引入了知识蒸馏技术，在保持轻量化模型 WDEH_YOLOv8 参数量不变的前提下，实现了改进型算法的性能提升。经过一系列实验分析，改进算法在保持高检测精度的前提下降低了模型参数量，满足轻量化需求。

中国知网 https://www.cnki.net

1.4 论文组织结构

本文探讨了在绝缘子缺陷检测领域中，改进型 CSSD_YOLOv8 网络算法及结合知识蒸馏的轻量化模型策略。全篇共分为五章，技术路线如图 2 所示。

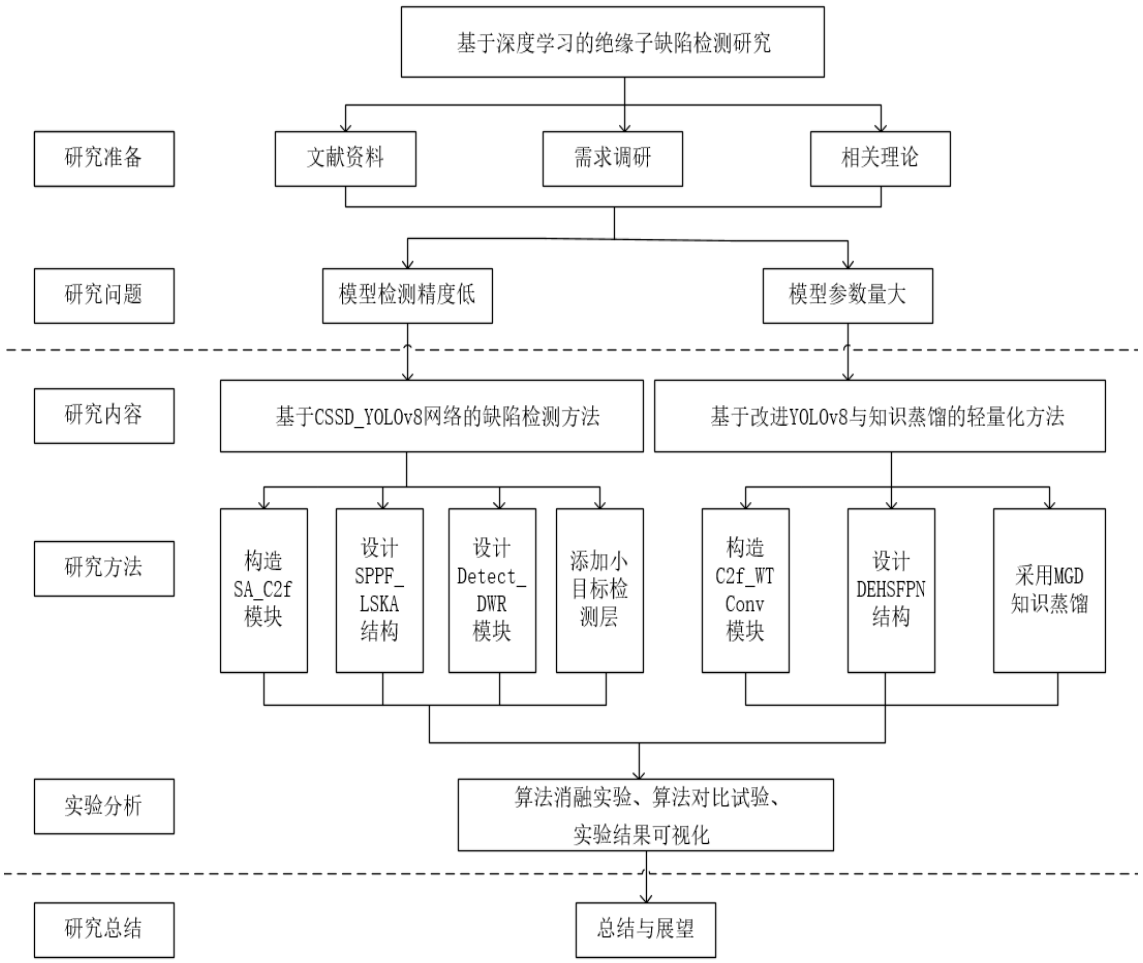

图 2 技术路线图

Fig2 Technology roadmap

第一章先阐述了绝缘子缺陷检测的意义及研究背景，继而介绍了国内外在绝缘体缺陷检测应用领域的研究现状，包括传统方法及深度学习方法，并分析了现有方法的局限性，最后对研究内容及整体结构进行了介绍。

第二章先介绍了卷积神经网络的基本理论及重要概念，在此基础上系统地介绍了目标检测领域的经典算法，如 RCNN、SSD、YOLO 系列等，还简要阐述了知识蒸馏的理论基础，为后续研究内容提供了理论支撑，最后简要介绍了目标检测领域常用的模型评价指标。

第三章介绍了提高检测精度的绝缘子缺陷检测算法设计。本章先阐述了 YOLOv8

中国知网 https://www.cnki.net

检测算法的理论基础，针对原始 YOLOv8 模型在绝缘子缺陷检测任务中存在的精度不足和漏检问题，本章设计了基于 YOLOv8n 改进的 CSSD_YOLOv8 网络。鉴于当前缺乏权威的公开数据集，本章自制了新的数据集，为后续实验提供了数据支持。本章通过对比实验和消融实验来验证所设计方法在提高绝缘子缺陷检测精度方面的有效性。

第四章介绍了轻量化的绝缘子缺陷检测算法设计。本章先对 YOLOv8 网络进行了简化改进，得到了 WDEH_YOLOv8 网络，这大大减少了模型参数的数量。然后将原 YOLOv8 网络作为教师网络，WDEH_YOLOv8 网络作为学生网络，WDEH_YOLOv8 网络引入 MGD 知识蒸馏方法，让学生网络学习教师网络的优秀性能，在不增加模型参数量的前提下，进一步提高检测精度。本章通过多次实验验证了改进算法的轻量化效果及优越性。

第五章总结了论文总体研究工作，指出了研究中仍存在的不足之处，并概述了未来的研究方向及发展前景。

中国知网 https://www.cnki.net

2 相关理论和技术

2.1 卷积神经网络

在人工神经网络发展的早期阶段，以多层感知器（Multi-Layer Perceptron，MLP）为典型代表的前馈网络作为经典模型占据了很长一段时间[29]。这种模型的信号机制依赖于相邻层的权重矩阵与输入向量的线性相乘，并通过映射激活函数生成现阶段层的响应值。而现代卷积架构通过引入局部特征空间及权重共享策略，利用空间卷积操作提取特征，实现了信息处理方式的根本性改变。全连接网络及卷积模型在参数优化过程中均采用误差反向传播的梯度计算方法，但在实际应用场景中表现出显著差异。全连接网络在处理结构化数据（如数字特征矩阵）时具有计算效率优势，而卷积模型因其特有的平移不变性特征，在视觉信息处理等非规则数据领域展现出更优越的泛化性能。

卷积神经网络（Convolutional Neural Networks, CNN）由 Hubel 及 Wiesel [30]提出。它的核心在于利用卷积层及池化层提取数据特征，继而在全连接层上执行分类或回归等操作。CNN 通常包含输入层、卷积层、池化层、全连接层和输出层。卷积层及池化层交替连接，最后与全连接层合并，完成分类或回归任务，网络结构如图 3 所示。它可以让 CNN 逐步学习到从图像中提取的抽象特征，来实现高效的分类及检测。下面将介绍卷积层、激活函数、池化层及全连接层。

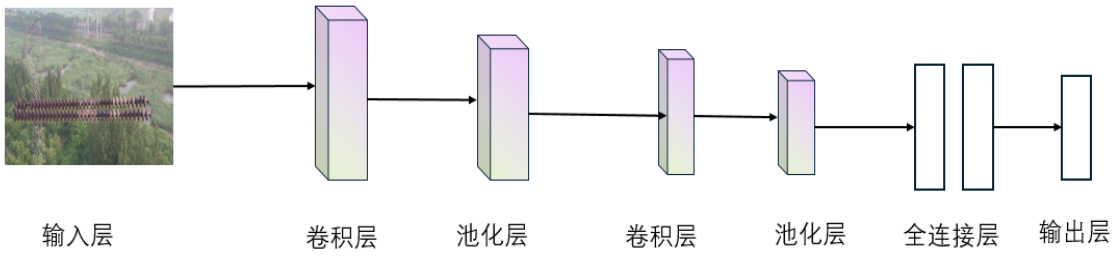

图 3 卷积神经网络结构图

Fig3 Structure diagram of the convolutional neural network

2.1.1 卷积层

卷积层（Convolutional Layer）是卷积神经网络的一个核心组件，由多个参数可调的卷积核组成。每个卷积核负责提取特定的特征，堆叠多个卷积核来形成卷积核组，逐步提取和组合输入数据的特征，并使用梯度下降算法优化参数。卷积核的大小分为 1×1、3×3 或 5×5，主要功能是利用卷积运算对图像进行特征提取。卷积操作主要涉及使用滤波器对两个像素矩阵进行点乘求和，一个矩阵是输入特征矩阵，另一个是卷积核矩阵。

中国知网 https://www.cnki.net

具体来说，卷积核从输入矩阵的左上角开始，逐步滑向右下角，每次移动都会与当前所覆盖区域的数据进行内积运算，并将运算结果填入输出特征矩阵的相应位置，形成该层的完整输出。每个卷积核都配有一组加权参数，它们在训练过程中不断调节以捕捉输入数据中的差异特征。为了避免边缘特征的丢失，卷积层会采用 Padding 方法对输入图像进行扩展。图 4 反映了卷积操作过程。

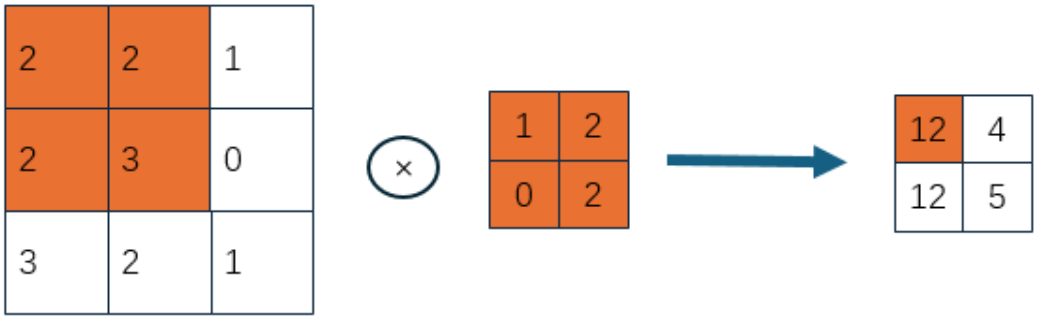

图 4 卷积运算

Fig4 Convolution operations

2.1.2 激活函数

激活函数在神经网络结构中扮演着至关重要的角色。倘若神经网络中没有激活函数，即便其通过增加卷积层数或神经元数量让结构变复杂，神经网络也仅能实现线性变换，输出结果也只是输入的线性组合，无法处理非线性问题。这种局限性严重限制了网络解决复杂问题的能力。要克服这一局限，关键在于引入激活函数。激活函数赋予神经网络非线性方式映射的能力，让神经网络能够模拟更复杂的数据关系，大大提高了神经网络表达能力。激活函数还能帮助网络更好地适应不同类型的输入数据，避免了梯度爆炸或梯度消失等问题。在卷积神经网络中，激活函数的选择对网络性能有着显著影响。常见的激活函数有 ReLU[31]、Sigmoid[32]、Tanh [33]、Leaky ReLU [34]及 SiLU[35]。这些激活函数各有特点，适用于不同的应用场景。在 YOLOv8 中，SiLU 被选为默认激活函数。SiLU 也被称为 Swish 函数，它结合了 ReLU 及 Sigmoid 函数的优点，具备非线性和平滑特性。它能对输入数据进行非线性变换，增强神经网络的表示能力。图 5 展示了不同激活函数。

中国知网 https://www.cnki.net

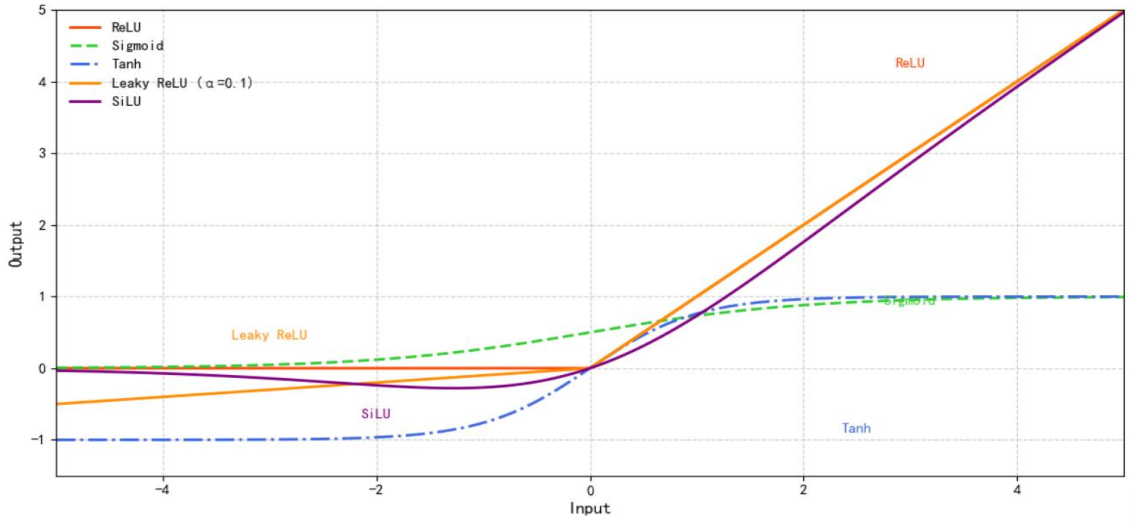

图 5 不同激活函数对比

Fig5 Comparison of different activation functions

2.1.3 池化层

池化层（Pooling Layer）一般在多个卷积层之后，对特征图进行下采样，在保持准确度的同时减小特征图尺寸，来应对特征图数量增加所导致的维度过高问题。这种降维方法能起到缓解过拟合的效果，提升了模型的泛化能力及鲁棒性，特别是对于复杂任务。池化操作不需设置学习参数，仅需设定池化窗口大小及滑动步长等参数就能实现降低特征维度。最大池化（Max Pooling，MP）及平均池化（Average Pooling，AP）是最常见的两种池化方法，最大池化提取每个区域的最大值来保留突出特征，而平均池化计算区域平均值来减少噪声，更有稳健性，更利于平滑特征图。这两种方法都是保留最显著特征，减少空间维度来降低特征图尺寸，在不同任务场景下发挥着重要作用[36]。图 6 反映了池化操作。

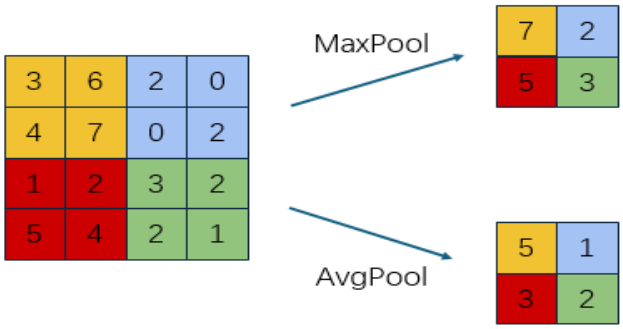

图 6 池化层操作

Fig6 Pooling layer operation

中国知网 https://www.cnki.net

2.1.4 全连接层

全连接层（Fully Connected Layer）位于神经网络架构的末端，负责将上一层的特征图转换成一维向量，产生最终的输出。全连接层通过学习连接权重，将输入特征与权重相乘并加上偏置，执行线性组合及非线性映射，完成从输入到输出的整个过程。全连接层在图像分类识别等任务中发挥着重要作用，它能整合全部特征信息，生成最终的输出结果。当输入数据是高维数据时，全连接层的参数量会大幅增加，这不仅增加了计算成本，还可能导致模型过拟合[37]。为了缓解这一问题，在全连接层之后用正则化技术来减少过拟合的风险。

2.2 目标检测算法

近年来，目标检测技术实现了显著进展。目标检测主要任务是在图像中准确找到目标并识别其类别。依据是否提取候选区域，目标检测方法主要分为两类。一类是以 R-CNN 系列算法为代表的两阶段目标检测算法，另一类是包括 SSD 及 YOLO 系列算法的单阶段目标检测算法。

2.2.1 两阶段目标检测算法

两阶段目标检测算法是一种基于区域建议的检测方法，检测过程分为两个步骤，一是候选框生成，二是候选框分类与位置微调。在候选框生成阶段，图像中可能存在多个目标，可以利用选择性搜索方法或基于锚框的方法在整幅图像范围内生成大小不等的候选框。接着筛选出基本符合目标特征的候选框，作为下一阶段的输入。在候选框分类与回归阶段，对每个候选框进行进一步处理。使用卷积神经网络作为分类器来判断候选框内是否包含目标，并将其归类到相应的类别。同时回归器用于调整候选区域的位置，以更精确地定位目标。

两步算法因其较高的检测精度及出色的检测效果而备受关注，但其两步性质造成检测速度相对较慢。常见的两步目标检测算法有 R-CNN、Fast R-CNN 及 Faster R-CNN。

（1）R-CNN 算法

R-CNN（Regions with CNN features）算法[38]是 Girshick 等人提出的，是 R-CNN 系列的开端。R-CNN 将区域模块与卷积神经网络结合，目标检测则转化为分类与定位的双重任务。R-CNN 算法的检测过程可分为四步，一是候选区域提取，使用选择性搜索算法对输入图像进行分析，生成潜在目标候选区域。为了适配 CNN 网络的输入要求，这些

中国知网 https://www.cnki.net

候选区域会被统一缩放至固定尺寸；二是特征提取，利用预训练的 CNN 模型对每个图像块提取出具有代表性的特征向量；三是目标分类定位，采用 SVM 分类器对目标进行精准分类，并借助回归模型对目标的边界框进行精细调整与定位；四是非重叠抑制，去除重叠区域输出涵盖目标类别与位置信息的检测结果。R-CNN 在提高检测精度方面取得了令人瞩目的成就，但其训练过程需要多步进行，检测时间大大增加，限制了其在实时性要求较高的场景应用。

（2）Fast R-CNN 算法

在 2015 年，Girshick 等人[39]针对 R-CNN 的计算效率和训练流程的不足，提出了 Fast R-CNN（Fast Region-based Convolutional Neural Network）这一改进算法。Fast R-CNN 对 R-CNN 进行了优化，无需为每个建议区域独立提取特征。Fast R-CNN 算法将整张图像及所有候选框一同输入模型，经卷积层和池化层处理后获得特征图，随后利用感兴趣区域池化层 ROI Pooling 从特征图中提取每个候选区域的固定大小特征，确保不同规模的区域均能得到统一的特征表示[40]。这些特征向量通过全连接层处理，用于目标类别的分类和边界框位置的回归分析，该分类过程常采用 softmax 函数。Fast R-CNN 在一定程度上解决了 R-CNN 计算冗余的问题，简化了 R-CNN 处理流程。Fast R-CNN 仍使用选择性搜索算法产生候选区域，这可能导致漏检误检问题，并限制了算法的检测速度。

（3）Faster R-CNN 算法

Ren 等人[41]提出了 Faster R-CNN（Faster Region-based Convolutional Neural Network），解决了 R-CNN 算法中选择性搜索算法生成候选框耗时的问题。Faster R-CNN 算法采用全卷积网络（RPN），提高了候选框生成的效率，减少了计算资源的消耗。Faster R-CNN 的训练过程分为两个阶段，在 RPN 阶段，算法利用滑动窗口在特征图上检测不同大小的锚框，并依据锚框与真实目标的重叠程度（IoU）进行分类及边界框回归，最终生成系列候选框；进入 ROI 阶段后，算法从这些候选区域中提取固定大小的特征，将不同尺寸的候选区域映射到固定大小的特征图上并执行池化操作，确保每个候选区域都能获得固定长度的特征表示，用于目标分类及边界框回归[42]。

2.2.2 单阶段目标检测算法

与传统的两步目标检测算法不同，单步目标检测算法直接在网络内部完成特征提取及对锚框的分类回归任务，无需候选区域生成等中间步骤，简化了处理流程，大幅提升了目标检测的速度。单阶段算法的检测精度在早期略低于两阶段算法，但技术不断更新，

中国知网 https://www.cnki.net

两者之间的差距正在逐渐缩小。单阶段算法仅需进行一次检测，其高效性使得在目标检测领域表现出色，在实际应用中得到了广泛采用。接下来本文将对两种核心目标检测方法简要介绍[43]。

（1）SSD 检测算法

SSD（Single Shot MultiBox Detector）算法[44]在不同尺度的特征图上部署多种尺寸和宽高比的锚框，能直接从网络中获取目标物体的类别及位置信息。SSD 算法受 VGG16 架构的启发，在 VGG16 的基础上增加了额外的卷积层，用于生成多尺度特征图，适应不同尺寸的目标检测需求。SSD 算法在特征图的每个位置上生成一系列默认框，这些框在尺寸和宽高比上存在差异，用于匹配多种潜在目标的形状和大小[45]。SSD 的网络结构如图 7 所示，SSD 算法利用多尺度分支提高了对不同尺寸目标的检测，但它未充分考虑不同尺度特征图之间的内在联系，浅层特征图中提取的信息相对较少且在捕捉语义信息方面的能力有限，致使 SSD 算法在小目标检测方面的表现仍有提升空间，性能优化是未来研究的方向。

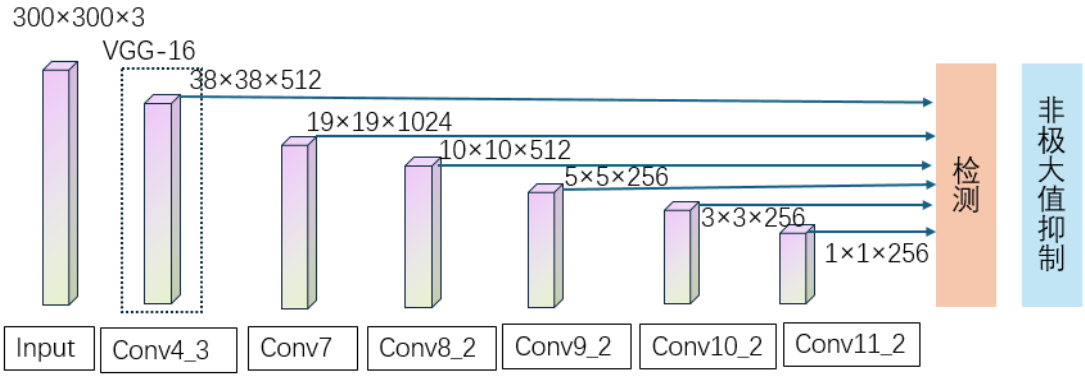

图 7 SSD 算法结构

Fig7 SSD algorithm structure

（2）YOLO 系列算法

Joseph Redmon 等人提出的 YOLO 算法模型是一种高效的目标检测算法，它能够一次性分析单张图像，识别出图中的多个目标并准确给出位置及类别信息。YOLO 算法将输入图像划分为 S×S 的网格，每个网格负责检测该区域内的物体，预测多个边界框及其置信度和类别概率[46]。YOLO 系列模型整合学习先进算法，不断优化模型架构，以其性能出色特点，获得了各领域研究人员的广泛认可。下面将简要介绍 YOLO 系列算法的发展改进。

YOLOv1[47]是 You Only Look Once 的第一个版本，开创性地将目标检测任务转化为

中国知网 https://www.cnki.net

回归问题，为后续 YOLO 系列模型的发展奠定了坚实基础。YOLOv1 算法以全局视角处理整幅图像，将其细分为多个网格单元，每个网格单元专注于预测其内部的目标对象，包含位置、尺寸及置信度信息。具体说来，每个网格会生成 2 个边界框及涵盖所有类别的概率值，借助非极大值抑制技术筛选出重叠边界框，输出精准的预测结果。YOLOv1 能在单个神经网络同时预测目标类别与位置，但在目标定位精度尚有提升空间。后续版本针对这些问题进行了优化，性能得到提升。

YOLOv2[48]是 YOLO 系列的第二代，在 YOLOv1 的基础上进行了多项关键改进，如引入了 Anchor Boxes 及 Darknet-19 模块。YOLOv2 算法采用基于 Faster-RCNN 的 Anchor Boxes 技术，在每个网格预测多个不同尺寸边界框，能更有效地检测不同尺寸的目标，增强了模型对各种大小目标的检测能力。Darknet-19 作为 YOLOv2 的核心特征提取网络，采用了更多的卷积层和更小的卷积核，每个卷积层后都加入了 Batch Normalization 层，降低了模型对输入图像尺度的敏感性，减少了对超参数调整的依赖，使得网络训练更加稳定。YOLOv2 在检测速度上取得了一定优势，但在处理尺寸多变的目标，尤其是小尺寸目标时，仍有局限性。

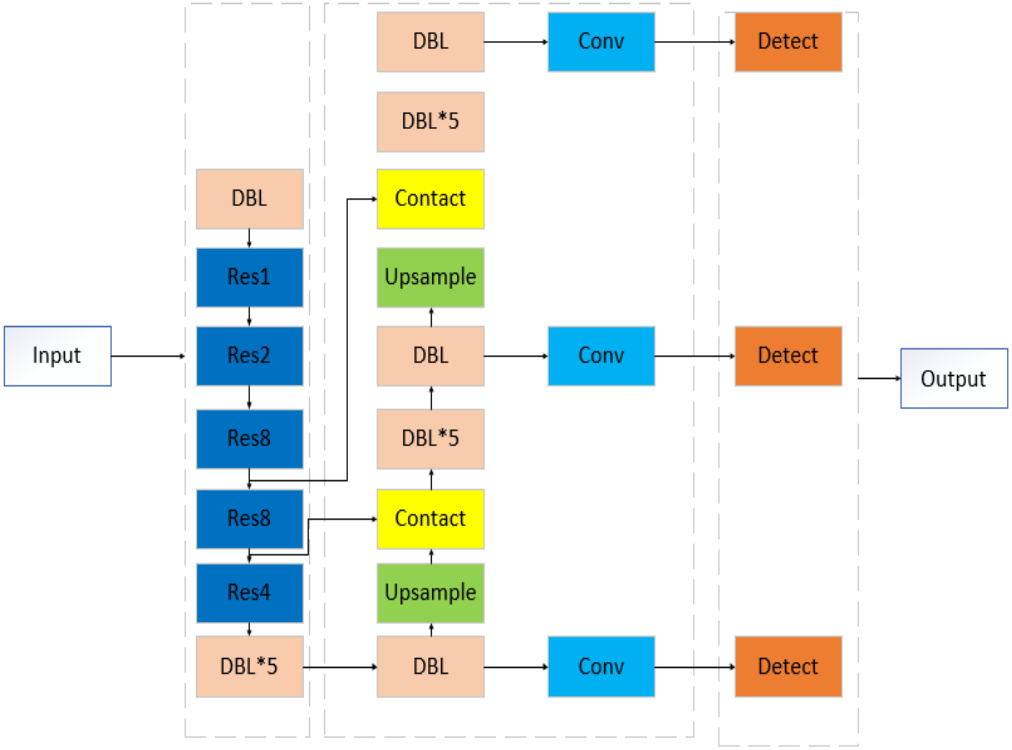

图 8 YOLOv3 网络结构图

Fig8 YOLO3 network structure diagram

中国知网 https://www.cnki.net

YOLOv3[49]（You Only Look Once version 3）是 YOLO 系列中一个重要的版本，后续的网络结构设计均在此基础上进行改进。YOLOv3 网络结构由 Darknet-53 骨干网络和特征金字塔网络（Feature Pyramid Networks，FPN）构成，如图 8 所示。Darknet-53 架构通过残差连接和深度可分离卷积提取目标特征信息，避免了梯度消失和梯度爆炸问题。FPN 负责融合不同层次的特征信息，使深层网络的语义特征向下传播，增强了浅层网络的语义信息，实现了大、中、小三种尺度目标的检测。YOLOv3 还引入逻辑回归来取代 Softmax 函数，提升了复杂背景下目标分类的准确度。这些改进提升了 YOLOv3 算法检测目标的准确性，但同时也增加了网络的复杂度。

YOLOv4[50]（You Only Look Once version 4）于 2020 年提出，引入了多项创新与优化。YOLOv4 在 YOLOv3 的 DarkNet-53 基础上融入了 CSP 模块作为新的 Backbone，既降低了计算量，又保留了特征的丰富性，有效规避了梯度消失问题。为了提升检测器性能，YOLOv4 还整合了路径聚合网络（PANet）和空间金字塔池化（SPP）来更高效地提炼和融合不同层次的特征信息。PANet 在 FPN 基础上增加了从浅层到深层的特征传递通道，提升了对小目标和远距离目标的检测能力。SPP 增加感受野避免了特征信息的丢失，节省了计算成本。在优化网络结构的同时，YOLOv4 还引入了数据增强技术和新的训练技巧，如 Mosaic 图像增强模块、采用 DropBlock 正则化方式取代传统 Dropout，增强了模型的泛化能力。YOLOv4 还采用了 CIoU Loss 替代以往的损失函数来提高定位精度。这些改进使得 YOLOv4 在准确性和速度上都取得了提升，有力地推动了目标检测技术的发展。

YOLOv5[51]是 You Only Look Once 的第五个版本，相较于之前的 YOLO 系列模型更为轻量化。YOLOv5 提供了多种模型尺寸，包括 YOLOv5s、YOLOv5m、YOLOv5l 和 YOLOv5x，这四种架构均以 CSPNet 为基础骨架网络，通过“depth multiple”和“width multiple”两个参数来控制网络的深度和宽度，YOLOv5s 的结构图如图 9 所示。YOLOv5 网络结构与 YOLOv4 相似，骨干网络、颈部网络和头部网络基本保持不变，仅在部分细节上有所改动。YOLOv5 在图像增强方面结合了 CutMix 和 Mosaic 技术，增加了训练数据的多样性。YOLOv5 在特征提取之前对图像执行了系列预处理步骤，增加了对小目标和长宽比大的目标的处理策略。YOLOv5 在训练过程中采用了 CIoU_Loss 和 NMS 预测框筛选方法，提升了模型的性能和精度。YOLOv5 还引入了自适应网络缩放策略，依据输入图像大小自动调整网络的深度及宽度，这不仅对小尺寸目标处理保持较高的准确性，

中国知网 https://www.cnki.net

也满足大尺寸目标的处理需求，能快速生成满足不同资源和性能需求的模型，增强了模型的通用性。

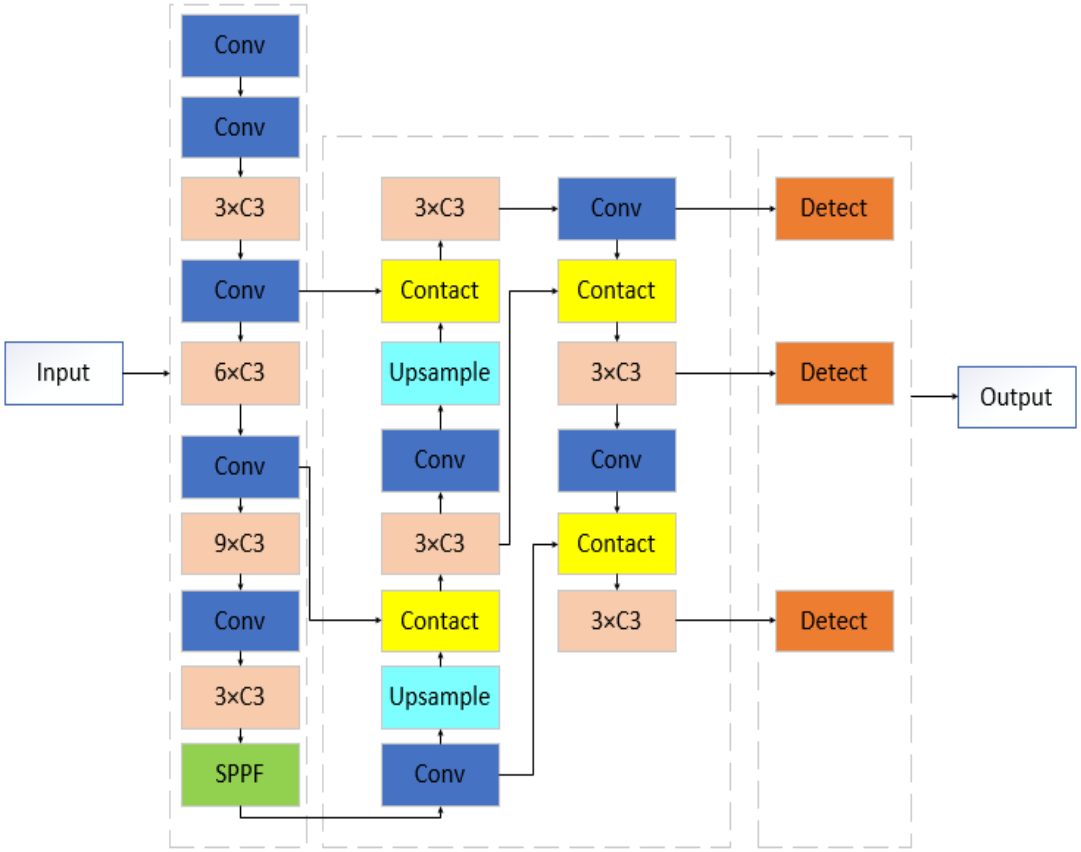

图 9 YOLOv5 网络结构图

Fig9 Network structure of YOLOv5

YOLOv6[52]和 YOLOv7[53]在 2022 年相继发布。YOLOv6 算法整合了多种优秀策略进行网络改进，采用重参数化结构，在推理时将卷积层和 BN 层合并，在头部网络中引入了 Decouple-Head 双检测头机制，分离分类和检测步骤来提升检测精度和推理效率。除了对网络架构进行优化，YOLOv6 的研发团队还引入了 Anchor-free 无锚范式，结合 SimOTA 标签分配策略和 SIoU 边界框回归损失等技术，进一步增强了 YOLOv6 算法性能[54]。YOLOv7 算法在 YOLOv5 的 Backbone 结构基础上进行了创新设计，构建了 ELAN 网络，通过采用基于级联模型的模型缩放和模型卷积重参数化等策略，在不降低模型性能的前提下加快了网络运行速度。

Ultralytics[55]在 2023 年初推出了 YOLOv8（You Only Look Once version 8），这是一款在前代版本基础上进行全面优化的模型。YOLOv8 模型在网络架构、锚点设置及数据增强技术等方面均进行了改进。YOLOv8 通过检测目标中心点来预测锚点框，省略了手

中国知网 https://www.cnki.net

动选择预设锚点框的步骤，不仅提升了模型性能，还增强了鲁棒性，使其能够高效完成分类、检测、分割等多种任务。关于 YOLOv8 模型的详细架构将在下一章讨论。

2.3 知识蒸馏

深度学习不断发展，模型检测精度不断攀升，主要得益于网络层数的不断增加，这也使得它们在资源受限的环境中部署面临着诸多挑战。知识蒸馏是能在不损失性能的前提下将深度学习模型部署于资源受限的设备上的一种有效解决方案。知识蒸馏（Knowledge Distillation，KD）是由 Hinton 等人[56]于 2015 年提出，本质上属于迁移学习范畴。其核心理念是借助一个已训练好的大型模型（教师模型）来指导小型模型（学生模型）的训练，使学生模型的效果能够接近甚至超越教师模型，并实现模型体积的缩减。在此过程中，教师和学生模型分别扮演着指导者和学习者的角色。学生模型在教师模型的指导下学习，不仅包括模仿教师模型的输出，还涉及学习教师模型的内部表征，相较于自主学习能更高效地提升性能。知识蒸馏依据知识来源的不同可分为基于响应的知识蒸馏和基于特征的知识蒸馏等多种类型，不同类型的蒸馏策略通过不同的方式把知识传给学生模型。基于响应的知识蒸馏利用教师模型的 logits 输出来引导学生模型的学习，而基于特征的知识蒸馏借助教师模型中间层的特征表示来传递知识[57]。这些方法在多种任务和数据集上均取得了性能提升，展示了知识蒸馏的有效性和潜力，在计算机视觉等领域具有广阔的应用前景。

2.4 模型评价指标

评估目标检测算法性能常采用一系列指标。精度评估指标包括精确率（P，Precision）、召回率（R，Recall）、平均精度（AP，Average Precision）及平均精度均值（mAP，mean Average Precision）[58]。复杂度与效率评估指标包括参数量（Params）、计算量（GFLOPs，Giga Floating Point Operations）及每秒传输帧率（FPS，Frame Per Second）。下面将对这些指标逐一展开介绍。

(1) 准确率及召回率

精确率 P 反映了模型预测为正的样本中实际为正的比例，而召回率 R 衡量了所有正样本被模型正确检测到的比例。这两个指标分别从不同角度评估模型的性能，P 关注预测的准确性，R 关注预测的全面性。通常情况下，这两个指标难以同时达到最优，当精确率较高时，召回率往往会较低，反之亦然。具体的计算公式如式 2.1、式 2.2 所示：

中国知网 https://www.cnki.net

$$P = \frac{TP}{TP + FP} \tag{2.1}$$

$$R = \frac{TP}{TP + FN} \tag{2.2}$$

式中，TP 表示真阳性（True Positive），FP 表示假阳性（False Positive）， FN 表示假阴性（False Negative）。

（2）平均精度均值

平均精度（AP）衡量某一特定类别下的模型性能，由计算 P-R 曲线下的面积得出，平均精度均值（mAP）是对所有类别 AP 值的平均来评估模型的整体性能。一般 AP 值和 mAP 值越高，模型的识别精度越高，表示模型检测效果越佳，计算公式如式 2.3、式 2.4 所示：

$$AP = \int_0^1 PdR \tag{2.3}$$

$$mAP = \frac{1}{n}\sum_{i=1}^{n} AP_i \tag{2.4}$$

式中，n 表示类别数，AP_i 表示第 i 类的精度均值。

（3）参数量与计算量

模型复杂度的重要评估指标之一是参数量（Parameters），参数量与模型复杂度一般呈正相关关系，参数规模越大，模型结构通常越复杂。参数量可以通过公式 2.5 计算；GFLOPs 是常用的量化标准，主要用于评估模型执行过程中所需的浮点运算次数，能有效反映模型对计算资源的需求程度。GFLOPs 越高，计算量越大，推理时间通常越长，功耗也更高。计算公式如式 2.6 所示：

$$Parameters = \sum_{l=1}^{L}(C_{in} \times C_{out} \times K^2 + C_{out}) \tag{2.5}$$

$$GFLOPs = \sum_{l=1}^{L}(2 \times C_{in} \times C_{out} \times K^2 \times H \times W)/10^9 \tag{2.6}$$

式中，卷积核大小为 K×K ，C_{in}、H、W 分别表示输入特征图的通道数、高度、宽度，C_{out} 表示卷积后输出特征图的通道数。

（4）模型推理速度

帧率（Frames Per Second, FPS）表示计算设备单位时间内能够处理的图像帧数，用于评估模型在硬件上的处理速度，其数值越高，表明算法在单位时间内完成的图像分析任务越多。

中国知网 https://www.cnki.net

这些量化指标为模型优化和实际应用部署提供了客观的性能评估依据，有助于指导算法改进方向。

2.5 本章小结

本章首先介绍了卷积神经网络的基本原理及重要组成部分，继而讨论了常见目标检测算法，还简要介绍了在提升模型精度方面发挥重要作用的知识蒸馏技术，最后对目标检测算法的采用评价指标进行了简要叙述，这些指标为评估目标检测算法的性能提供了定量依据。

中国知网 https://www.cnki.net

3 基于 CSSD_YOLOv8 网络的绝缘子缺陷检测方法

现有的 YOLOv8 模型在通用目标检测任务中表现出色，但在复杂场景中检测航拍绝缘子缺陷任务有明显的局限性。具体来说，受航空图像中存在严重背景干扰的影响，并且缺陷目标具有尺寸微小、分布密集、易受遮挡等特点，标准 YOLOv8n 模型在检测精度方面难以满足工程应用的要求。针对这一问题，本章提出了一种改进的 CSSD_YOLOv8 算法，通过针对性地改进网络结构来提升检测性能。本章在自建数据集上设计了消融和对比模型实验，通过实验分析得到，改进后的算法显著改善了小目标漏检问题，降低了误检率，检测精度也满足电力巡检的实际需求。

3.1 YOLOv8 算法概述

近年来，YOLO 系列算法不断推出新版本，其中 YOLOv8 在多个公开数据集上表现都十分优秀，在 YOLOv8 的众多版本中， YOLOv8n 因其在模型精度与轻量之间的出色平衡而备受关注。该版本在显著降低计算资源消耗的同时，仍能保持较高的检测准确率，故本研究选取其作为基础架构进行优化改进。图 10 展示了 YOLOv8 的整体框架，该架构继承并发展了 YOLOv5 和 YOLOv7 的设计理念，通过引入多项创新性改进，在检测精度与推理速度之间实现了更优的平衡。YOLOv8 模型采用了与 YOLOv5 相同的方法，重点运用 Mosaic 数据增强技术。该技术通过智能组合存在差异的样本图像及其背景，大大扩展了训练数据的多样性，增强了模型对复杂环境的适应性，为模型在真实场景中的应用奠定了坚实的基础。YOLOv8 算法特征提取网络由 CBS 卷积模块、C2f 模块及 SPPF 模块三个核心组件组成，YOLOv8 用 C2f 模块替代了原有的 C3 模块，C2f 模块融合了 YOLOv5 的 CSP 结构与 YOLOv7 的 ELAN 架构优势，通过引入 Split 分离机制与 Concat 操作，构建了类似 ResNet 的残差连接结构。这种改进在维持模型轻量化的前提下，增强了梯度信息流动，提升了网络对细小目标的特征捕捉能力。YOLOv8 算法的多尺度特征融合网络使用 SPPF 模块（Spatial Pyramid Pooling-Fast）替代传统 SPP 结构，并保留了 YOLOv5 的 PANet 结构，在 FPN+PAN 结构中全面采用 C2f 模块，并取消了 1×1 降采样层，使原始特征能够直接参与融合过程，增强多尺度特征交互。这些改进不仅减少了参数数量，还提升了模型的检测精度与计算效率。YOLOv8 检测头部采用了解耦式结构设计，将分类与定位任务分离为两个独立分支，分别处理类别预测和边界框回归，每个分支的输出均经过 1×1 卷积层精炼。在损失函数方面，YOLOv8 创新性

中国知网 https://www.cnki.net

地采用动态样本分配策略，分类任务使用 VFL 损失（Varifocal Loss），回归任务则应用 DFL 损失（Distribution Focal Loss）。

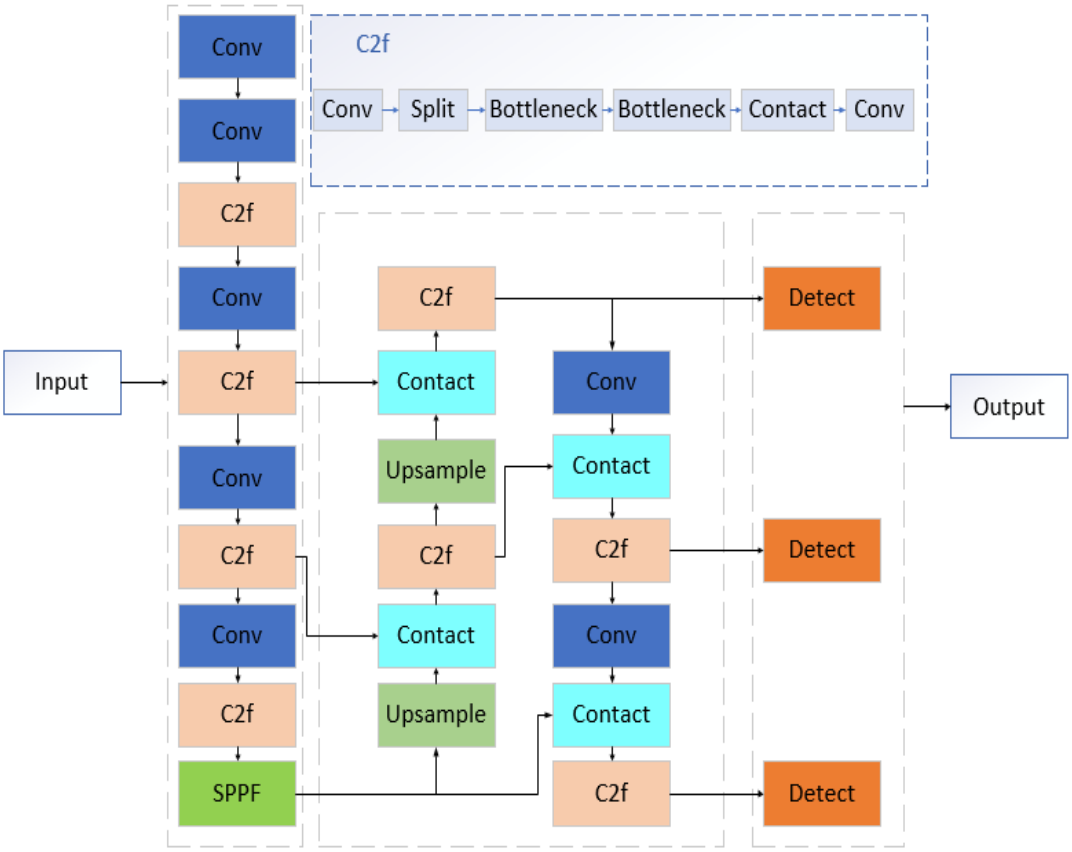

图 10 YOLOv8 网络结构图

Fig10 Network structure of YOLOv8

3.2 网络模型设计

本章在 YOLOv8 框架的基础上，提出一种新的改进方法，即 CSSD_YOLOv8，网络结构如图 11 所示。首先，将 SAConv 与 C2f 模块相结合，设计了 C2f_SAConv 模块，并将其取代 YOLOv8n 网络中的部分 C2f 模块。这种修改使网络能够通过具有两种不同膨胀率的卷积核来观察不同尺度的特征，以提高 C2f 增强模型的适应性，增强模型的检测能力。然后，受大型可分离核注意力（LSKA）概念的启发，将 LSKA 与 YOLOv8 中的 SPPF 模块相结合，使模型能够更有效地关注图像中的缺陷区域。通过捕获长距离依赖性和适应性来减少来自复杂背景的干扰，并增强了模型捕获关键信息的能力。此外，为更好捕获多尺度上下文信息，降低小目标的漏检率，将 DWR 模块引入头网络，重新设计 Detect 结构。同时为能在深层特征图中捕获小目标特征，添加小目标检测层，提高模型对密集缺陷检测的准确性。接下来将具体介绍各模块的原理。

中国知网 https://www.cnki.net

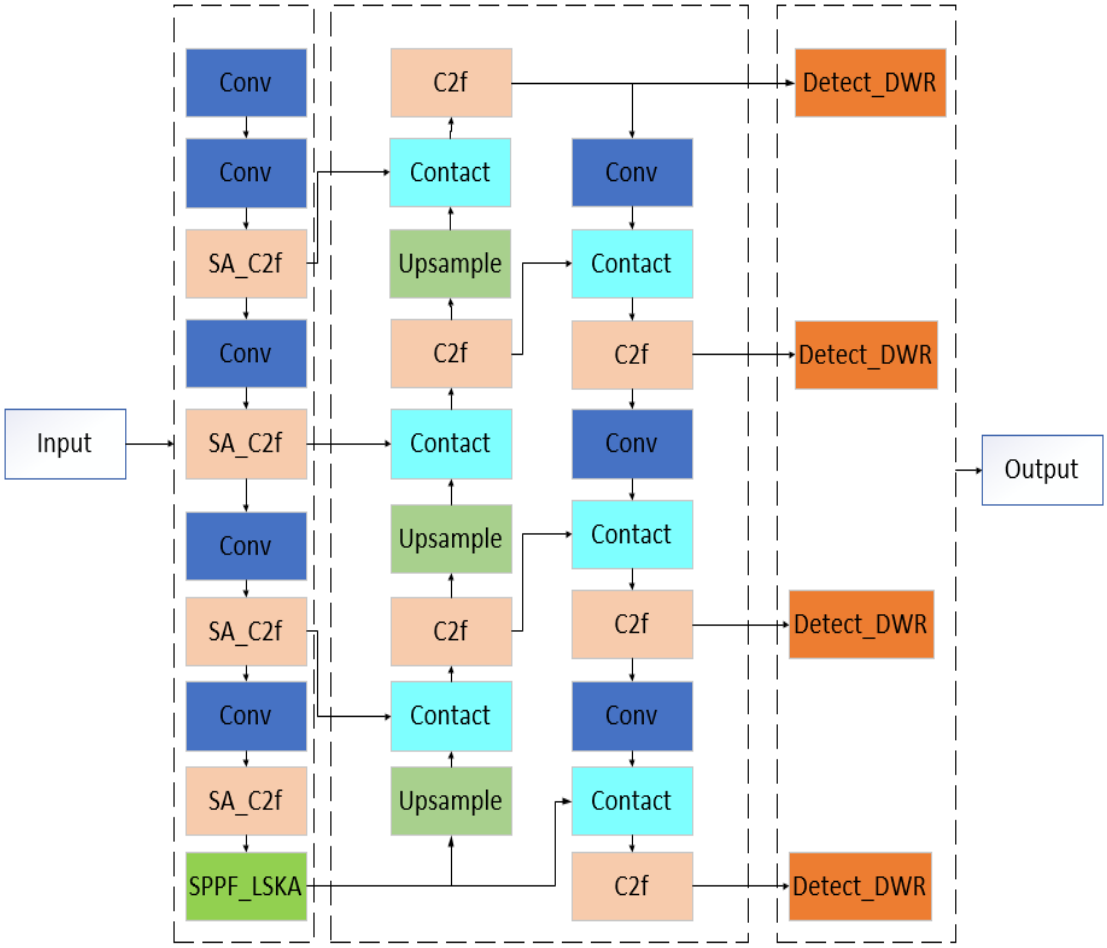

图 11 CSSD_YOLOv8 网络结构图

Fig11 CSSD_YOLOv8 network structure diagram

3.2.1 构造 SA_C2f 模块

在绝缘子缺陷检测的实际场景中，由于拍摄距离和角度等原因，航拍图像中的绝缘子往往存在相互遮挡或被电力塔遮挡现象，使模型难以完全检测到缺陷，再加上复杂的背景，增加了模型误判的风险，影响了整体检测的准确性和鲁棒性。原始 YOLOv8n 中所采用的 C2f 结构仅有有限的感受野和通道间的相互作用能力，无法有效地提取多尺度目标的特征，致使 YOLOv8n 的检测效果并不好。为了解决上述问题，本文用 SAConv（Switchable Atrous Convolution）[59]替换骨干网络中的一些 Conv 结构。普通的卷积使用固定的卷积核大小，这限制了感知范围，难以灵活地捕获广泛的特征信息。SAConv 通过改变卷积核的扩张率来扩展感受野，自适应地学习图像中不同位置的特征之间的关系，从而弥补局部细节的缺乏，增强了目标特征，抑制了背景噪声。

空洞卷积（Dilated Convolution）是一种有效扩展感受野的技术手段，不同空洞率的

中国知网 https://www.cnki.net

空洞卷积捕捉到不同感受野的目标，通过在卷积核中引入额外的空间（即空洞），扩大了感受野。SAConv 基于 atous 卷积的概念，它的空洞卷积和可切换的特性使得模型可以从多个多尺度特征信息中选择或融合，解决了小目标特征信息在传统卷积中难以学习的问题。SAConv 通过将 atrous 添加到卷积核中来扩展感受野的大小，使卷积层能够在更大范围内捕获特征，而不会扩大卷积核的大小，使得具有相同内核大小但不同膨胀率的卷积完全学习不同尺度和形态的缺陷特征。SAConv 的结构见图 12 所示，开关函数 S 是通过在卷积层之前使用平均池化层和 1×1 卷积层来计算的，将 S 和 1-S 分别乘以不同膨胀率的卷积的结果，将这两部分的结果相加，得到最终的输出。

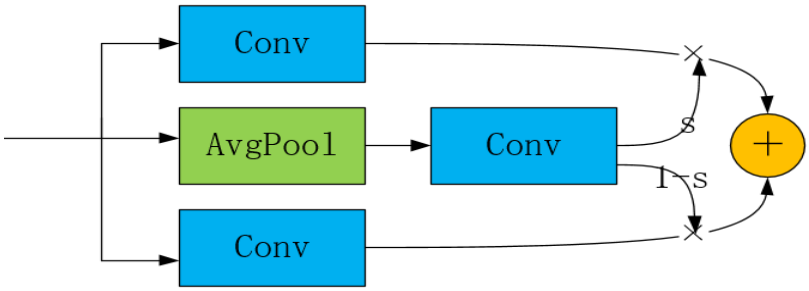

图 12 可切换的空洞卷积结构

Fig12 Switchable dilated convolutional structure

SAConv 模块通过引入可调节的空洞率参数（rate），对输入特征进行多尺度卷积运算，其主要创新之处在于利用开关函数（switch function）对卷积结果进行动态融合。这种设计使得特征图中每个空间位置都能独立控制输出特征的选择，实现了感受野的自适应调节机制。具体而言，网络能够根据输入特征自动在标准卷积与条件卷积模式间进行最优切换。公式 3.1 详细描述了将常规卷积层改造为可切换空洞卷积的数学过程。

$$\begin{aligned}\mathrm{Conv}(x,w,1)\xrightarrow[\text{toSAC}]{\text{Convert}}\mathrm{S}(x)\mathrm{Conv}(x,w,1)+\\(1-\mathrm{S}(x))\mathrm{Conv}(x,w+\triangle\mathrm{w},r)\end{aligned}\tag{3.1}$$

其中 r 是 SAConv 的超参数，Δw 是可训练的权重，开关函数 S（）的实现为具有 5×5 内核的平均池化层，后跟 1×1 卷积层。

通过结合 C2f 和 SAConv 模块，设计了 SA_C2f 模块，其结构如图 13 所示。该模块通过将 SAConv 集成到 C2f 模块的 Bottleneck 结构中，可以自适应地处理不同大小的物体，根据不同的输入图像数据，增加卷积核的空洞，扩大感受野的大小，使得网络在处理图像不同尺度特征的准确性提高，因而在目标检测展现出显著的性能提升。这种创新设计带来了三个关键优势，首先感受野的大小可以根据目标尺寸进行智能调节；其

中国知网 https://www.cnki.net

次不同尺度的特征信息能够得到更精确的提取；最后网络对各类尺寸目标的检测性能均获得显著改善，有效提升了模型对多尺度目标的识别准确率。

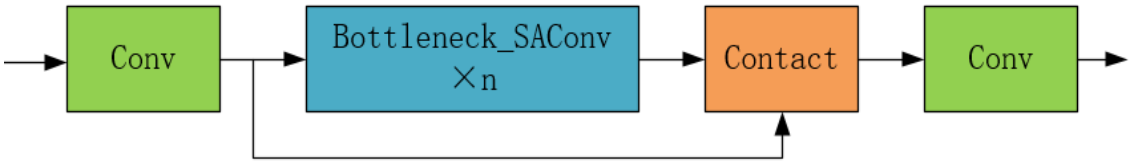

图 13 SA_C2f 结构

Fig13 Structure of SA_C2f

3.2.2 设计 SPPF_LSKA 结构

由于航拍图像背景复杂，缺陷特征常被背景掩盖，本章提出了 SPPF_LSKA 模块以增强模型提取关键目标特征的能力。该模块将 LSKA 注意力机制集成到 SPPF 层中，形成优化的 SPPF_LSKA 模块，捕获更广泛的特征信息，最大限度地减少了来自不相关背景信息的干扰。Self-Attention 机制和大核卷积可以在图像的不同部分之间建立关系。然而，自我注意具有很高的计算复杂性，并且大型内核卷积会带来大量的计算开销。本章介绍的 LSKA（Large Separable Kernel Attention）[60]基于 LKA[61]架构，是一个创新的 Attention 模块，LSKA 保持了与原始 LKA 相似的性能，在处理图像的关键特征（例如边缘、纹理和形状）时可以有效地捕获重要信息。它结合了可分离和空间扩展卷积，以增强网络对关键特征的关注，从而优化视觉注意力网络（VAN）的整体性能。LSKA 网络结构如图 14（a）所示。首先，将 K×K 卷积分解为 （2d-1 ）×（2d-1）深度卷积（DW-Conv）、K/d×K/d 深度扩展卷积（DW-D-Conv）和 1×1 卷积。接下来，将 2D 深度卷积核和扩张的深度卷积核进一步分解为 1D 水平和垂直卷积核。最后，将分解后的卷积核串联。这种分解机制使其能够直接利用深度卷积层的大内核，而无需额外的模块来提供帮助。

LSKA 机制通过注意力模块来加权特征图的不同部分以增强特征表示，使得模型能够更加关注于目标区域，在 SPPF 的结构中，LSKA 模块被添加在最大池化层（MaxPool2d）操作完成后和第二个卷积层（Conv）之前，如图 14（b） 所示。将 LSKA 与 SPPF 相结合对多尺度特征图进行加权处理，计算每个特征图上的空间权重和通道权重，根据这些权重对特征图进行调整，增强模型的多尺度特征提取能力，提高模型对目标特征的敏感度，使得模型能够更好地适应不同尺度的目标。

中国知网 https://www.cnki.net

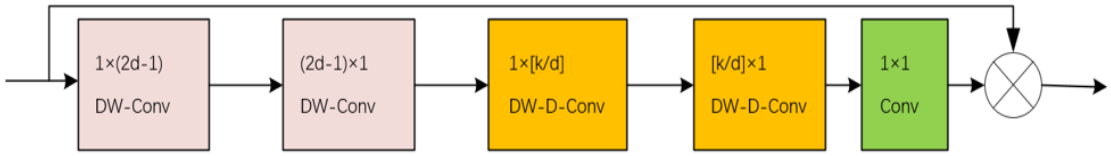

(a) LSKA 模块

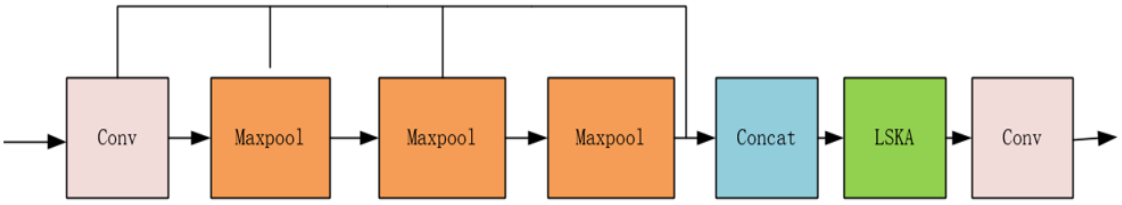

(b) SPPF-LSKA 模块

图 14 LSKA 和 SPPF-LSKA 模块结构

Fig14 Structure of LSKA and SPPF-LSKA modules

3.2.3 设计 Detect_DWR 模块

YOLOv8 采用解耦式检测头进行目标检测，检测头模块负责从特征图中预测目标位置和类别，有两个分支分别处理分类和回归任务，头部模块面对小尺寸缺陷时难以捕捉细节特征，限制了检测精度。针对上述问题，本文结合 DWR（Dilation-wise Residual）[62]的思想设计了 Detect_DWR 模块用于提取网络高层的特征，在单个输入特征图中捕获多尺度上下文信息，提高模型感知细节特征的能力。改进后的动态解耦头如图 15 所示，整体的模型框架在引入 DWR 模块后不发生改变，只进行卷积模块的替换，添加 DWR 模块以增强模型对相关特征的关注，忽略冗余信息，改善特征表示和整体检测准确性。

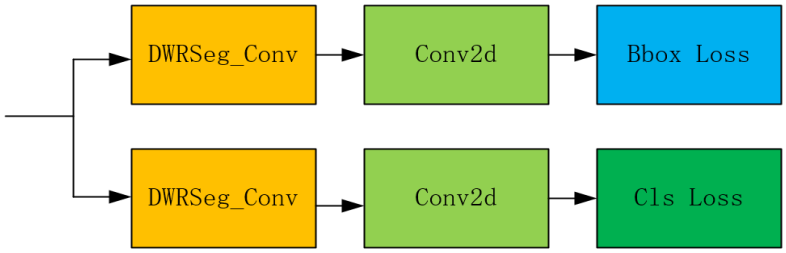

图 15 Detect_DWR 模块

Figure15 Detect_DWR module

DWR 模块使用具有不同膨胀率的深度可分离卷积处理输入特征，它在语义层面详细捕获图像中的不同对象，提取更丰富的上下文信息，更准确地捕获相应的特征信息。这一特性使得算法在集成该模块后能够更精确、更高效地识别绝缘子小缺陷的细微特征，

中国知网 https://www.cnki.net

有效提升了算法的性能。图 16 展示了 DWR（扩张残差）模块，它采用高效的两步方法，将多尺度特征提取的复杂任务简化为每个区域特征图的形态学过滤，用于捕获多尺度上下文信息。具体来说，将传统的单步卷积模块分为两个步骤，区域残差化（RR）及语义残差化（SR）。

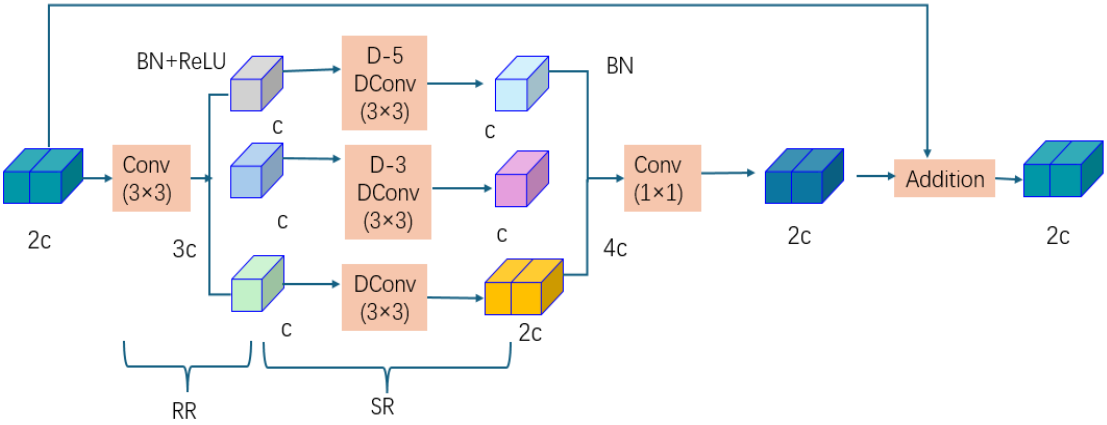

图 16 扩张残差模块图

Fig16 Diagram of the expansion residuals module

第一步用一个 3*3 的卷积核对输入的特征图进行预处理，通过批量归一化及 ReLU 激活函数来产生包含各种尺寸区域特征的简化特征图。第二步将这些特征图分为三组，并使用不同速率的深度扩张卷积（DConv）对不同大小的区域特征进行形态学过滤，代表语义残差化步骤。最后，特征图经过 BN 层和 1×1 卷积后进行合并，形成最终的残差，得到更全面、语义更丰富的特征表示。上述步骤由公式 3.2-3.4 表示。

$$C_1(x)=\mathrm{ReLU}(\mathrm{BN}(\mathrm{Conv}(x)))\tag{3.2}$$

$$C_2(x,d)=D_d\mathrm{DConv}(C_1(x))\tag{3.3}$$

$$\mathrm{DWR}(x)=\mathrm{PConv}(\mathrm{BN}(\Gamma_d\{C_2(x,d)\}))+x\tag{3.4}$$

式中，x 表示输入特征图，Conv（）表示 3×3 标准卷积，D_dDConv（）表示膨胀率为 d 的扩张深度卷积，PConv（）表示逐点卷积，Γ d{}表示所有膨胀率 d 的串联。

3.2.4 添加小目标层

原模型 YOLOv8n 对不同尺度的目标进行检测与识别，采用三个检测头并输出三种不同尺寸的特征图，分别为 20×20 像素、40×40 像素和 80×80 像素。模型输入图像大小 640×640，最小检测尺度 80×80 检测每一个网格得到 8×8 的感受野，如果目标的高度和宽度均小于 8 像素，则原始模型比较难学到小目标的特征信息，尤其是当绝缘子图像中的物体相互遮挡时，这就导致了小目标检测准确率不高、 漏检严重。因此为了改进

中国知网 https://www.cnki.net

这一问题，本文引入一个新的检测头，其对应的检测特征图的大小为 160×160，160×160 的特征图通常具有更高的分辨率，提供更多的空间信息，相比其他更大范围的检测层能够更加细粒度地获取极小目标的特征信息，弥补了原有网络在小目标检测方面的不足。它使得小目标的特征信息通过 Head 结构继续沿着下采样路径传递到其他三个尺度特征层，可以更深层次的特征传递和特征融合，以增强小目标的语义信息和特征表达能力，使模型可以检测包含更多细节低阶信息的目标和更微小的目标。这一结构调整提升了网络对各种尺寸目标的检测能力，不仅能够有效处理大型和中等尺寸的目标，还能更有效地处理小目标绝缘子缺陷图像，提高了在实际应用中的检测准确性。

3.3 实验过程与结果分析

3.3.1 数据集的构建

模型的性能在深度学习领域很大程度上取决于数据集的规模及质量。然而电气行业的绝缘子数据具有特殊性，难以获得绝缘体缺陷样本，绝缘子缺陷检测领域内并未有公开的大型权威数据集。考虑到这种情况，本文构建了一个绝缘体缺陷检测数据集。数据集由 CPLID 数据集中提供的 848 张标记图像及无人机巡网过程中采集的输电线路图像两部分组成，其中部分图像如图 17 所示。

图 17 部分绝缘子及缺陷数据集

Fig17 Partial insulator and defect dataset

为了避免样本数量不足导致的过拟合，本文对原数据集执行数据增强，包括亮度调

中国知网 https://www.cnki.net

整，旋转和水平翻转，以有效增加训练集的大小，为模型训练提供更为丰富的样本数据，从而提高模型的泛化能力。图像增强后，对数据集进行了数据扩充，最终扩充后的数据集图像共 6496 张。将其添加到数据集中，通过执行 Python 脚本，将训练集、验证集和测试集的比例按 8：1：1 随机分布，并且使用开源数据标注工具 LabelImg 对绝缘子数据集进行标注，将绝缘子图像导入 LabelImg，针对每张图像的缺陷，框选缺陷区域的边界框，标注文件自动生成为 PASCAL VOC 格式的 xml 文件。本文实验的基准模型是 YOLOv8n，所以需将 xml 文件转换为 YOLO 模型所需要的 txt 文件格式，适配 YOLO 系列算法的训练需求。后续章节均使用此数据集进行相关实验，这为保证实验结果的可靠性提供了坚实基础。

3.3.2 实验环境配置

本文实验环境在 Windows10 操作系统上进行，使用 NVIDIAGeForce RTX3060 进行训练和测试。该模型使用 PyTorch1.13.1 框架和 Python3.8 编程语言构建。初始学习率为 0.01，图片尺寸 640×640，在批量大小为 4 的情况下，训练了 100 个 epoch，采用随机梯度下降（SGD）优化器，优化器的动量和权重衰减值分别配置为 0.937 和 0.0005，并在剩余的 10%的时期期间禁用数据增强。具体实验环境如表 1 所示。

表 1 训练参数配置

Table1 Training parameter setting

参数名称	配置
epochs	100
batchsize	4
workers	0
imgsz	640
close_mosaic	10

3.3.3 实验结果分析

（1）不同检测模型对比试验

本章采用多元评估方法来检验改进模型的效果，如表 2 所示。本章对所提出的 CSSD_YOLOv8 算法与主要检测模型进行了比较，选取了四个主要性能指标进行定量分析：精度 P 衡量检测正样本的准确性；召回率 R 评估缺陷检测性能；平均精度 mAP 全面反映检测性能；计算复杂度 GFLOP 表示模型计算量。为了保证比较的公平性，全部模型都用相同的训练及测试数据集、采用相同的测试环境配置及保持相同的评价标准等要求。比较模型包括三类代表性算法：两阶段检测器 Faster-RCNN，单阶段检测器 SSD、

中国知网 https://www.cnki.net

YOLOv5，文献[63]、文献[64]中的方法，及原始模型 YOLOv8n。

表 2 不同算法性能对比

Table2 Comparison of the performance of different algorithms

Model	P/%	R/%	mAP	GFLOPs
Faster-RCNN	58.3	75.5	70.6	401.71
SSD	96.5	42.5	62.8	273.61
YOLOv5s	95.1	96.0	92.6	6.11
文献[63]	91.1	89.0	92.1	6.33
文献[64]	91.4	89.0	92.4	5.91
YOLOv8n	90.3	96.0	90.7	8.1
CSSD_YOLOv8	92.1	90.2	93.8	49.8

从表 2 可得，本章提出的算法对比 YOLOv5s、文献[63]、文献[64]和 YOLOv8n，mAP 分别提高了 1.2%、1.7%、1.4%和 3.1%，改进后的模型具有更高的检测精度。CSSD_YOLOv8 在 YOLOv8n 的基础上增加了小目标检测层和改进的检测头等改进，提高了模型对小目标的检测精度，但这也增加了网络计算量，在模型计算负载方面，CSSD_YOLOv8 模型相对较大，这给在移动的设备上测试部署带来挑战。同时，本章改进的网络与 Faster-RCNN、SSD 网络相比具有非常明显的优势，CSSD_YOLOv8 模型计算量大幅下降，召回率和平均精度也都有较大提升。由此可见，改进后的 CSSD_YOLOv8 算法在显著提高检测精度的同时，保持了较高的检测速率，在精度和参数量的综合考量方面较其他算法有明显优势。改进的 YOLOv8n 模型与同领域模型相比具有更好的检测性能，为绝缘子缺陷检测提供了一种实用的应用方案。

（2）模型消融实验

表 3 消融实验结果

Table3 results of ablation experiments

SAC	LSKA	Small layer	DWR	P/%	R/%	mAP/%	FPS	GFLOPs
				91.4	86.3	90.7	87.5	8.1
√				92.9	87.0	91.4	47.8	7.4
	√			90.2	87.4	90.9	64.8	8.3
		√		90.5	87.1	91.8	22.6	40.4
			√	92.5	86.9	91.3	49.1	10.5
√		√		90.4	86.7	91.1	19.6	39.7
		√	√	92.1	88.9	92.9	14.8	50.3
	√		√	90.4	88.0	91.2	48.0	10.7
√		√	√	91.8	88.8	92.8	13.2	49.6
√	√	√	√	92.1	90.2	93.8	13.0	49.8

本章以 YOLOv8n 为基线模型，在其依次加入了 SAC 卷积、LSKA 注意力机制、小目标检测层、DWR 模块四种改进方法，设计了严格的消融实验，以客观评估每个增

中国知网 https://www.cnki.net

强组件达到的效果。如表 3 所示。实验采用增量验证法，通过控制变量来分析每个模块的独立贡献。在结果展示中，符号"√"表示所采用的改进策略，这种设计可以清楚地反映存在差异组合下的性能变化。

由表 3 可知，每一种优化方案的引入都提升了模型的检测效果。通过引入 SAC 卷积、LSKA 注意机制、小目标层和 DWR 模块， mAP 分别提高了 0.7%、0.2%、1.1%和 0.6%。将小目标层和 DWR 模块添加在基线模型后，提升了模型对小目标的感知力，mAP 提升了 2.2%，但 GFLOPs 增加 42.2GFLOPs，说明引入的模块只适于精度提升，有参数量大的特点，在此基础上添加轻量级 SAC 卷积后，mAP 略微下降 0.2%，GFLOPs 也随之下降，说明 SAC 卷积能有效地降低冗余计算，对整体模型有轻量化的重要作用。由表 3 的实验结果表明，改进后的 CSSD_YOLOv8 模型比原 YOLOv8 模型，Precision、Recall、 mAP 分别提高了 0.7、3.9、3.1 个百分点，mAP 提升最为明显，但检测速度 FPS 降幅也最为明显，说明本章所提出的算法改进能提升精度，但也会增加模型的复杂度。

为了系统地评估改进算法的性能，本章对训练过程中的关键指标进行了直观分析。如图 18 所示。

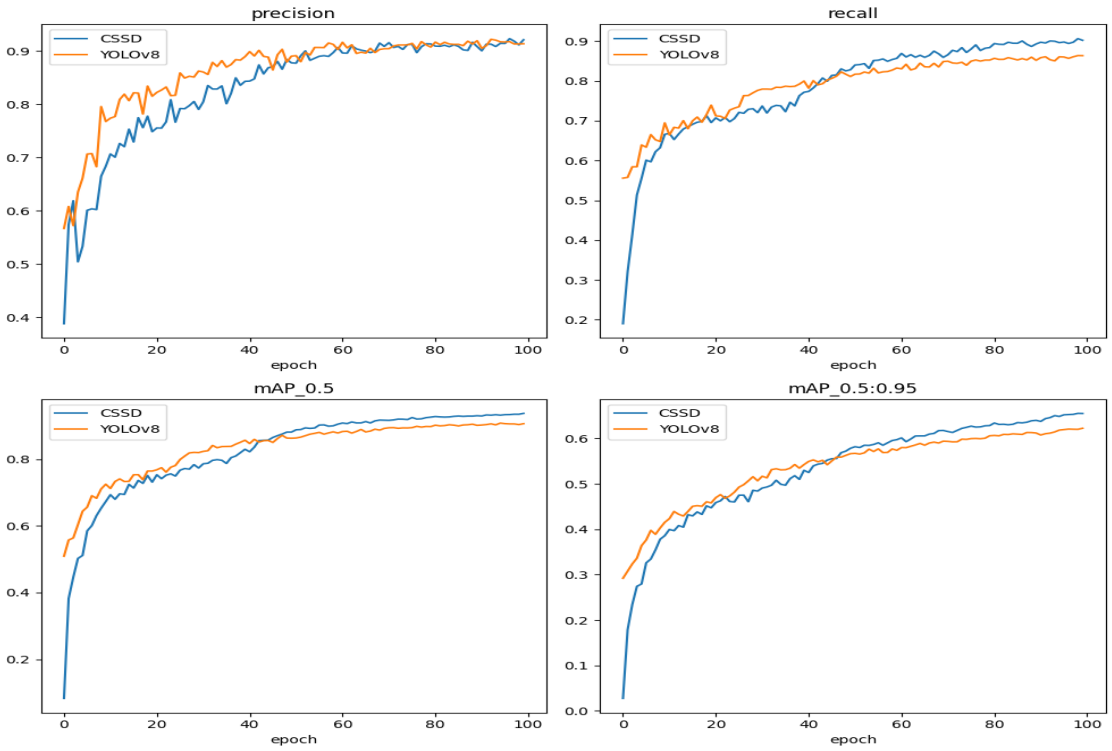

图 18 训练结果对比

Fig18 Comparison of training results

通过比较 CSSD_YOLOv8 及基准模型 YOLOv8n 在 100 个训练周期内的性能曲

中国知网 https://www.cnki.net

线，可以得出以下结论：在整个训练过程中，改进模型的精确度持续提高，召回率持续改善，mAP50 和 mAP50:95 指标提升。与基准模型相比，CSSD_YOLOv8 性能更好。该训练曲线证实了网络结构可以让模型性能得到改善。实验结果表明，CSSD_YOLOv8 既满足实现了更高的检测精度，又实现了在训练稳定性方面的优势，证实了本文提出的改进方案的科学性及有效性。

（3）可视化实验

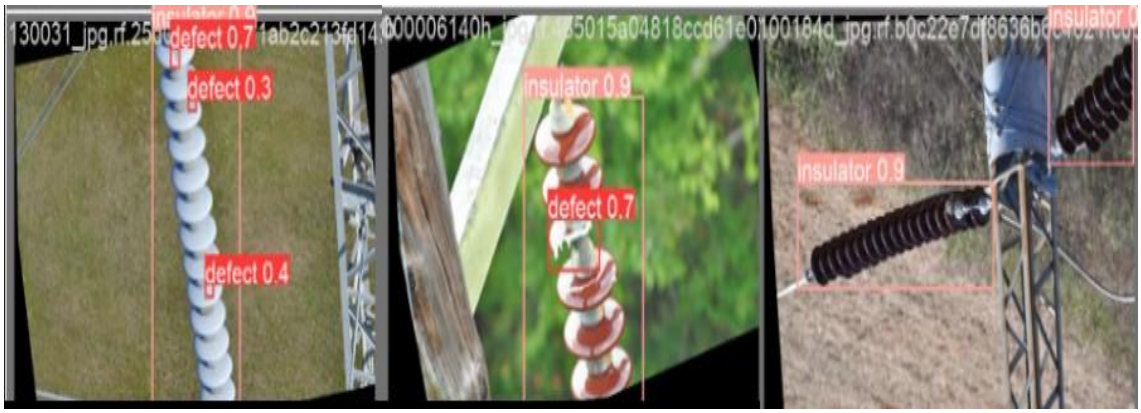

图 19 原 YOLOv8n 检测图

Fig19 original YOLOv8n detection image

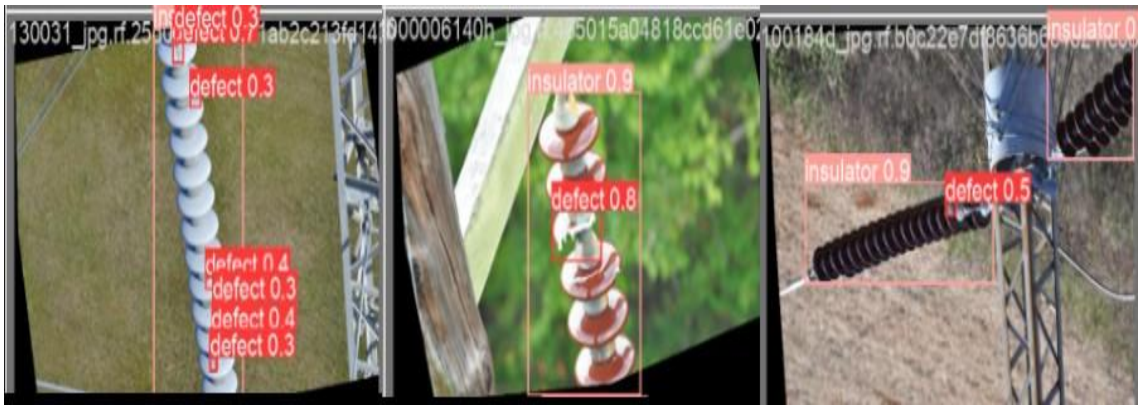

图 20 改进后的 YOLOv8n 检测图

Fig20 Improved detection of YOLOv8n

为更加直观地评价改进前后的效果，本章从数据集选取正常和有缺陷的绝缘子进行检测，橙色框表示绝缘体，红色框表示缺陷。对比图 19、图 20 可以看出，基准 YOLOv8n 网络在复杂背景干扰下可能会遇到检测精度低，漏检测和误报等问题，所提出的 CSSD_YOLOv8 算法通过加入四个改进点，显著提高了模型的特征提取能力，进而能够准确检测目标，有效地识别了绝缘体和缺陷，降低了漏检率和误检率，证明了该方法的鲁棒性。图 19 第一张图像是在密集缺陷目标场景下存在漏检,没有将图中全部缺陷检测

中国知网 https://www.cnki.net

到，图 19 第二张图像是检测绝缘子缺陷的精度低，图 19 第三张图像目标存在部分遮挡导致漏检，改进后的 CSSD_YOLOv8 模型解决了相应问题，能够检测出所有目标，且对每个目标的检测精度都有所提高。上述可视化实验对比结果表明，改进后的模型能够有效、准确地识别绝缘子及缺陷，改进模型检测性能提升明显。

3.4 本章小结

本章重点讨论基于 YOLOv8 模型的绝缘子缺陷检测精度低、漏检问题的改进。本章先概述了 YOLOv8 算法，因其在保持较高检测精度的同时，具有最小的参数量和计算量，被选中作为改进对象。接着本章详细描述了所设计网络模型的结构，并依据绝缘体缺陷检测的具体要求，设计并实现了基于 YOLOv8n 的改进算法 CSSD_YOLOv8。本章的目的是通过一系列优化目标检测算法，提高模型在小缺陷检测任务中的性能。本章最后介绍了实验过程及结果分析，对运用数据增强的自建数据集进行简要描述，通过消融实验和性能对比实验，验证了改进算法的有效性和优势。消融实验和性能对比实验表明，CSSD_YOLOv8 在 mAP 指标上取得了显著提升，但也存在一些局限性，如模型复杂度问题仍需进一步优化。

中国知网 https://www.cnki.net

4 基于改进 YOLOv8 与知识蒸馏的模型轻量化方法

在上一章中，通过一系列改进方法，CSSD_YOLOv8 网络相较于 YOLOv8n 网络在检测精度上得到了不小的提升，还有效减少了漏检和误检的发生，但为此付出了模型检测参数量增加的代价。在实际应用中，考虑到绝缘子缺陷检测模型通常需要部署在存储资源和计算资源有限的嵌入式设备上，模型的参数量不宜过大。为了进一步压缩模型，提高模型的运行效率，本章从轻量化的角度出发，对 YOLOv8 进行网络轻量化，但改进后的精度难以满足实际场景要求，为此使用基于特征的知识蒸馏方法，实现模型的轻量化的同时一定程度上提升检测精度。实验结果表明，通过这一系列的改进和优化，很好地降低了参数量，并且保证了一定的检测精度，验证了轻量化策略改进的有效性，为资源受限的应用场景提供了一种有效的解决方案。

4.1 轻量化网络设计

本章在 YOLOv8n 的基础上，对其网络结构进行改进，改进后的 YOLOv8 命名为 WDEH_YOLOv8，其网络结构如图 21 所示。

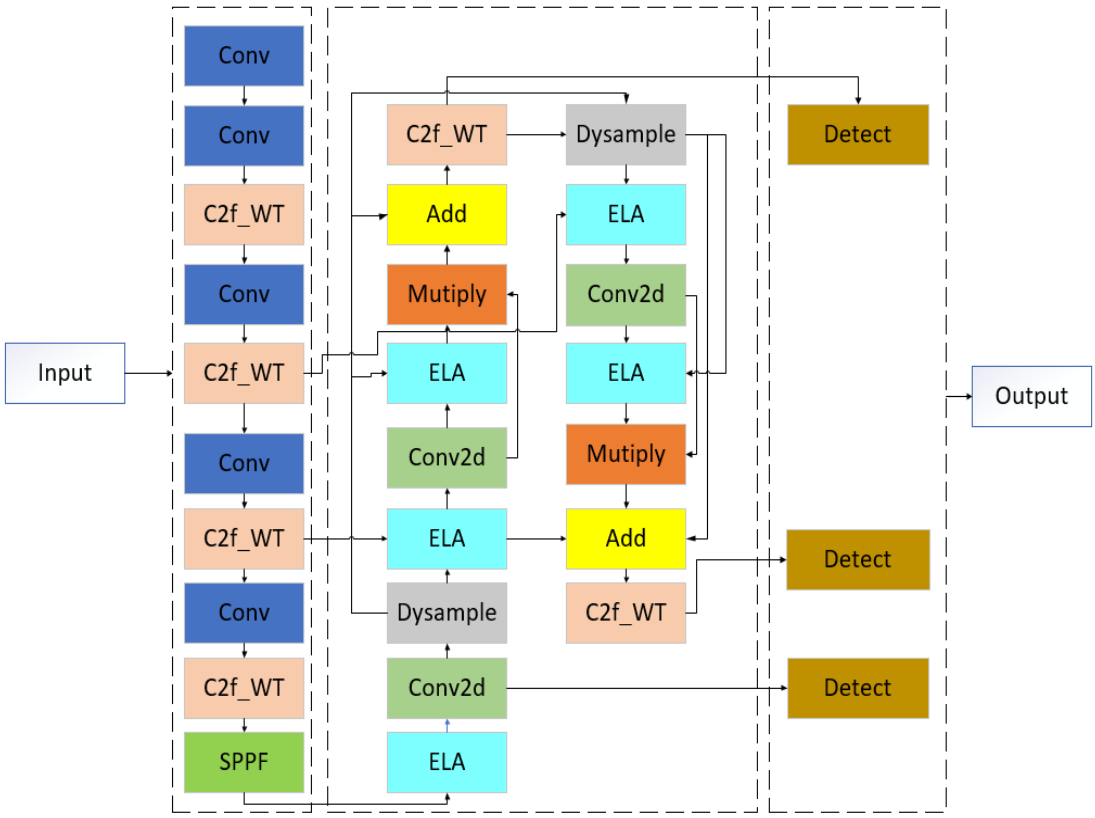

图 21 WDEH_YOLOv8 网络结构图

Fig21 WDEH_YOLOv8 network structure diagram

中国知网 https://www.cnki.net

在具体改进方面，本章先重新设计 C2f 结构，将 WTConv 模块替换原有卷积，通过获得大感受野来捕获低频，以实现轻量化的操作。与原始 C2f 模块相比，C2f_WTConv 模块具有更高的计算效率和特征表示能力。其次，为解决原 YOLOv8 模型过滤小尺度特征信息问题，本章将 ELA 注意力模块与 HSFPN 模块集成，得到 EHSFPN 模块，避免了传统金字塔结构逐层特征融合导致参数量过大问题。该算法在降低模型复杂度的同时，有效实现了多尺度特征融合，增强了模型的特征表达能力，使其能够有效地检测不同大小的目标。另外，改进算法采用 DySample 模块来进行动态采样，保留更关键的细节信息，以进一步减少参数量并增强模型在不同级别融合特征的能力。总的来说，WDEH_YOLOv8 模型通过创新的网络设计，提高了网络在复杂背景中提取对象特征的准确性，在保持较高检测精度的同时减少模型参数量，为实际应用场景提供了有力支撑。接下来将分别介绍用于改进 YOLOv8 的网络模块。

4.1.1 构造 C2f_WTConv 模块

原 YOLOv8n 的 C2f 结构采用了大量标准卷积运算，集成了瓶颈结构和跨层连接，增加了模型的计算复杂度，其中的 Split 操作也不利于硬件部署，因为这种操作需要特殊的硬件支持以优化处理效率。此外 CSPDarknet-53 的大量堆叠结构也加深了网络的复杂度，增加了模型的计算负担，影响了部署时的效率。因此需要对 C2f 结构进行轻量化改造，WTConv（Wavelet Convolution）[65]是一种新型的大核卷积，解决了 CNN 在实现大感受野时参数过多的问题，如图 22 所示。

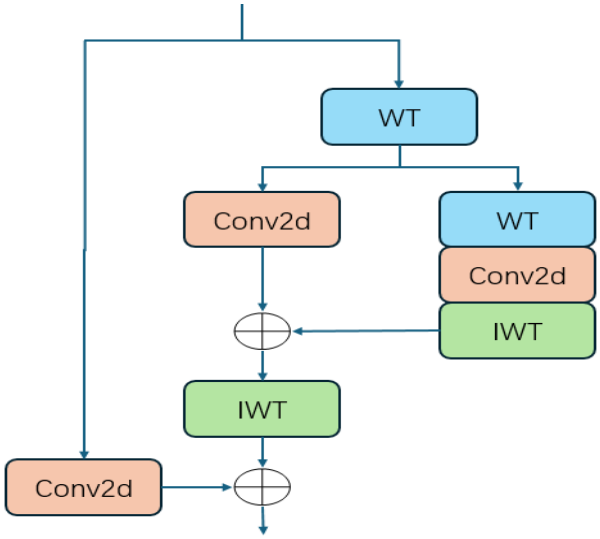

图 22 WTConv 结构图

Fig22 Structure diagram of WTConv

中国知网 https://www.cnki.net

WTConv 通过对输入数据的不同频率带处理捕捉局部和全局特征，而传统的 CNN 只能处理局部特征。具体来说，WTConv 模块利用小波变换（WT）实现更大的感受野，有效地提取了低频信息，同时避免了与过度参数化相关的问题。WTConv 模块的设计通过小波变换将输入信号分解为不同频率的子带，这需要对输入信号的低频和高频分量进行滤波和下采样，随后小卷积核利用小波逆变换（IWT）对输出进行重构。此过程可概括如下公式 4.1：

$$Y = \mathrm{IWT}\left(\mathrm{Conv}(w, \mathrm{WT}(X))\right) \tag{4.1}$$

其中 X 表示输入张量，w 表示卷积核权重，Conv、WT 和 IWT 分别表示卷积运算、小波变换及其逆变换。

受小波变换卷积的启发，改进算法替换 C2f 的 Bottleneck 中的普通卷积为 WTConv，将其集成到 YOLOv8 网络的 C2f 中，形成一种新的 C2f_WT 结构，如图 23 所示。通过 WTConv 有效捕获低频特征信息并以最小的参数实现更大的感受野，显著增强了网络对形状的响应能力，为复杂场景中的目标检测任务提供了一种新的技术思路及易于集成的模块化解决方案 。

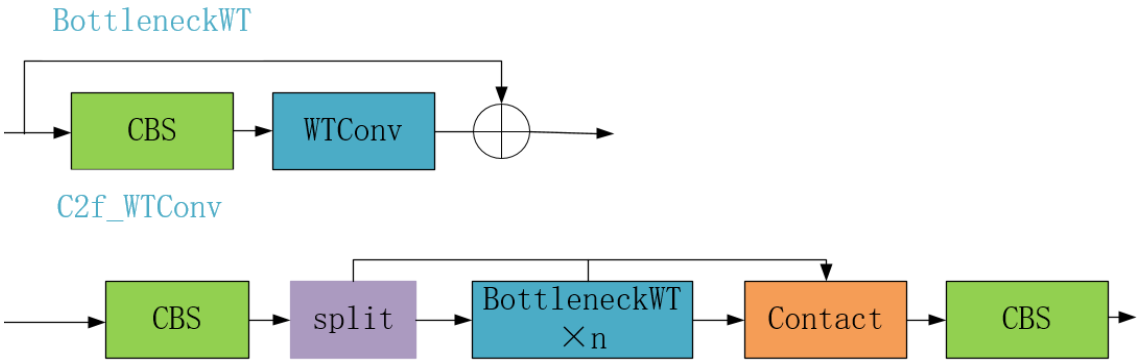

图 23 C2f_WT 结构图

Fig23 Structure diagram of C2f_WT

4.1.2 设计 DEHSFPN 结构

绝缘子缺陷大小的变化和微观差异，给检测缺陷带来相当大的多尺度挑战。为了有效地解决这一障碍，HSFPN（High-level Screening-Feature Pyramid Network）[66]提供了一个解决方案，构建与尺度变化相协调的分层特征金字塔来保留小目标的信息，使得模型能够捕获更加全面的目标的特征信息，提高了检测准确性和稳健性。HSFPN 的简单结构还显著减少了计算冗余，缩小了模型尺寸，这为本章讨论的轻量化改进提供了指导。HSFPN 结构由特征选择模块（FSM）和特征融合模块（FFM）组成，通过二者实现了多

中国知网 https://www.cnki.net

尺度特征的分层和选择性利用，这有助于模型更好地检测小目标或目标的特定细节，提高了模型检测的鲁棒性。FSM 使用通道注意力（CA）和维度匹配（DM）机制过滤不同尺度的特征图，有效地提取每个通道中的关键信息，而 FFM 主要使用 Select Feature Fusion（SFF）模块，将转置卷积和双线性插值结合来处理高级特征，实现有目的的特征融合。

原始的 HS-FPN 通道注意力机制关注通道间信息，忽略空间维度的信息，降低了输入特征图的通道维度。为此使用 ELA （efficient local attention）模块[67]替换 HSFPN 中的 CA 模块，本章提出 EHSFPN 模块，其结构如图 24 所示。与 CA 不同，ELA 不需要降维，它允许保持输入特征图的通道维数，从而能更加细致地捕捉到重要特征区域。ELA 注意力机制独立地处理每个方向上的特征向量以获得注意力预测，保持狭窄的核形状以捕获长距离依赖关系，然后使用乘积运算将它们组合起来，确保感兴趣区域的准确位置信息。

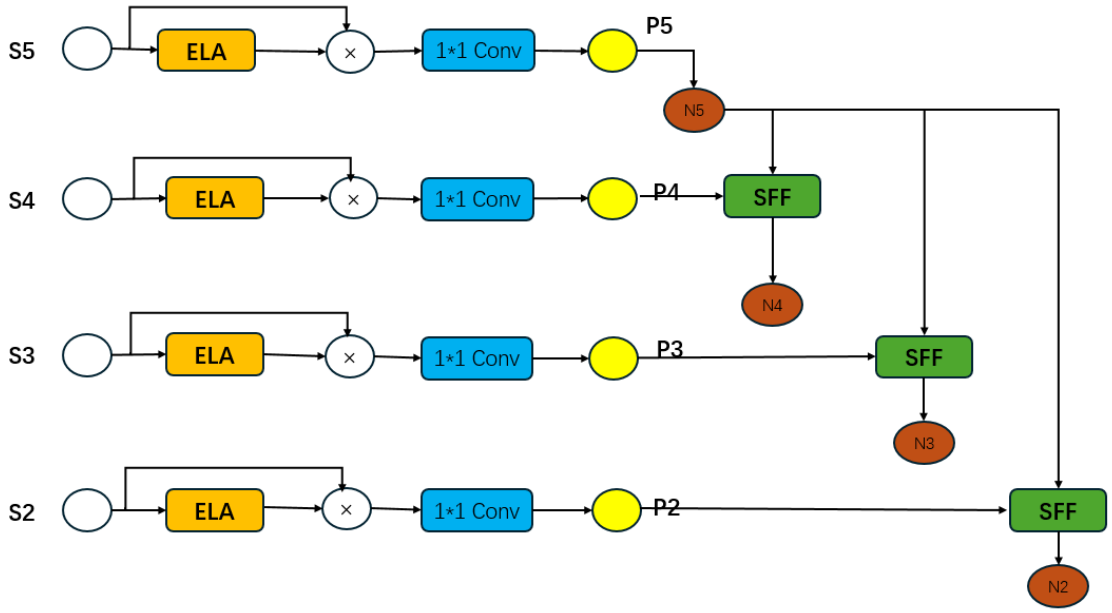

图 24 EHSFPN 结构图

Fig24 EHSFPN structure diagram

EHSFPN 模块有效地结合了 ELA 注意力机制和 HSFPN 结构的优点，通过筛选重要特征并融合低级和高级特征，增强了模型对小目标的检测能力。其轻量化结构也简化了准确定位感兴趣区域的过程，保持了较低的计算和参数要求，大大提高了检测速度和鲁棒性。

SFF 结合了来自各种尺度的特征图，它不是简单地添加高级和低级特征的像素值，

中国知网 https://www.cnki.net

而是采用战略性方法来进行特征融合。该模块使用更高级别的特征作为权重来过滤和选择性地从低级特征中提取相关信息，这个过程选择性地融合了低尺度特征的语义信息和详细信息。但其融合特征包含的目标空间位置信息较少，定位能力较弱。另外，HS-FPN 通过转置卷积和双线性插值相结合的方法来恢复高阶特征的尺度，在绝缘子缺陷检测任务中，存在密集缺陷的情况，这会带来性能上的缺失。因此改进算法将通道特征自过滤模块更换为 ELA 模块，并将转置卷积与双线性差值的组合替换为 DySample[68]模块，如图 25 所示。DySample 避免了动态卷积的必要性，采用基于点的采样方法来提高小目标图像的分辨率，它允许上采样过程动态调整每个像素的值和位置，而不会造成额外的计算负担。DySample 模块如图 26 所示，它采用了分组上采样的方式，将特征图从通道维度分为四组，每组中产生的偏差分别进行上采样，在每个分组中要素共享相同的采样集。这种方法不仅可以更好地保留输入特征图中的细节信息，还可以缓解与传统方法相关的细节丢失问题。

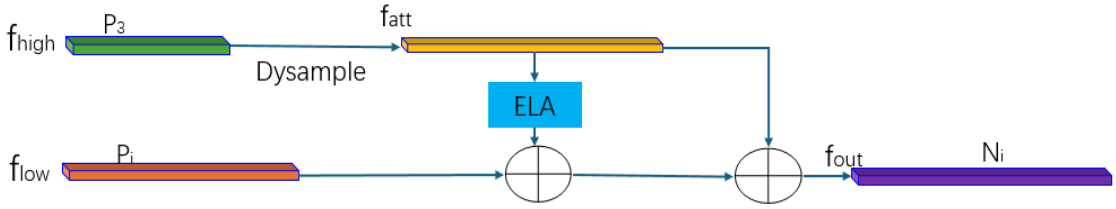

图 25 改进后的 SFF 模块

Fig25 The improved SFF module

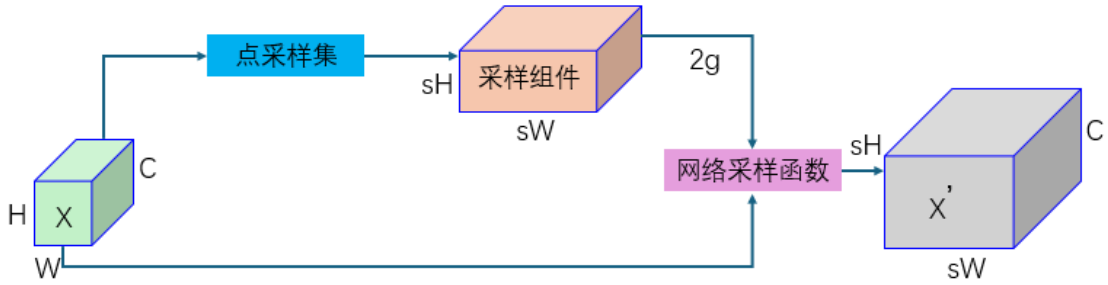

图 26 Dysample 模块

Fig26 Dysample module

4.2 基于知识蒸馏的检测精度改进

在 4.1 节中，通过轻量化模块改进 YOLOv8 实现了算法的轻量化，使之满足实际场景对绝缘子缺陷检测的轻量化部署要求，但是改进后的模型的检测精度下降。知识蒸馏的目的在于不增加模型体积的前提下提升模型的检测精度，使轻量化模型的准确率可

中国知网 https://www.cnki.net

以满足实际检测要求。因此为了适当的提高轻量化算法对绝缘子缺陷检测的精度，使用知识蒸馏的方法弥补轻量化改进带来的精度损失，进一步提高 WDEH_YOLOv8 模型的检测性能。具体来说，以精度很高但较大的教师模型 YOLOv8 指导 WDEH_YOLOv8 模型的训练，将大模型的知识迁移到 WDEH_YOLOv8 模型中，使其在精确度与轻量化上具有双重优势。

现阶段，知识蒸馏主要涵盖 logits 蒸馏及 features 蒸馏两种方式。其中，features 蒸馏因其良好的拓展性已在众多视觉任务中得到广泛应用。但受存在差异任务模型结构的影响，许多 features 蒸馏方法是针对特定任务设计的。本文选择采用 features 蒸馏中的 MGD（Masked Generative Distillation）[69]方式，以 YOLOv8n 作为教师模型来训练 4.1 节中改进后的轻量化 WDEH_YOLOv8 模型。传统的基于特征的蒸馏方法通常让学生模型尽可能地模仿教师模型的输出，因为教师模型的特征具有更强的表示能力。但 MGD 知识蒸馏让学生模型凭借自身较弱的特征去生成教师模型较强的特征，而不是直接模仿教师模型。它帮助学生模型更好地表示输入图像。在蒸馏策略中，MGD 允许学生网络利用部分特征来重建教师网络的全部特征。在蒸馏过程中，会在学生网络的特征上随机设置一个掩码，掩盖学生特征的随机像素，迫使学生仅可以让用自己的部分特征来生成全部教师的特征，以此提升学生的表征能力。

在 MGD 方法中，教师及学生的第 l 个特征图分别用 $T^l \in R^{C\times H\times W}$ 及 $S^l \in R^{C\times H\times W}$ 表示，其中 l=1,…,L。首先为学生的第 l 个特征图设置一个随机掩码，该掩码可以表示为公式 4.2：

$$M_{i,j}^{l}=\begin{cases}0, R_{i,j}^{l}<\lambda \\ 1, R_{i,j}^{l}\geqslant\lambda\end{cases} \tag{4.2}$$

其中 $R_{i,j}^{l}$ 是一个介于 0 及 1 之间的随机数，i 及 j 分别表示特征图的水平及垂直坐标。超参数 λ 用于控制掩码比率，从而确定第 l 个特征图中被随机掩码覆盖的部分。

接下来，利用这个随机掩码覆盖学生的特征图，并尝试生成教师特征图中未被掩码覆盖的部分，这一过程可以通过公式 4.3 及 4.4 来描述：

$$T^{l}=G\left(f_{\text{align}}(S^{l})\cdot M^{l}\right) \tag{4.3}$$

$$G(F)=W_{l2}\left(\text{ReLU}\left(W_{l1}(F)\right)\right) \tag{4.4}$$

G 表示投影层，它包含两个卷积层（W_{11} 、 W_{12}）及一个 ReLU 激活层，F 代表特征。在本章中，采用 1×1 卷积层来适配层 f_{align}，用 3×3 卷积层来适配投影层中的 W_{l1} 及

中国知网 https://www.cnki.net

W_{l2}。对于 MGD，蒸馏损失 L_{mgd} 如公式 4.5 所示：

$$L_{\mathrm{mgd}}(S,T)=\sum_{l=1}^{L}\sum_{k=1}^{C}\sum_{i=1}^{H}\sum_{j=1}^{W}\left(T_{k,i,j}^{l}-G\left(f_{\mathrm{align}}(S_{k,i,j}^{l})M_{i,j}^{l}\right)\right)^{2} \tag{4.5}$$

其中 L 代表蒸馏层总数，C、H、W 分别表示特征图的通道数、高度及宽度，S 及 T 对应学生及教师的特征。

综合上述内容，本章采用公式 4.6 所示的总损失来训练模型。

$$L_{\mathrm{all}}=L_{\mathrm{original}}+\alpha\cdot L_{mgd} \tag{4.6}$$

其中，$L_{original}$ 是目标检测任务中的原始损失，α 是平衡损失的超参数。

4.3 实验结果及分析

本章的核心任务是运用知识蒸馏技术来构建高效轻量化的检测模型。本章实验环境及数据集与第三章实验基本保持一致，在自制的绝缘子数据集执行了一系列实验，以证实改进模型的泛化性能。为准确评估轻量化模型的检测能力，本节采用模型的参数量、平均精度均值等性能指标评估模型。

4.3.1 模型轻量化消融实验

为了验证本章介绍的 WDEH_YOLOv8 算法中各个模块方法的有效性，本节在自建的绝缘子缺陷数据集上进行了一系列消融实验，结果见表 4，其中"√"表示添加了相应的改进。

表 4 轻量化 YOLOv8 消融实验

Table4 Lightweight YOLOv8 ablation experiment

模型	C2f_WT	ELA_HSFPN	Dysample	P/%	R/%	mAP/%	Size/M	Param	GFLOPs
A				90.5	86.5	90.6	5.9	3,006,038	8.1
B	√			90.3	84.2	88.5	5.2	2,634,806	7.1
C		√		92.0	82.7	88.3	5.0	2,547,798	6.9
D			√	91.8	87.2	91.0	6.0	3,018,390	8.1
E		√	√	90.8	83.0	88.1	4.9	2,478,102	6.3
F	√	√		90.9	79.7	85.4	4.7	2,360,310	6.3
G	√	√	√	90.2	81.6	87.2	4.6	2,282,550	5.6

共分为 7 组模型。A 组以 YOLOv8n 为基础模型；B 组仅增加了 C2f_WTConv 模块；C 组仅采用了 ELA_HSFPN 模块；D 组仅配备了 Dysample 模块；E 组结合了 ELA_HSFPN 模块及 Dysample 模块；F 组结合了 C2f_WTConv 模块及 ELA_HSFPN 模块；G 组本章改进后的轻量化 WDEH_YOLOv8 模型。从表 4 可以看出，模型 G 在

中国知网 https://www.cnki.net

多个关键指标上均表现出色。模型 G 的召回率为 81.6%，略低于其他模型如 D（87.2%）、E（83%.0）和 F（79.7%），但其参数量和 GFLOPs 均为最低，表明模型 G 在保证一定召回率的同时实现了更小的模型规模。模型 G 的 mAP 为 87.2%，略低于其他模型如 D（91.0%）、C（88.3%）等。考虑到模型 G 的参数量和 GFLOPs 均为最低，其在轻量化方面的优势更加突出。模型 G 在保持较高准确率的同时实现了最优的参数量和计算开销，充分证明了其在轻量化 YOLOv8 模型设计中的优越性。其他模型如 A、B、C 等虽然在某些指标上有不错的表现，但其规模较大或性能有所牺牲，无法完全满足轻量化的需求。以上数据验证了所提改进方法的可行性与有效性，模型 G 在准确率、召回率和平均精度等方面表现优异，并且参数量和计算开销均为所有模型中最小，能实现在低硬件性能工业场景中的部署。

为了进一步验证 4.1 节中所做改进的有效性，本节以 mAP0.5 作为评估指标，直观展示了各模块及其组合在消融实验中的趋势，结果如图 27 所示，它以训练周期为横坐标，mAP 值为纵坐标。图 27 清楚地反映了随着训练周期的增加，模型的准确性也在逐步提高。

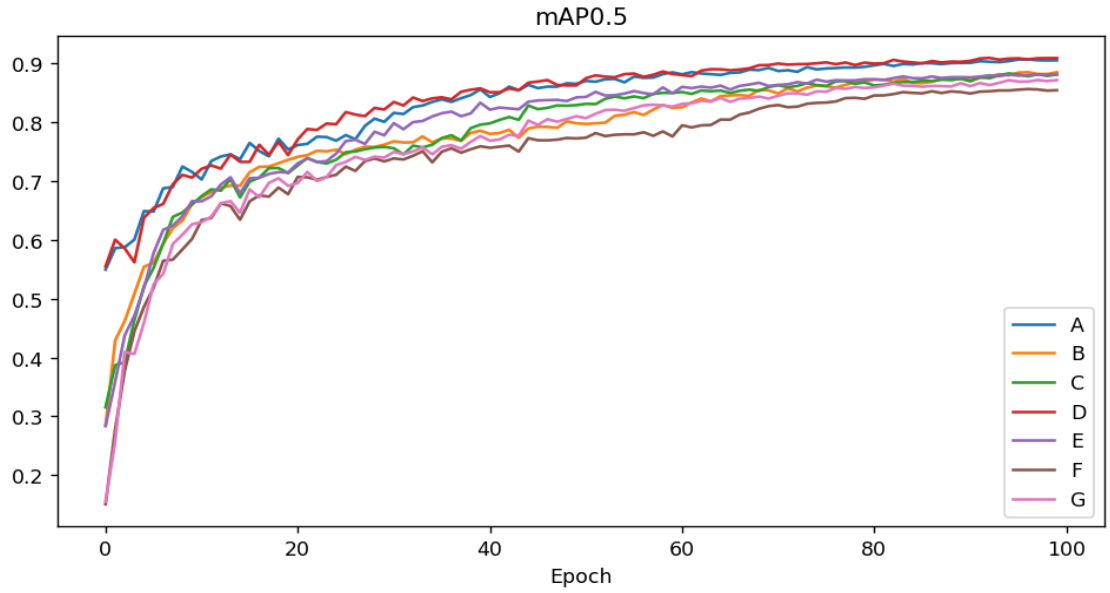

图 27 消融实验的 mAP0.5 曲线

Fig27 mAP0.5 curve for ablation experiment

如图 27 所示，通过消融实验对比了不同组件配置下模型的 mAP0.5 指标随训练轮次的变化趋势。从曲线整体表现来看，所有配置的模型性能均随训练轮次增加逐步提升，最终趋于收敛，表现出显著的学习收敛性。在训练初期（约 0-20 Epoch），各模型的曲线较为陡峭，说明模型在快速学习阶段，mAP0.5 值迅速提升。随着训练的进行（约 20-

中国知网 https://www.cnki.net

60 Epoch），曲线的斜率逐渐减小，模型进入平稳收敛阶段，mAP0.5 值的提升速度放缓。在训练后期（约 60-100 Epoch），各曲线趋于平稳，mAP0.5 值在 0.85-0.95 之间波动，表明模型已经基本收敛，性能达到较为稳定的水平。具体分析各曲线：模型 A、D 在前期训练中增速较快，且最终 mAP0.5 值显著高于其他配置，验证了对应组件组合的有效性；模型 B、C、E 虽整体趋势向上，但收敛后的性能略逊于模型 A、D，表明其模型结构对检测精度有显著影响；模型 F、G 的曲线在中后期增速放缓，最终性能相对较低，说明有提升目标检测精度的必要性。通过对比不同配置的曲线差异，验证了模型中各组件的有效性，也为后续模型优化提供了理论依据。

4.3.2 蒸馏算法实验结果与分析

4.3.1 节实验表明，轻量化模型 WDEH_YOLOv8 在参数量下降的同时也导致精度有所下降。鉴于此，为提高轻量化模型的精度，本实验采用 MGD 知识蒸馏的方法，以 YOLOv8n 模型作为教师网络引导学生模型 WDEH_YOLOv8 学习教师模型的性能，在不增加任何参数量和计算量的情况下，提高学生模型的性能。经过知识蒸馏后的模型称为 WDEH_YOLOv8+MGD，实验结果见表 5。

表 5 知识蒸馏前后模型对比

Table5 Comparison of models before and after knowledge distillation

模型	P/%	R/%	mAP/%	Size/M	Param	GFLOPs
YOLOv8n	90.5	86.5	90.6	5.9	3,006,038	8.1
WDEH_YOLOv8	90.2	81.6	87.2	4.6	2,282,550	5.6
WDEH_YOLOv8+MGD	92.0	86.5	91.0	4.6	2,282,550	5.6

根据表 5 所示，在知识蒸馏过程中，WDEH_YOLOv8+MGD 模型表现出显著的性能提升，其准确率（P%）从 90.2%提升至 92.0%，召回率（R%）从 81.6%提升至 86.5%，mAP 也从 87.2%提升至 91.0%，这说明 MGD 知识蒸馏利用教师网络的知识可以全面提升算法精度。同时,该模型在参数量和 GFLOPs 方面与轻量化后的 WDEH_YOLOv8 模型相同，既保证了模型精度又实现了模型的轻量化。与 YOLOv8n 相比，WDEH_YOLOv8+MGD 模型的参数量和 GFLOPs 量减少了 24.1%和 30.9%的同时实现了模型大小降至 4.6M，mAP 值也提高了 0.4%。这一结果表明，通过蒸馏过程，WDEH_YOLOv8+MGD 在保持参数规模不变的前提下，显著提升了准确率、召回率和平均精度，同时维持了与学生模型相当的计算量，能够极大地降低模型部署的成本。因此，可以认为 WDEH_YOLOv8+MGD 模型在知识蒸馏过程中取得了最佳平衡，展现出

中国知网 https://www.cnki.net

最优的性能表现，进一步验证了蒸馏过程的有效性和可行性，具有重要的理论和实际应用价值。

为了进一步突出知识蒸馏方案的优势，图 28 反映了教师模型 (YOLOv8n)、学生模型 (WDEH_YOLOv8) 及经过知识蒸馏训练的模型 (WDEH_YOLOv8+MGD) 的 mAP 变化曲线。图中清楚地反映了随着迭代次数的增加，每个模型的性能改善及收敛情况。

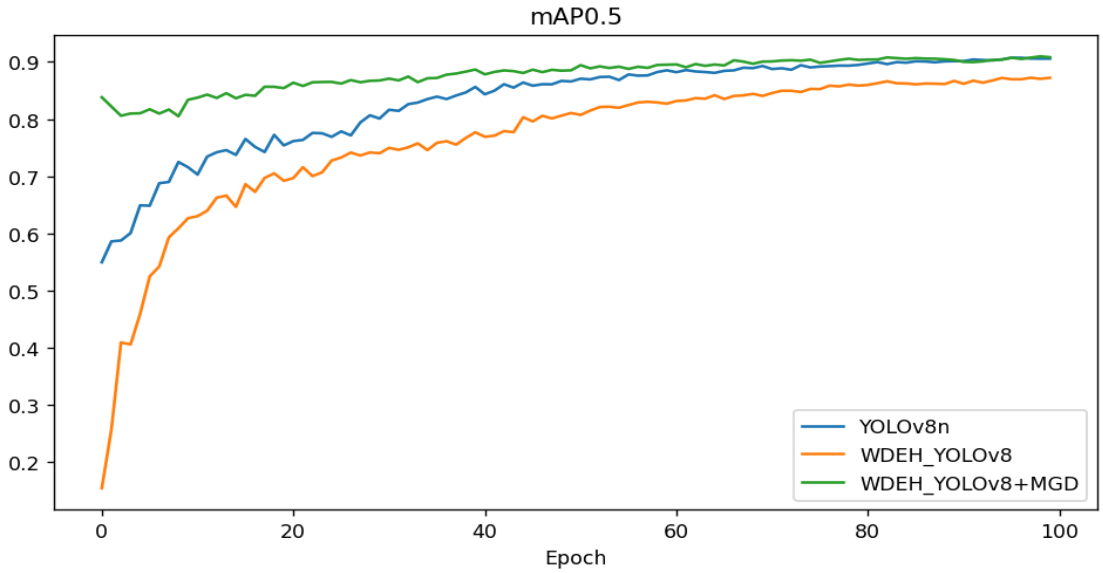

图 28 蒸馏前后的 mAP 变化曲线

Fig28 mAP curves before and after distillation

由图 28 可知，模型 WDEH_YOLOv8+MGD 在 mAP0.5 指标上展现出最优性能。从训练过程来看，模型 WDEH_YOLOv8+MGD 在初期即保持稳定增长趋势，且增速显著优于模型 YOLOv8n 与模型 WDEH_YOLOv8；进入中后期训练后，其曲线逐渐向教师网络的曲线靠拢并超越，mAP0.5 值率先趋近 0.9 并保持稳定，最终收敛值高于其他对比模型。模型 WDEH_YOLOv8 在训练初期的提升速度相对较慢，但随着训练的进行，其性能逐渐提升，最终接近模型 YOLOv8n 的水平。这一结果不仅验证了知识蒸馏的优越性，还表明知识蒸馏策略能使学生模型从教师模型中汲取到重要知识，实现了模型 mAP 值在后期得到较大提升。

4.3.3 与其它轻量化模型对比实验

在成功应用知识蒸馏技术优化学生网络模型后，本实验将优化后的模型与其他轻量化模型进行性能对比，对比实验结果如表 6 所示。本章复现文献[70]工作，其在 YOLOv8n 基础上，引入 SE 注意力机制和使用 C2f_CIB 模块替换部分 C2f 模块，以减少模型参数。同时，本章复现文献[71]工作，其通过更换主干网络 MobileNetv3 和添加 CA 注意力机制

中国知网 https://www.cnki.net

对 YOLOv5 进行改进，从而在保持一定检测精度的同时降低参数量和计算量。

表 6 不同轻量化模型对比

Table6 Comparison of different lightweight models

Model	P/%	R/%	mAP/%	Size/M	Param	GFLOPs
YOLOv5s	91.8	89.9	93.1	13.7	7,015,819	15.8
YOLOv8n	90.5	86.5	90.6	5.9	3,006,038	8.1
YOLOv8_MobileNetv2	89.4	80.3	85.8	7.5	3,756,918	10.1
YOLOv8_Shufflenetv2	90.0	78.3	83.2	5.6	2,790,442	7.4
YOLOv8_Emo	87.0	78.6	84.7	12.3	6,279,402	9.2
文献[70]	91.4	86.3	90.2	5.3	2,675,158	7.6
文献[71]	84.6	72.7	78.1	4.8	2,358,256	5.4
CSSD_YOLOv8	92.1	90.2	93.8	10.0	4,984,654	49.8
WDEH_YOLOv8+MGD	92.0	86.5	91.0	4.6	2,282,550	5.6

本章对 WDEH_YOLOv8+MGD 的模型性能进行了详细的对比分析，由表 6 中的实验结果得，WDEH_YOLOv8+MGD 模型在准确率、召回率和平均精度表现最为突出，WDEH_YOLOv8+MGD 准确率为 92.0%，该指标高于大部分对比模型的表现，包括 YOLOv5s（91.8%）、YOLOv8n（90.5%）及文献[70]和文献[71]等轻量化模型。另外在参数数量（Param）和 GFLOPs 方面，WDEH_YOLOv8+MGD 的参数量为 2,282,550，GFLOPs 为 5.6，该模型在保证高性能的同时，具有较低的资源消耗，较其他对比模型更加轻量化。总的来说 WDEH_YOLOv8+MGD 在准确率、召回率和平均精度等关键指标上优于其他对比模型，并且其参数量和计算复杂度也较为合理。这表明 WDEH_YOLOv8+MGD 模型在轻量化与高精度之间取得了平衡，有较高的实用性及研究价值。

为了更直观展示本章所提出算法对绝缘子缺陷的检测效果，本节选取部分检测图像进行对比，其结果展示如图 29 所示。通过分析图 29 可以看出，YOLOv8n 在某些情况下，如存在多缺陷目标时，未能成功识别所有缺陷，表明该模型在缺陷检测的完整性上存在局限。轻量化模型 WDEH_YOLOv8 因其轻量化改进，绝缘子缺陷检测精度下降且存在绝缘子缺陷未检测到情况。采用知识蒸馏方法的模型 WDEH_YOLOv8+MGD，其性能优于 YOLOv8n，在确保轻量化的同时增强了小目标识别能力，密集目标的检测精确度也较高，在遮挡目标检测效果上更为准确可靠，有效解决了绝缘子缺陷检测中出现的误检和漏检问题。本章最终提出的模型在检测精度和轻量化之间做到了很好的平衡，能够满足实际应用中轻量、精确的检测要求，提高了模型在实际应用场景中的适用性和可靠性。

中国知网 https://www.cnki.net

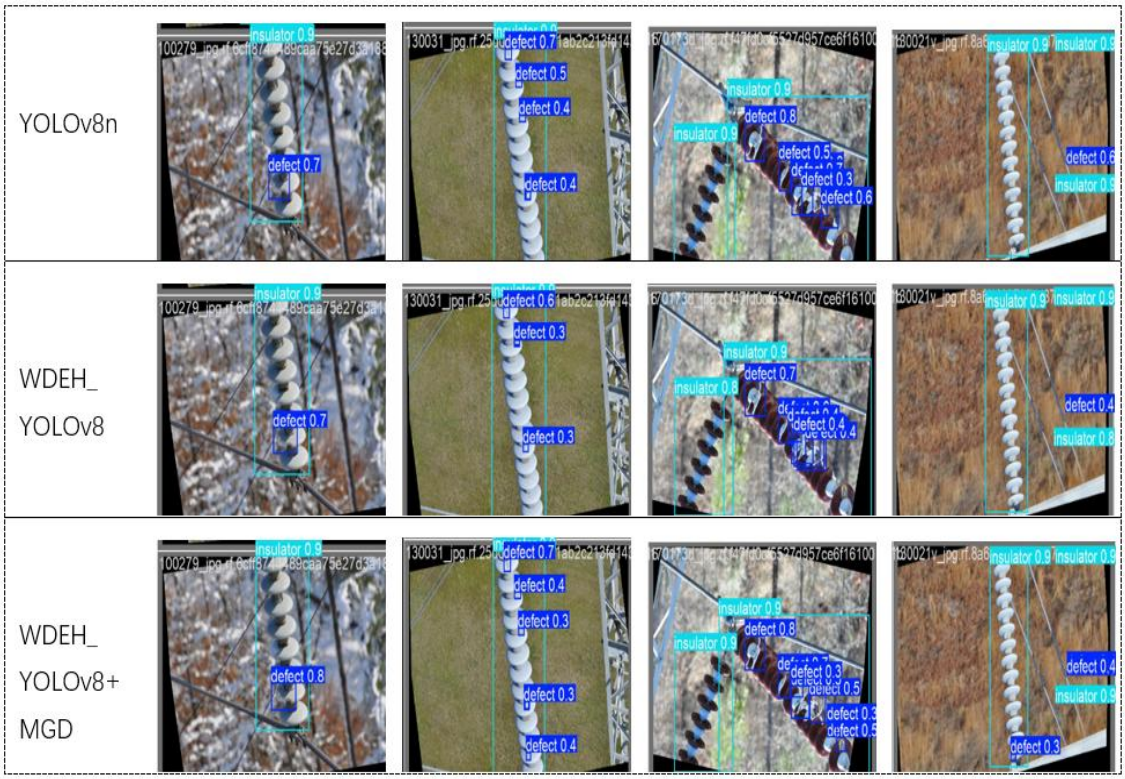

图 29 模型改进前后的检测图

Fig29 Detection diagram before and after model improvement

4.4 本章小结

本章主要介绍轻量级网络设计及知识蒸馏技术改进，旨在构建高效、轻量级的检测模型。本章先通过构建 C2f_WTConv 模块、设计 DEHSFPN 结构的轻量级方法减少了模型参数量；然后利用知识蒸馏技术让教师模型（YOLOv8n）训练轻量级学生模型（WDEH-YOLOv8），既保持了较高的检测精度，又减少了计算资源的消耗。实验结果表明，与现有的轻量级模型相比，所提出的方法在准确率、召回率及平均精度方面表现良好，并且参数量及 GFLOP 量较低。这既证实了轻量级改进模型在缺陷检测的有效性，又为电力系统中的高效缺陷检测提供了解决方案，对理论研究及实际应用都具有很高的价值。

中国知网 https://www.cnki.net

5 总结与展望

5.1 论文总结

高压输电线路的绝缘子数量众多，可靠性较低，其存在缺陷容易影响电力系统的安全稳定运行。基于此，准确检测缺陷对维护电力系统安全运行具有重要意义。本文以绝缘子航拍图像为研究对象，针对绝缘子图像检测中存在的问题， 以 YOLOv8 算法作为基础，在提升检测精度及模型轻量化两个方面进行优化改进，使其更好地适用于绝缘子的缺陷检测。本文的主要工作包括：

(1) 针对原 YOLOv8 模型在检测绝缘子缺陷时存在精度低及漏检的问题，本文提出了一种改进模型 CSSD_YOLOv8。该模型的设计首先采用 SAConv 代替传统的 Conv，设计了全新的 SA_C2f 模块，以提高模型对复杂尺度目标的特征提取能力；接着设计了 SPPF_LSKA 模块，让模型能够更全面地捕捉存在差异尺度的特征信息；在检测架构方面，优化了传统检测架构，构建了一种改进型的 DWR_Detect 模块，显著降低了小目标的漏检率；在此期间还新增了小目标检测层，进一步提高了小目标的检测性能，强化了深层语义信息与浅层目标检测性能的结合。实验结果表明，改进后的算法既改善了传统 YOLOv8 算法在绝缘子缺陷检测中的漏检和误检问题，也显著提高了整体的检测精度，相较于原始算法在 mAP 值提升了 3.1%，为电力系统的安全稳定运行提供了有力的技术支持。

（2）考虑到绝缘子缺陷检测模型的参数量及计算量大，不利于部署等问题，本文提出了轻量化结构与知识蒸馏相结合的绝缘子缺陷检测模型。该算法以 YOLOv8n 为基础网络，在模型架构设计上进行了多项优化。具体而言，在图像特征提取环节，改进算法将 WTConv 模块与 C2f 组件相结合，构建了高效特征提取框架 C2f_WTConv，通过增加网络感受野来更好地捕捉目标细节；在特征融合部分，设计 DEHSFPN 结构，结合 ELA 注意力及 HSFPN 结构形成 EHSFPN 高效特征融合网络，并且采用 Dysample 上采样算子进行动态采样，提升了特征融合的效率及性能。为提升检测精度，改进算法采用 MGD 知识蒸馏技术，在保持原始模型参数量不变的前提下，达到了提高检测精度的效果。实验结果表明，与 YOLOv8n 相比，改进后的模型 mAP 值提高了 0.4%，参数量及 GFLOPs 数量减少了 24.1%及 30.9%的同时，实现了模型大小降至 4.6M，这使得改进后的算法更适合部署到计算资源受限的设备上使用。

中国知网 https://www.cnki.net

5.2 未来展望

本文研究的绝缘子缺陷检测模型虽取得一定的进展，但仍有进一步可优化空间，未来可以从以下几个方面对算法进行改进，一是数据集的扩展及优化，考虑到真实场景中绝缘子缺陷的类型较多，未来可以收集更多不同背景下的绝缘子缺陷图像，涵盖更广泛材质的绝缘子及缺陷类型，以增强模型的泛化性和鲁棒性；二是对于模型的轻量化改进方面还可再提升，本文提出的轻量化改进策略，在模型复杂度和计算量方面还能继续改善，实验方面还可补充与基于 Transformer 的算法进行准确率对比，未来的工作可探索更多轻量化算法，使得模型在保证检测精度的同时更加轻量； 三是在实际部署方面，本文所提出的绝缘子缺陷检测算法仅进行了模型的设计和训练任务，没有落实到实际应用中的部署工作，在实际部署中可以结合 5G 通信、云计算等技术，实现真正的智能检测并拓展检测的应用领域，如在高塔压力容器领域，提升绝缘子缺陷检测的应用价值。

中国知网 https://www.cnki.net

参考文献

[1] 陈伯建,张伟豪,吴文斌,等.基于改进 YOLOv7 的配电网绝缘子缺陷检测[J].电子测试,2023,(06):24-29.

[2] 胡鞍钢,周绍杰.中国“十四五”时期经济社会发展初步评估[J/OL].北京工业大学学报(社会科学版),1-24[2025-03-30].

[3] Liu J, Hu M, Dong J, et al. The application of a lightweight model FA-YOLOv5 with fused attention mechanism in insulator defect detection[J]. Frontiers in Energy Research, 2023, 11: 1283394.

[4] 廖丽瑛,刘洪.基于改进 YOLOv8 的绝缘子自爆缺陷检测[J].电子测量技术,2024,47(18):138-144.

[5] 刘开培,李博强,秦亮,等.深度学习目标检测算法在架空输电线路绝缘子缺陷检测中的应用研究综述[J].高电压技术,2023,49(09):3584-3595.

[6] 杨世芳,臧欣怡,朱明曦,等.融合多尺度卷积注意力机制的绝缘子表面藻类污秽语义分割和识别算法研究[J].绝缘材料,2024,57(11):135-143.

[7] Zhang Q, Zhang J, Li Y, et al. IL-YOLO: an efficient detection algorithm for insulator defects in complex backgrounds of transmission lines[J]. IEEE Access, 2024, 12: 14532-14546.

[8] 臧积业,曲朝阳,董运昌,等.基于仿生视觉骨干的级联蒸馏输电线路目标检测模型[J].高电压技术,2024,50(08):3757-3768.

[9] Zhao Z, Liu N, Wang L. Localization of multiple insulators by orientation angle detection and binary shape prior knowledge[J]. IEEE Transactions on Dielectrics and Electrical Insulation, 2016, 22(6): 3421-3428.

[10] Jabid T, Uddin M Z. Rotation invariant power line insulator detection using local directional pattern and support vector machine[C]//2016 International conference on innovations in science, engineering and technology (ICISET). IEEE, 2016: 1-4.

[11] Zhai Y, Chen R, Yang Q, et al. Insulator fault detection based on spatial morphological features of aerial images[J]. IEEE Access, 2018, 6: 35316-35326.

[12] Guifeng Z, Zhiren T. Swarm optimization clustering for image segmentation of insulators[C]//2019 14th IEEE Conference on Industrial Electronics and Applications (ICIEA). IEEE, 2019: 397-401.

[13] Liu Y, Xie Z, Liu H. An adaptive and robust edge detection method based on edge proportion statistics[J]. IEEE Transactions on Image Processing, 2020, 29: 5206-5215.

[14] 陈文浩,姚利娜,李丰哲.无人机电网巡检中的绝缘子缺陷检测与定位[J].计算机应用,2019,39(S1):210-214.

[15] Li Z, Song Y, Li R, et al. A novel data augmentation method for improving the accuracy of insulator health diagnosis[J]. Sensors, 2022, 22(21): 8187.

[16] Kang G, Gao S, Yu L, et al. Deep architecture for high-speed railway insulator surface defect detection: Denoising autoencoder with multitask learning[J]. IEEE Transactions on Instrumentation and Measurement, 2018, 68(8): 2679-2690.

中国知网 https://www.cnki.net

[17] 顾超越,李喆,史晋涛,等.基于改进 Faster-RCNN 的无人机巡检架空线路销钉缺陷检测[J].高电压技术,2020,46(09):3089-3096.

[18] Feng Z, Guo L, Huang D, et al. Electrical insulator defects detection method based on yolov5[C]//2021 IEEE 10th Data Driven Control and Learning Systems Conference (DDCLS). IEEE, 2021: 979-984.

[19] 熊炜,黄玉谦,孟圣哲.基于改进 YOLOv8 算法的绝缘子缺陷检测模型[J].电子测量技术,2024,47(12):132-139.

[20] Ahmed F, Mohanta J C. Inspection of power transmission line insulators with autonomous quadcopter and SSD network[J]. Sigma Journal of Engineering and Natural Sciences, 2024, 42(3): 621-632.

[21] Zhang L, Li B, Cui Y, et al. Research on improved YOLOv8 algorithm for insulator defect detection[J]. Journal of Real-Time Image Processing, 2024, 21(1): 22.

[22] Wang B, Ma F, Ge L, et al. Icing-EdgeNet: A pruning lightweight edge intelligent method of discriminative driving channel for ice thickness of transmission lines[J]. IEEE transactions on instrumentation and measurement, 2020, 70: 1-12.

[23] Liu J, Liu C, Wu Y, et al. An improved method based on deep learning for insulator fault detection in diverse aerial images[J]. Energies, 2021, 14(14): 4365.

[24] Qiu Z, Zhu X, Liao C, et al. Detection of transmission line insulator defects based on an improved lightweight YOLOv4 model[J]. Applied Sciences, 2022, 12(3): 1207.

[25] Li Y, Wei S, Liu X, et al. An improved insulator and spacer detection algorithm based on dual network and SSD[J]. IEICE TRANSACTIONS on Information and Systems, 2023, 106(5): 662-672.

[26] 伍箴燎,吴正平,孙水发.基于改进 YOLOv5 算法的绝缘子多缺陷检测[J].高压电器,2024,60(12):95-102+112.

[27] 赵洋,刘青,李宁,等.融合注意力与轻量化的多尺度电缆绝缘子缺陷检测[J].电瓷避雷器,2024,(06):145-152.

[28] Liu Y, Li X, Qiao R, et al. Lightweight Insulator and Defect Detection Method Based on Improved YOLOv8[J]. Applied Sciences, 2024, 14(19): 8691.

[29] Pinkus A. Approximation theory of the MLP model in neural networks[J]. Acta numerica, 1999, 8: 143-195.

[30] Hubel D H. Exploration of the primary visual cortex, 1955–78[J]. Nature, 1982, 299(5883): 515-524.

[31] Maniatopoulos A, Mitianoudis N. Learnable leaky relu (LeLeLU): An alternative accuracy-optimized activation function[J]. Information, 2021, 12(12): 513.

[32] Chen H, Ye Q. Composite Optimization Algorithms for Sigmoid Networks[J]. Neural Computation, 2023, 35(9): 1543-1565.

[33] Wang C, Wang Y, Deng T, et al. A nonlinear multi-label learning model based on Tanh mapping[J]. Engineering Applications of Artificial Intelligence, 2023, 126: 106837.

[34] Wang X, Liu X, Wang J, et al. Improved variational mode decomposition and one-dimensional CNN network with parametric rectified linear unit (PReLU) approach for rolling bearing fault diagnosis[J]. Applied Sciences, 2022, 12(18): 9324.

中国知网 https://www.cnki.net

[35] Jocher G, Stoken A, Borovec J, et al. ultralytics/yolov5: v4. 0-nn. SiLU () activations, Weights & Biases logging, PyTorch Hub integration[J]. Zenodo, 2021.

[36] 公鹏.基于细节特征增强的小目标检测方法研究[D].山东财经大学,2024.

[37] 祝浪洪.基于深度学习的道路路面病害检测与分割研究[D].重庆交通大学,2024.

[38] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2014: 580-587.

[39] Girshick R. Fast r-cnn[C]//Proceedings of the IEEE international conference on computer vision. 2015: 1440-1448.

[40] 唐茂俊,黄海松,张松松,等.改进的 Faster-RCNN 在焊缝缺陷检测中的应用[J].组合机床与自动化加工技术,2021,(12):83-86.

[41] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. IEEE transactions on pattern analysis and machine intelligence, 2016, 39(6): 1137-1149.

[42] 黄鹏豪.基于深度学习的 PCB 缺陷检测[D].电子科技大学,2024.

[43] 陈长.基于改进 YOLOv8 的玫瑰叶片病害检测方法研究[D].武汉轻工大学,2024.

[44] Liu W, Anguelov D, Erhan D, et al. Ssd: Single shot multibox detector[C]//Computer Vision–ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part I 14. Springer International Publishing, 2016: 21-37.

[45] 汪红江.基于 YOLO 算法的黄瓜花果检测的研究与实现[D].扬州大学,2024.

[46] 印元军.基于深度学习的无人机多目标检测算法研究[J].现代计算机,2023,29(19):22-25+47.

[47] Redmon J, Divvala S, Girshick R, et al. You only look once: unified, real-time object detection. 2016[J]. arXiv preprint arXiv:1506.02640, 2015, 825.

[48] Redmon J, Farhadi A. YOLO9000: better, faster, stronger[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 7263-7271.

[49] Redmon J, Farhadi A. Yolov3: An incremental improvement[J]. arXiv preprint arXiv:1804.02767, 2018.

[50] Bochkovskiy A, Wang C Y, Liao H Y M. Yolov4: Optimal speed and accuracy of object detection[J]. arXiv preprint arXiv:2004.10934, 2020.

[51] Jocher G, Stoken A, Borovec J, et al. ultralytics/yolov5: v3. 0[J]. Zenodo, 2020.

[52] Li C, Li L, Jiang H, et al. YOLOv6: A single-stage object detection framework for industrial applications[J]. arXiv preprint arXiv:2209.02976, 2022.

[53] Wang C Y, Bochkovskiy A, Liao H Y M. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 7464-7475.

[54] 游越,伊力哈木·亚尔买买提,吐松江·卡日.基于 YOLOv6 的输电线路电力部件识别及缺陷检测算法研究[J].高压电器,2024,60(05):194-205+213.

中国知网 https://www.cnki.net

[55] 熊恩杰,张荣芬,刘宇红,等.面向交通标志的 Ghost-YOLOv8 检测算法[J].计算机工程与应用,2023,59(20):200-207.

[56] Hinton G, Vinyals O, Dean J. Distilling the knowledge in a neural network[J]. arXiv preprint arXiv:1503.02531, 2015.

[57] Gou J, Yu B, Maybank S J, et al. Knowledge distillation: A survey[J]. International Journal of Computer Vision, 2021, 129(6): 1789-1819.

[58] 夏正洪,魏汝祥,屠佳,等.通航机场场面运动目标检测方法[J].科学技术与工程,2022,22(29):13114-13119.

[59] Qiao S, Chen L C, Yuille A. Detectors: Detecting objects with recursive feature pyramid and switchable atrous convolution[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 10213-10224.

[60] Lau K W, Po L M, Rehman Y A U. Large separable kernel attention: Rethinking the large kernel attention design in cnn[J]. Expert Systems with Applications, 2024, 236: 121352.

[61] Guo M H, Lu C Z, Liu Z N, et al. Visual attention network[J]. Computational visual media, 2023, 9(4): 733-752.

[62] Wei H, Liu X, Xu S, et al. DWRSeg: Rethinking efficient acquisition of multi-scale contextual information for real-time semantic segmentation[J]. arXiv preprint arXiv:2212.01173, 2022.

[63] 季世超,曲星合,宋庆彬,等.基于改进 YOLOv5 的轻量化绝缘子缺陷检测算法[J].浙江电力,2023,42(12):64-72.

[64] 唐靓,余明慧,武明虎,等.基于改进 YOLOv5 的绝缘子缺陷检测算法[J].华中师范大学学报(自然科学版),2022,56(05):771-780.

[65] Finder S E, Amoyal R, Treister E, et al. Wavelet convolutions for large receptive fields[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2024: 363-380.

[66] Shi Z, Hu J, Ren J, et al. HS-FPN: High Frequency and Spatial Perception FPN for Tiny Object Detection[J]. arXiv preprint arXiv:2412.10116, 2024.

[67] Xu W, Wan Y. ELA: Efficient local attention for deep convolutional neural networks[J]. arXiv preprint arXiv:2403.01123, 2024.

[68] Liu W, Lu H, Fu H, et al. Learning to upsample by learning to sample[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 6027-6037.

[69] Yang Z, Li Z, Shao M, et al. Masked generative distillation[C]//European conference on computer vision. Cham: Springer Nature Switzerland, 2022: 53-69.

[70] Liu X, Du R, Tan L, et al. CIB-SE-YOLOv8: Optimized YOLOv8 for Real-Time Safety Equipment Detection on Construction Sites[J]. arXiv preprint arXiv:2410.20699, 2024.

[71] 郭安文,权冀川.基于改进 YOLOv5 算法的安全帽佩戴实时检测模型[J].计算机时代,2023,(10):105-109+114.

中国知网 https://www.cnki.net